上下文工程：打造有状态、有记忆的AI Agent

Google 白皮书解读

会话

记忆

Google

上下文工程vs.Prompt工程：不仅仅是写提示

从静态指令到动态信息组装的进化

Prompt 工程(关注静态提示词)

- 编写最佳的静态系统指令引导模型。

类比：优化菜谱

上下文工程(关注动态组装)

- 在每次调用时构建包含多源信息的完整输入有效载荷。

类比：备料与组装(提供恰到好处的信息)

⚠ 核心挑战与治理(Challenges & Governance)

有限窗口、成本增加、上下文衰减->解决方案：动态裁剪、压缩、摘要，确保不超载不遗忘。

Google

会话(Session):
短期对话上下文的“工作台”

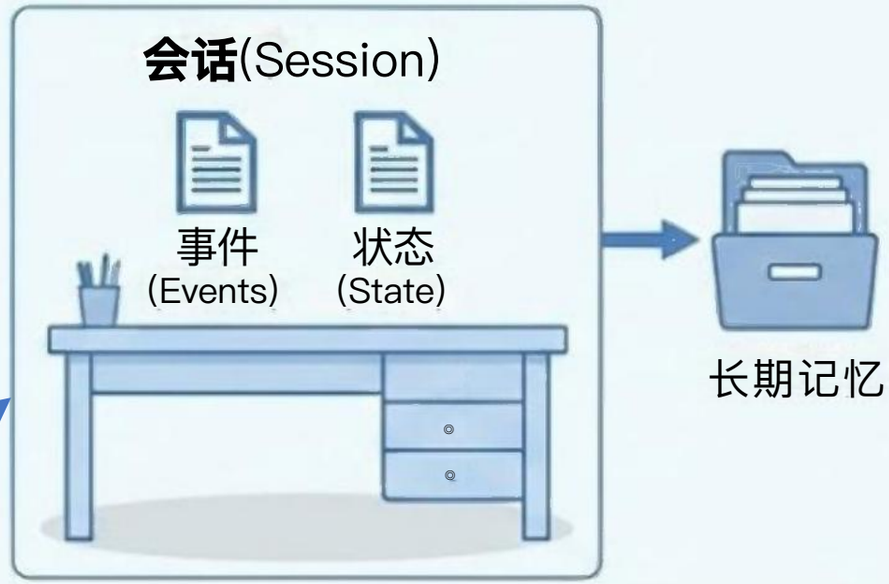

核心组件

事件(Events)序列

用户输入→AI回复→工具调用→工具结果

状态(State)/ 工作内存(便笺)

临时结构化数据
(如：当前任务、中间结果)

框架实现差异

Google ADK

[Event列表]

[独立的state对象]

其他框架(如LangChain)

[大的状态对象
(包含对话和中间信息)]

目的：保持对话连贯性

多代理场景下的会话共享

模式一：统一的共享会话历史

所有Agent共同维护单一日志

- 一致的“真相来源”
- 适合紧密协作
- 事件带Agent标签

示例：Google ADK多代理委派

模式二：独立的私有会话历史

明确的消息传递

彼此看不到内部过程

- 类似黑箱工具
- 适合松散耦合
- 需设计通信协议

示例：Agent-as-a-Tool模式

核心考量：任务需求与协作方式

重要提示： 不论模式，调用LLM 时，应从历史中挑选相关片段作为上下文，而非整个日志。

长对话窗口挑战与会话压缩

目标：应对窗口溢出，在不丢失关键信息的前提下尽量缩短历史记录。

1.固定窗口保留 (Fixed Window)

- 滑动窗口机制(Sliding Window)
- 只保留最近N轮对话
- 简单直接，丢弃久远内容

2.基于Token 截断 (Token Truncation)

- 精确计算Token 计数
- 保留最近内容直至上限
- 比轮次更精细，确保不越界

3.递归摘要 (Recursive Summarization)

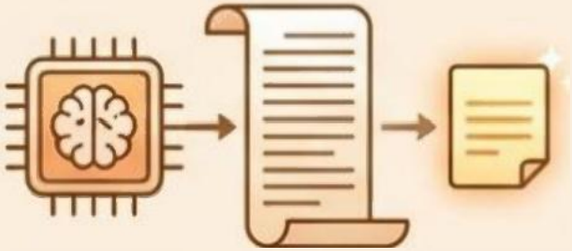

- 调用LLM总结旧内容
- 生成简短摘要腾出空间
- 后台异步执行，智能保留

触发 (Triggers)

阈值达标(轮数/Token)
闲置期后台处理|主题/任务完成

→

会话Session (短期记忆工作台)

遇过戲断/摘要保特合理大小，不滋出窗口

→ 提炼关键信息 →

长期记忆模块 (Long-Term Memory)

持久化保存，用于未来检隶引用

记忆：构建AI的长期个性化记忆库

从短期会话到跨会话的持久知识管理，打造“长期伙伴”

短期会话(Session)– 眼前的工作桌

长期记忆(Memory)– 分类有序的档案柜

关注当前对话状态，存储原始交互数据
(Raw Chat Logs)

经过加工的高价值知识(Refined Knowledge Points)，非逐字记录

赋能关键能力

个性化
(Personalization)

记住用户偏好和历史，无需重复询问。例如：记住“喜欢篮球” –> 自动推荐相关内容。

原始对话流
(Dialogue Stream)

记忆管理器
(Memory Manager)

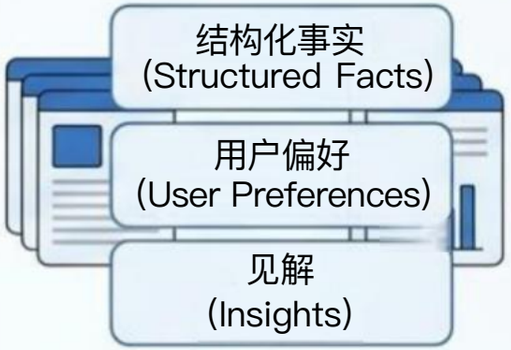

持久记忆让AI 从“短期应答者”升级为“长期伙伴”。

Memory vs. RAG:记忆不等于知识库检索

功能互补，定位不同：从“外部世界知识”到“个性化用户经验”

RAG （检索增强生成）

“图书管理员”：
查询外部世界知识

面向公共事实，
通用知识
（静态，外部数据）

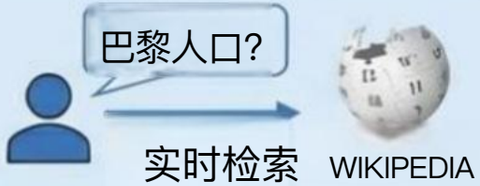

Memory （记忆系统）

“私人助理”：
熟知服务对象

面向用户和交互，
个性化上下文
（动态，用户特定数据）

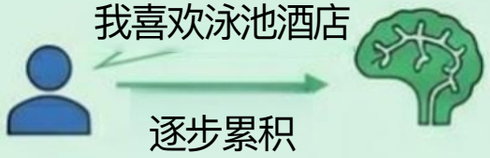

二者协同

权威知识 + 贴心服务=真正聪明的AI

记忆的种类：陈述性vs.程序性

AI Agent的长期记忆分类 —— 知道“是什么”与“怎么做”

陈述性记忆(Declarative Memory)

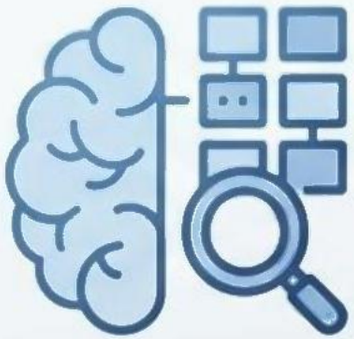

- 关于事实和事件的知识
- 回答“是什么”的问题
- 包含世界知识(语义记忆)与用户信息(情景记忆)

示例

用户姓名、生日、喜欢的球队，或上次投诉货物破损的事实

程序性记忆(Procedural Memory)

- 关于技能和流程的知识
- 回答“怎么做”的问题，隐含指导行动
- 类似于行动指南或可重用脚本

示例

订票步骤调用工具的流程，或引导愤怒用户冷静下来的对话策略

陈述性=事实/数据
(Facts/Data)

程序性=脚本/范例
(Scripts/Examples)

记忆的范围：用户、会话与全局（Scopes of Memory）

用户级记忆

个人档案

- 针对特定用户ID，跨会话持久存在
- 打造连续个性化体验
- 示例：记住“喜欢靠窗座位”

会话级记忆

当前会话精华

- 限定在单次会话，压缩长对话
- 替代冗长日志，只存加工精华
- 示例：浓缩行程查询细节

应用级记忆(全局)

通用知识库&流程

- 面向整个应用，所有用户共享
- 存储程序性知识与通用指导
- 需严格审核与匿名化

从个性化体验到通用规则：构建多层次的 AI 记忆体系

记忆存储：向量数据库vs. 知识图谱

存储架构影响检索效率与方式，需根据场景选择或融合。

向量数据库

- 将记忆转换为语义向量
- 通过向量相似度检索
- 适合非结构化自然语言，语义级匹配
- 常用方案，处理模糊记忆

知识图谱

- 存成实体–关系图谱
- 通过遍历图谱检索关联事实
- 擅长结构化、关系性查询与推理
- 适用于复杂连接场景

混合存储（Hybrid Storage）– 兼具优势

- 结合语义搜索与图谱遍历
- 兼具模糊匹配与精确推理
- 示例：开源项目Mem0、Cognee

多模态记忆：处理非文本信息

应对图像、音频等输入，AI 如何“记住”这些内容？

常见做法：多模态源转换为文本记忆

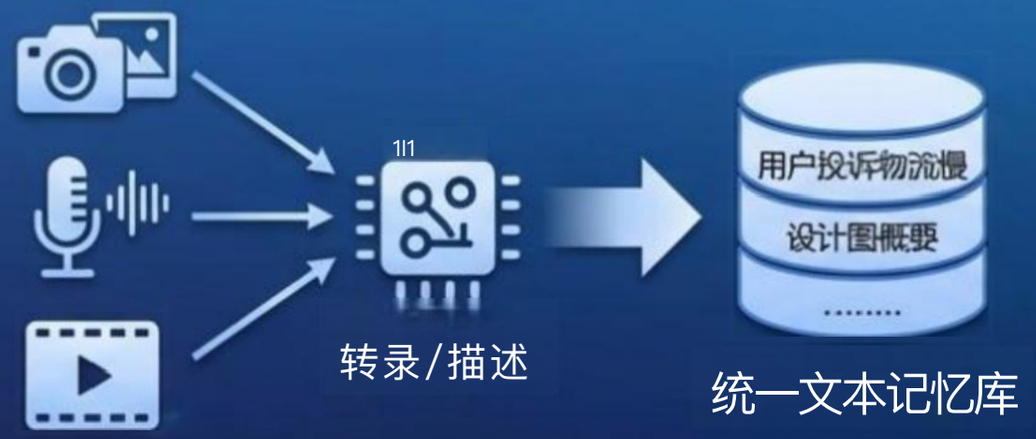

- 将图像/语音等转换为文字描述存储
- 统一存储格式，便于全文搜索
- 示例：语音投诉->转录为文字摘要记忆

高级做法：直接存储非文本内容

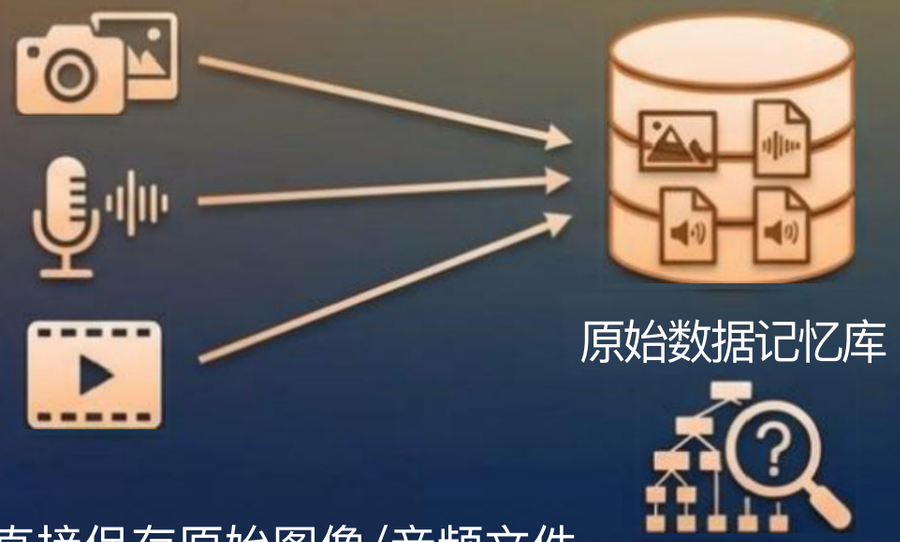

- 直接保存原始图像/音频文件
- 需专用模型支持搜索(如图像相似度)
- 复杂度高，格式难以统一索引，目前较少用

总 结：转换为文本作为“共同语言”是当前最简单有效的方案。未来可引入专门的多模态索引。

记忆的生成：LLM 驱动的提取与整合

一个自动化的ETL(Extract–Transform–Load） 流程，培养Agent 的专属知识库

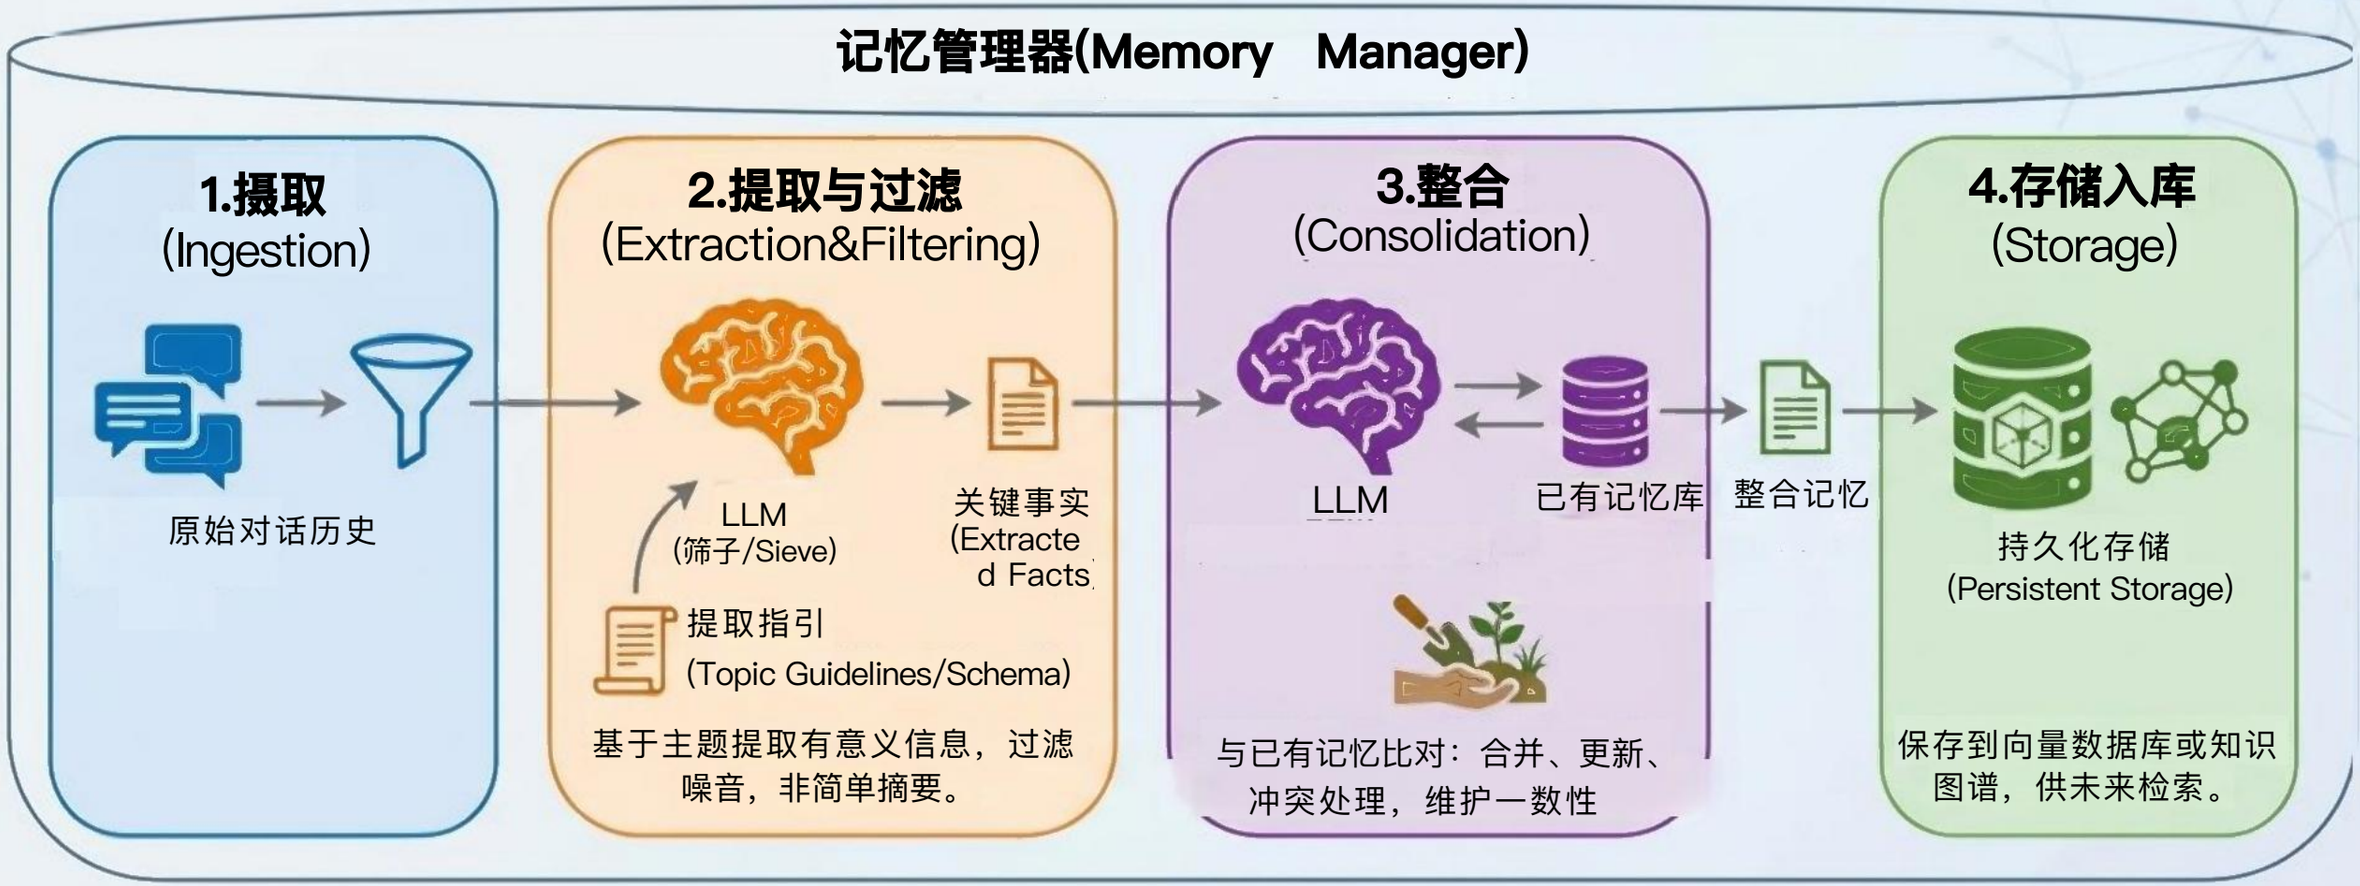

通过后台异步完成这些步骤，AI 自动沉淀知识，无需人工干预细节，实现个性化与聪明服务。

记忆的溯源与信任管理(Memory Provenance &Trust Management)

确保记忆可靠，防止“带有自信的谬误”,构建可信赖的 AI 伙伴。

1.来源溯源与信任层级
(Provenance &Trust Levels)

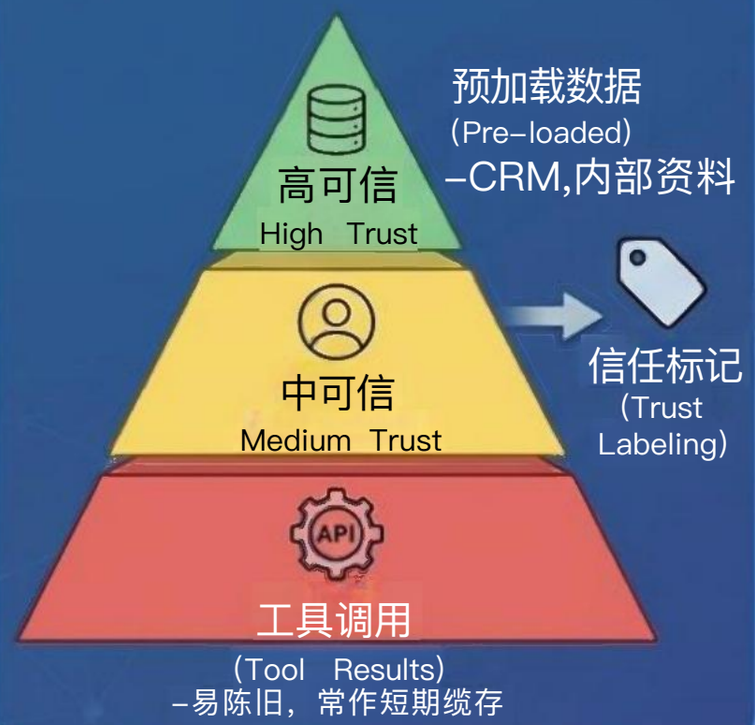

2.动态置信度与修剪
(Dynamic Confidence & Pruning)

3.推理中的信任考量
(Trust in Reasoning)

通过严格管理，防范“记忆中毒”,确保知识库长久可信。

在生产环境实现高效、安全、可扩展的上下文与记忆管理 (1/ 3)

解耦与异步：让记忆管理不拖慢主流程

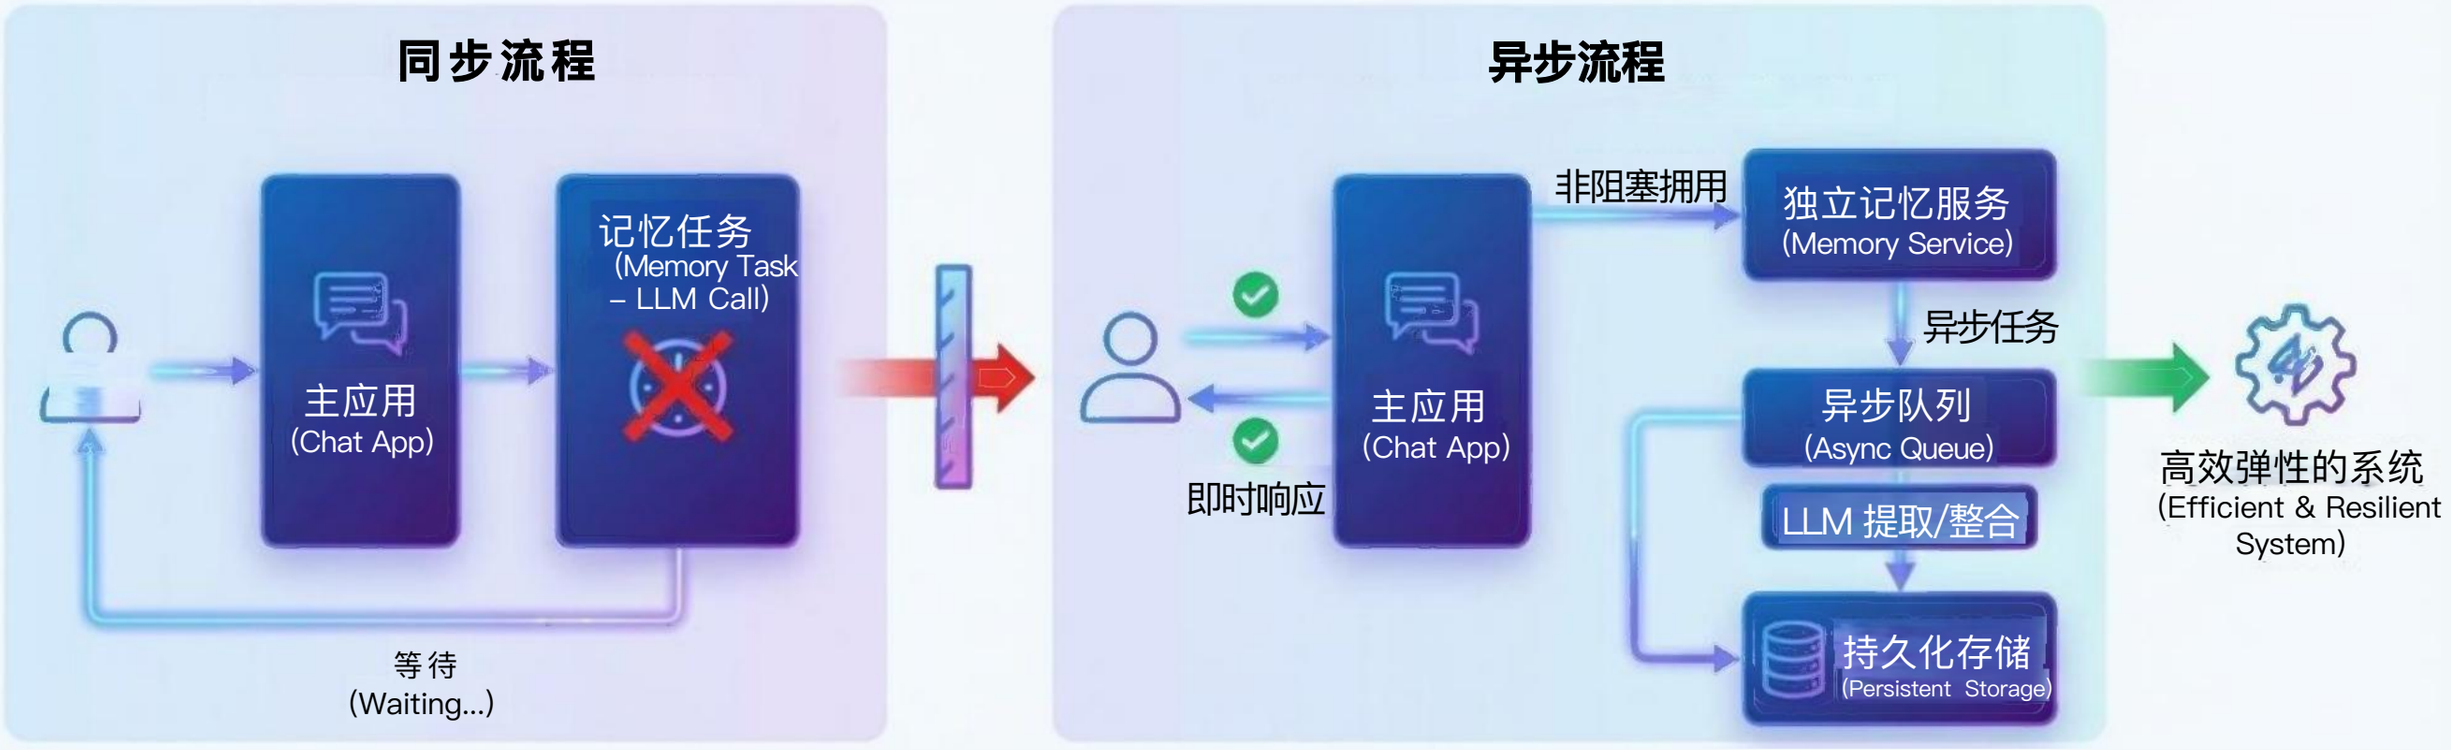

用户需等待记忆生成，影响体验。

降低延迟
(Lower Latency)

隔离故障
(Fault Isolation)

灵活处理
(Flexible Processing–
Real–time/Batch)

在生产环境实现高效、安全、可扩展的上下文与记忆管理(2/3)

并发与一致性：让记忆系统支撑大规模使用

1. 队列削峰(Queue-based Load Leveling)

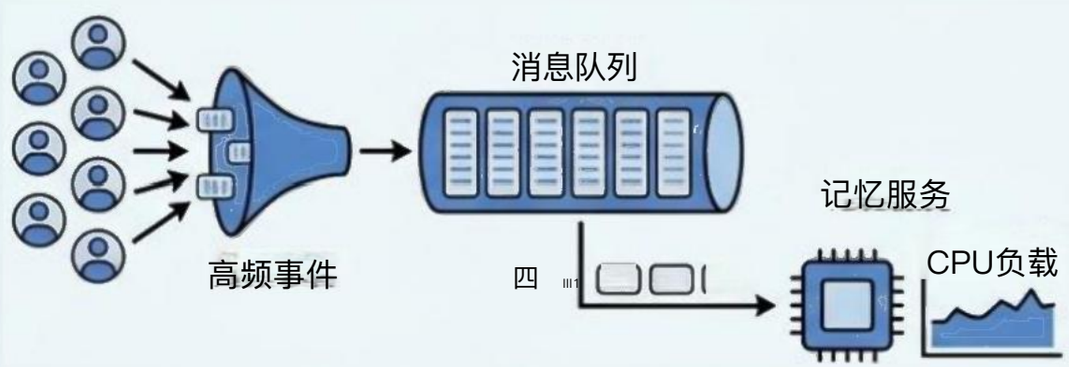

暂存洪峰，匀速处理，防止服务崩溃。

2. 并发冲突控制(Concurrency Conflict Control)

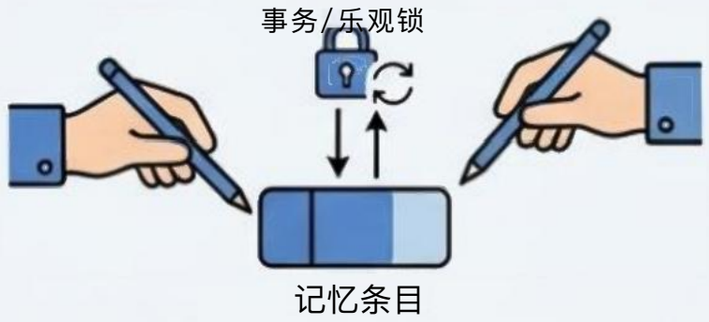

确保同一时间单一写入，权衡延迟与频率。

3. 失败重试机制(Failure Retry Mechanism)

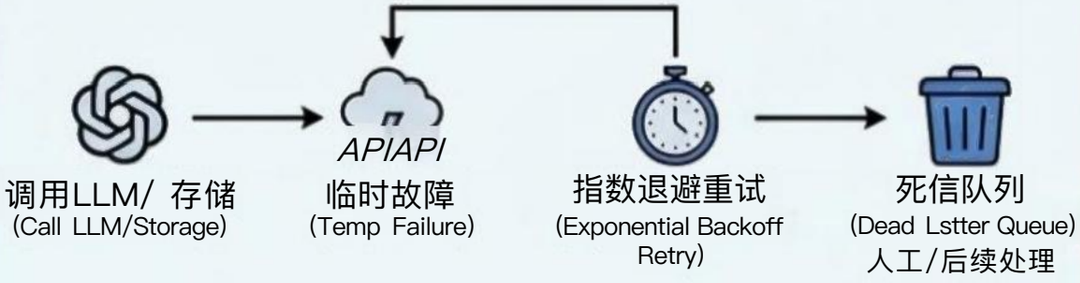

自动重试短暂故障，避免数据丢失。

4. 多地域部署与数据同步(Multi-Region Deployment & Sync)

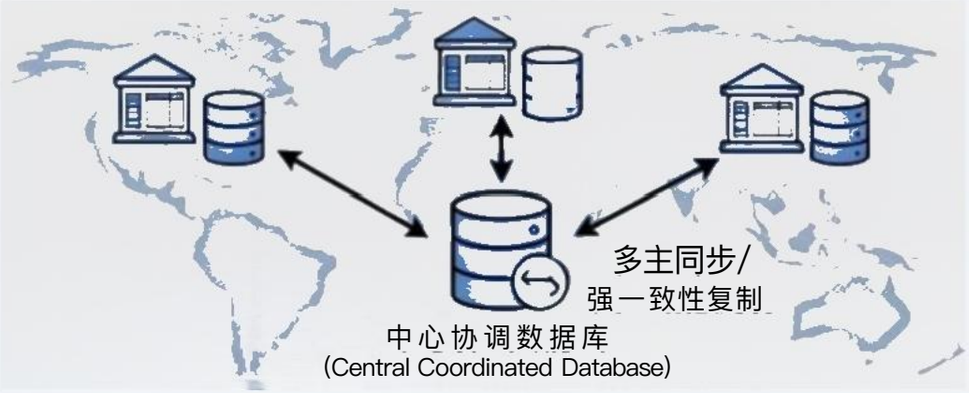

全球数据一致，中心协调跨地域读写。

通过这些架构设计，记忆系统能在高并发下保持数据一致性、弹性和全球同步，支撑大规模业务。

在生产环境实现高效、安全、可扩展的上下文与记忆管理(3/3)

数据隔离与安全：保护用户隐私和防御恶意

1.严格的数据隔离 (Strict Data Isolation)

基于用户/租户的访问控制，确保记忆完全隔离；共享记忆彻底匿名化。

2.用户数据控制 (User Data Control)

尊重用户选择权：允许关闭记忆功能或请求删除所有数据。

3.写入前校验 (Pre-write Validation)

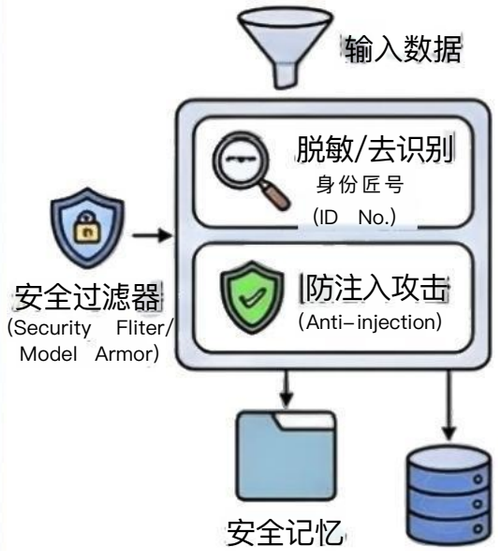

敏感信息去识别，防范提示注入攻击，审查有害内容。

4.防泄露 (Prevent Exfiltration)

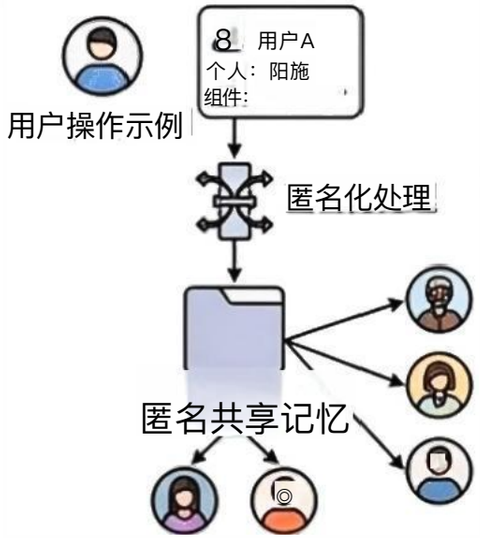

共享记忆去身份化，防止通过共享通道泄漏个人信息。

通过这些措施架设信息防火墙：记忆库数据各归各位，进出严格检查，确保隐私安全无隐患。

未来已来：构建
有记忆、有温度的AI 伙伴

超越模型堆砌，
转向精巧系统设计

会话+记忆=
持续成长与个性化

从“聪明”到“智慧”，
打造长期数字伴侣

让我们携手应用这套蓝图，创造下一个惊叹体验!