阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

基于 EMR Skills 实现智驾场景的自动化数据标注

董亚军 | EMR 产品专家 | 计算平台事业部

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

目录

content

01 EMR AI Native 全景图

02 EMR Skills 能力

03 EMR Spark Skills 能力
基于 Agent + EMR Spark 实现智驾场景下的数据标注

04 EMR AI Native 展望

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

01 / EMR AI NATIVE 全景图

如何构建一个面向 Agent 协作的数据平台

过去十年，大数据平台的核心目标是：把数据"存下来、算出来、用起来"。

但今天，我们面对的不再只是 BI 与报表，而是越来越多的**智能体（Agent）**——

它们自动读取数据、调用算力、生成结果，甚至驱动业务决策。

> **所以，如何构建一个面向"智能体协作"的大数据平台？**

Agent 时代，对大数据平台提出了新的要求

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

从"支持人分析"，走向"支持 Agent 自主调用"

新要求

更低门槛的调用方式
从 SQL / 作业配置，走向 API / 能力调用

更统一的能力抽象
数据处理、查询分析、系统运维，需要统一对外

更实时的响应能力
支持 Agent 的即时决策与交互

能力 Skill 化

数据处理 Skill
全托管 Spark 能力，Agent 可直接调用数据处理

查询分析 Skill
StarRocks 实时分析能力，Agent 即时获取结果

系统运维 Skill
集群管理与自动化运维能力，Agent 自主调度资源

EMR：面向 Agent 的数据与计算能力平台

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

EMR 不再只是一个"集群产品"，它对外提供的是三类核心能力：

统一接口层

EMR 平台

数据 + 计算 + 运维

数据处理 Skill

全托管 Spark 能力，Agent 可直接提交数据处理任务，无需关心集群配置

实时分析 Skill

StarRocks 查询能力，Agent 可即时获取分析结果，支撑实时决策

系统运维 Skill

集群管理与自动化运维能力，Agent 可自主完成资源调度与故障恢复

接下来将从三个方面展开：

1. Agent 时代大数据平台需要具备哪些**关键能力**
2. EMR 如何把这些能力**"Skill 化"**，对外提供统一接口
3. 这种模式在真实业务场景中能带来什么**变化**

EMR AI Native 产品功能大图

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

SQL 层原生大模型调用 · 百炼 MaaS 深度集成 · 全栈 Serverless 免运维

应用场景层

智能数据分析
- 自然语言查数据
- SQL 自动优化
- 查询结果可视化

智能数据开发
- SQL Copilot 辅助
- 作业性能调优
- SQL 方言转换
- 代码生成

智能运维管理
- 集群健康巡检
- 异常诊断
- 根因分析
- 成本优化建议
- 预测式扩缩容

多模态数据处理
- 文档 / 图像智能处理
- 企业知识库 RAG
- 多模检索
- 音视频内容理解

AI 能力层

EMR AI 助手
- 实例管理
- 任务诊断优化
- 健康巡检
- 产品咨询
- 成本优化

智能开发助手
- 错误根因分析
- SQL 智能生成
- 代码生成
- SQL 方言迁移
- 执行计划诊断

AI Function 体系
- 情感分析
- 文本翻译
- 实体识别
- 图像分析
- 文档理解
- 音频处理
- 时序预测
- 内容安全

Agent Skills
- 集群/实例管理
- 作业管理
- 弹性管理
- 资源管理
- 运维管理
- SQL 执行
- 元数据查询
- 智能诊断
- 参数优化
- MCP Server 协议

多模态处理引擎
- Embedding
- 批量模型推理
- 非结构化数据加工
- 全文检索 Beta
- 向量检索 Beta
- 混合检索 Beta

AI 基础设施

模型服务
- 百炼 Qwen 系列
- 自定义模型接入

Token 管控
- 用量仪表盘
- 按量计费

安全合规
- 模型内容安全
- 审计日志

推理优化
- 批量推理
- 异步调用

计算引擎层

EMR on ECS / ACK
- 集群化部署
- 大规模批处理
- 弹性伸缩
- 多引擎支持

Serverless StarRocks
- 实时 AI 查询
- 毫秒级 OLAP
- AI Function 推理
- 向量检索 Beta
- 全文检索 Beta
- 混合检索 Beta

Serverless Spark
- 批量 AI 数据加工
- Ray 分布式计算
- AI Function 推理
- Daft 多模态处理
- GPU/GPU 资源支持

数据底座层

统一存储
- OSS
- NAS
- CPFS

统一 Catalog
- DLF（Data Lake Formation）

湖格式
- Paimon
- Iceberg
- Fluss

自下而上构建：底层能力支撑上层产品，最终服务于四大应用场景

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

02 / EMR SKILLS 能力介绍

EMR Skill 能力全景图

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

三大子产品通过 MCP Skill 接入 AI 助手，覆盖集群管理、计算作业、分析数据库全链路运维

EMR on ECS 集群管理

alibabacloud-emr-cluster-manage

Skill 定位

管理 EMR 集群全生命周期：创建、扩缩容、续费、状态查询

1. **集群生命周期管理**
   5 种集群类型、HA/普通部署、存算分离/一体架构、状态查询、克隆、删除
2. **节点组管理与扩缩容**
   5 种节点角色（MASTER/CORE/TASK 等）、新建节点组、手动扩缩容
3. **弹性伸缩**
   定时策略与指标策略（CPU/内存/YARN 负载触发）、伸缩活动历史查询
4. **运维与诊断**
   集群与节点巡检、续费管理、属性修改、创建失败诊断

用法

- “帮我建个 Hadoop 集群，要高可用的
- “我要搞个数据湖，存算分离那种
- “集群资源不够，加几台机器
- “CPU 超 80% 就自动加机器
- “集群快到期了，帮我续个费
- “集群创建失败了，帮我查原因

EMR Serverless Spark

alibabacloud-emr-spark-manage

Skill 定位

管理 Spark 工作空间全生命周期：创建工作空间、提交作业、Kyuubi 交互式查询、资源扩缩容

1. **工作空间管理**
   创建、查询、删除工作空间，查询可用引擎版本
2. **作业提交与监控**
   提交 Spark 作业（JAR/PySpark/SQL）、查询状态与日志、取消作业
3. **Kyuubi 交互式查询**
   创建/启停 SQL 网关、JDBC 连接、Token 管理、取消查询
4. **资源队列扩缩容**
   资源队列 CU 扩缩容、查询队列状态，按需弹性调整计算资源
5. **会话集群管理**
   创建/启停/删除会话集群，支持长时间运行的交互式会话环境

用法

- “帮我建个 Spark 工作空间
- “跑个 PySpark 任务，数据在 OSS 上
- “用 Kyuubi 跑条 SQL 看看结果
- “作业跑得怎么样了，看看日志
- “资源队列不够用了，扩点 CU
- “帮我起个会话集群做交互式开发

EMR Serverless StarRocks

alibabacloud-emr-starrocks-manage

Skill 定位

管理 StarRocks 实例全生命周期：创建、扩缩容、配置、维护、诊断和释放

1. **实例生命周期管理**
   创建（存算一体/分离）、查询状态、释放、恢复暂停
2. **弹性扩缩容**
   节点/磁盘扩缩容、计算组节点增减，均支持预检
3. **配置与版本管理**
   配置修改（预检+回滚）、版本升级、SSL、付费转换
4. **基础运维**
   重启实例/计算组/节点、操作历史查询
5. **网络管理**
   网关增删改查、隔离、公网 SLB 开关

用法

- “帮我建个 StarRocks，存算分离的
- “查询有点慢了，扩几个节点
- “改一下配置，先帮我预检
- “重启一下实例，刚改了参数
- “最近查询老报错，帮我诊断下
- “版本落后了，帮我升级一下

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

03 / EMR SPARK SKILLS 能力介绍

Demo: 基于 Dataworks Data Agent + EMR Serverless Spark 实现智驾场景下的数据标注

EMR Serverless Spark Skills 能力介绍

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

Spark AI Agent 覆盖工作空间、作业、查询、资源四大核心场景

工作空间管理

核心工具
CreateWorkspace 创建工作空间
GetWorkspace 查询工作空间

管理范围
工作空间全生命周期管理

适用场景
自动化环境开通
多租户工作空间管理

Spark 作业管理

核心工具
StartJobRun 提交作业
GetJobRun 查询状态
CancelJobRun 取消作业

管理范围
作业提交、监控、日志查看

适用场景
自动化数据 Pipeline
ETL 调度与异常处理

Kyuubi 交互查询

核心工具
Kyuubi Gateway SQL 查询
ListKyuubiSparkApplications
查看查询结果与日志

管理范围
交互式 SQL/JDBC 查询

适用场景
自然语言查询数据
BI 报表自动生成

资源队列管理

核心工具
CreateQueue 创建队列
ScaleQueue 弹性扩缩容
ListQueues 查询队列列表

管理范围
计算资源配额管理

适用场景
按需调整队列并发上限
多业务资源隔离与分配

核心优势

Agent 原生集成
一键添加 Skill
开箱即用，无需额外开发

核心场景 覆盖
覆盖工作空间、作业、查询、
资源四大管理场景

安全合规
基于 RAM 权限体系
细粒度访问控制

Serverless 免运维
无需管理基础设施
按需弹性扩缩容

生产级稳定性
企业级可靠性保障
完善的容错与重试机制

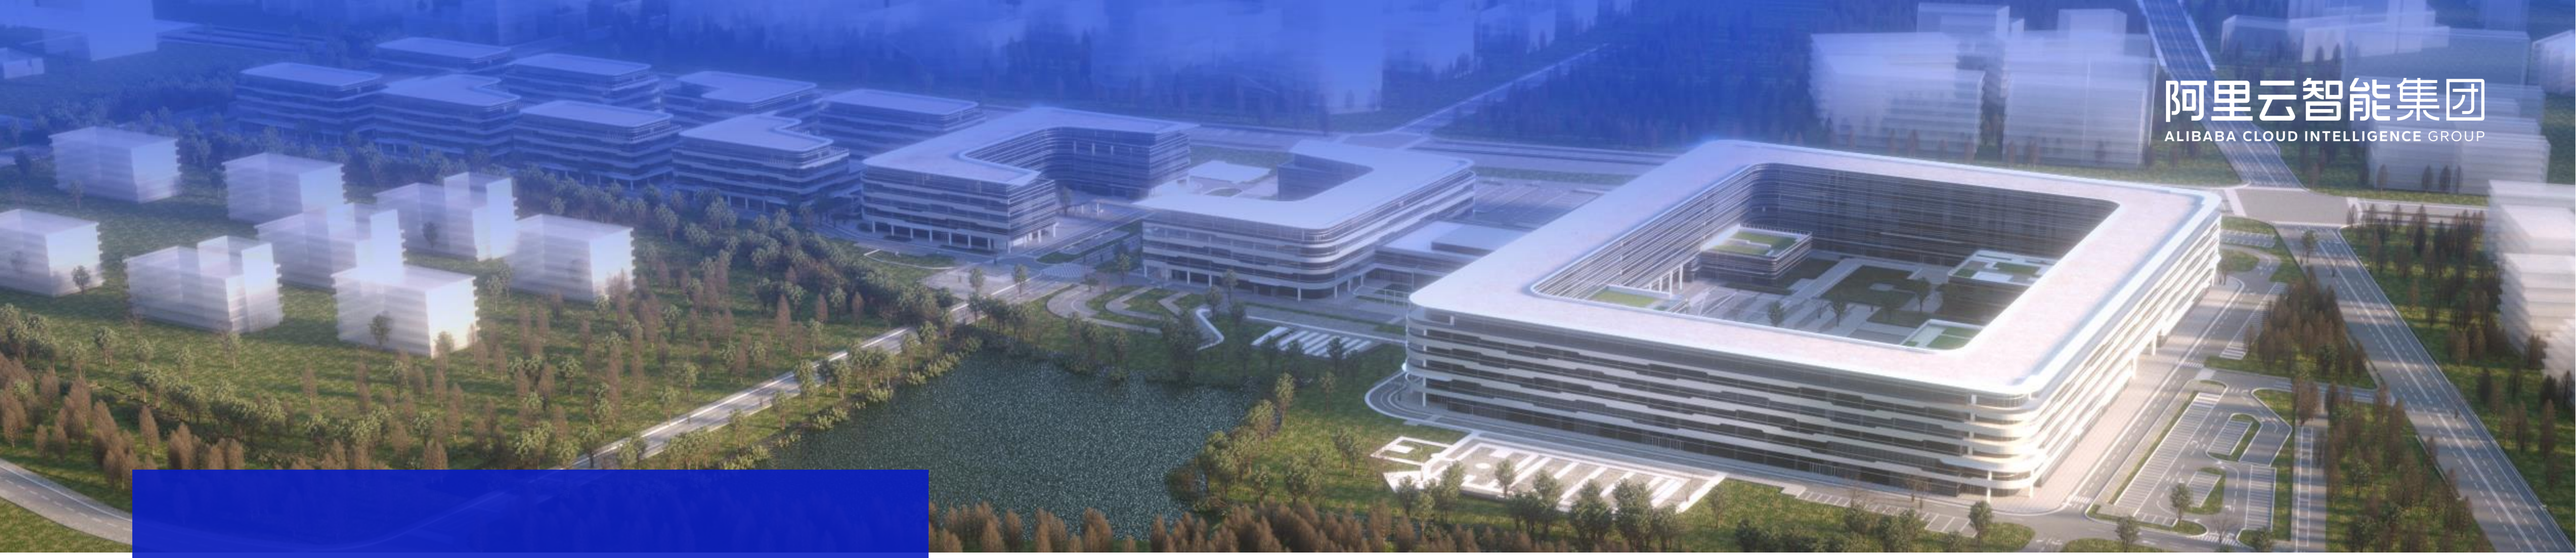

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

多模态图片理解

利用Serverless Spark 集成的 ai_query 函数，直接调用通义千问（Qwen-VL）多模态大模型能力。整个流程被简化为标准的 ETL 流水线：读取 OSS 文件 -> SQL 定义 Prompt -> 调用 AI 函数 -> 输出结构化结果。 整个过程由 Data Agent 触 发。

基于 Agent 配合 EMR Spark Skills 完成图片打标

Agent 驱动的视觉理解应用架构（Agent +Spark +AI）

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

基于 Dataworks Data Agent 和 Spark Skills 完成图片打标

应用架构：

[1] 控制与编排层
DW DataAgent

Skills Library
- Spark Skills
- Kyuubi Skills
- ...

Action
1. 理解用户意图
2. 生成SQL 代码
3. 提交任务

[2] 计算引擎
Spark

接收 Agent 提交的 SQL

1. 解析 Prompt
- 环岛/警车/皮卡/吊车
2. 调用 read_files 读取数据源图片
3 . 执行 ai_auery()
- 调用 qwen3.6-plus

[3] 数据源 DLF&OSS

OSS Bucket

```
camera_front/
├─ img_01.jpg
├─ img_02.jpg
└─ ...
```

[4]模型服务层

Qwen3.6-plus

输入：
- 图片 Binary
- 提示词

输出：
- [“警车”，“吊车”]

核心流程：

意图识别：用户告诉 Agent “帮我找出所有包含警车和吊车的图片”

→

SQL 生成：Agent 调用 “Spark SQL Skills”，自动编写包含详细视觉特征 Prompt 的 SQL

→

弹性执行：Agent 将 SQL 提交给 EMR Serverless Spark，集群秒级启动并处理 OSS 数据

→

智能推理：Spark 内部通过 ai_query 调用大模型，完成图像理解

→

闭环反馈：结果返回给 Agent，Agent 可据此进行二次分析或触发业务动作

Demo: 基于 Agent 配合 EMR Spark Skills 完成图片打标

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

04 / EMR AI NATIVE 展望

EMR AI Native 能力展望

- EMR Skills支持Spark 诊断与优化
- Serverless Spark Daft 集群GA
- Serverless StarRocks 基于Lakehouse向量检索GA

- Daft集群支持Auto Scaling，GPU调度和推理优化
- Ray集群支持Auto Scaling，GPU调度和推理优化
- Serverless StarRocks 基于Lakehouse全文检索GA
- 智能助手支持成本与资源优化

- 智能AI助手 接入飞书等通信
- EMR Skills支持参数优化、索引/分区优化
- Serverless StarRocks 基于Lakehouse全文检索GA
- Spark 多模态算子市场 GA

阿里云智能集团
ALIBABA CLOUD INTELLIGENCE GROUP

THANKS