

下一代ODPS: 全模态引擎和Agentic全面升级

演讲嘉宾：赵弘扬

ODPS 跟随时代进程的成长路径



大数据技术【探索期】

互联网时代到来，以分布式调度、存储为核心的基础设施建设时期，打破数据库以低成本大规模扩张问题。分布式计算模型为MapReduce

大数据技术【发展期】

开始关注开发效率，分布式计算模型针对场景细分，总体向SQL靠拢


大数据技术【普惠期】

开始关注投入企业生产必须的能力：工作流、安全、治理、规模、稳定性等，出现数据中台概念

大数据技术【变革期】

开始关注Bigdata+AI的异构计算能力，以及对多模态海量数据的高效处理能力


阿里云大数据里程碑




ODPS 曾获得的重大成就



IDC: 中国公有云大数据平台市场占有率第一（**2023年**）
连续四年排名第一




IDC: 中国数据治理市场占有率第一（**2023年**）
连续三年排名第一



影响力(亚洲)领先

- 2024年：信通院数据智能平台专项测试认证
- 2022年：阿里云自主研发的大数据智能计算平台 **ODPS** 入选世界互联网领先科技成果
- 2021年：Forrester CDW 2021 Wave, MC+DW 全球卓越表现者象限，**亚洲唯一入选云厂商**
- 2021年：Gartner DSML（数据客户与机器学习），第一年入榜，**国内唯一**
- 2020年：Gartner 云数据库/数据分析**国内唯一进入 Leader 象限**的云厂商



国家奖项

- 2017年：中国电子学会科技进步特等奖（被业界誉为“科技界金棕榈”）
- 2018年：浙江省科技进步一等奖
- 2018年：国家大数据博览会十佳产品：最佳案例实践奖
- 2018年：中国数字化转型与创新案例大会：年度大数据创新产品奖。
- 2019年：大数据“星河（Galaxy）”奖 最佳大数据产品奖（TOP10）

01

DATA AI 能力全面升级

阿里云**MAXCOMPUTE**（原名**ODPS**）

MaxCompute Data + AI 能力全面升级



AI Function推理 将复杂的AI推理场景“降维”成一行简单代码、SQL和MaxFrame双引擎开发生态支持，能力丰富、对接简单，构建面向智能体时代的统一开发与运行范式，释放数据价值。

异构资源灵活调度
支持多种不同类型计算资源（如 CPU、GPU、PPU等），支持多种不同类型计费方式（按数据扫描量、CU、GU、Token等）；根据作业任务和资源特性，智能地将任务分配到最合适的资源上执行，以实现性能最优、成本最低或效率最高的目标。



多种模型覆盖全场景
MC支持统一模型对象管理并提供开箱即用的公共模型，可直接对接百炼各类商业化大模型，同时通过无缝集成数据处理与AI能力，完成从数据准备、数据处理、到模型推理的完整流程，降低企业级大模型应用门槛。

全模态存储 以多模态数据为核心，深度对接DLP，支持原生多模态数据存储格式、统一数据访问接口，实现元数据统一管理，同时面向数据处理/推理场景深度优化。

模型层：MaxCompute 多种模型类型统一管理、使用简单



丰富的模型类型

公共模型

内置开箱即用的**百炼商业化模型**及**QWEN 3**、**DEEPSEEK**系列开源大模型，预先创建在**BIGDATA PUBLIC MODELSET**公共项目

导入模型

支持用户导入在外部训练调优后保存的自定义模型文件，指定**OSS**模型文件地址，并注册至**MAXCOMPUTE**

远端模型

支持对接**PAI EAS**上已经部署好的模型，指定对应访问**ENDPOINT**和**TOKEN**，注册成为**MAXCOMPUTE**远端模型

用户训练模型

支持用户进行传统机器学习模型训练，执行**TO ODPS MODEL API**将其保存成为**MAXCOMPUTE**模型

完善的模型管理能力

同时提供模型和模型版本能力，方便用户进行模型的版本管理和灰度验证

- ✓ 支持完整的模型元信息与权限体系
- ✓ 同时基于 SQL & Python(MaxFrame) 支持模型的CRUD
- ✓ MaxCompute 控制台支持模型的白屏化查看

```
graph TD
    Project --> Schema
    Schema --> Model
    Model --> Model_version1
    Model --> Model_version2
```

统一的模型使用体验

支持 **SQL & MAXFRAME AI FUNCTION** 无缝调用

MaxFrame AI Function

```
# 创建ManagedTextLLM对象，指定使用公共模型qwen3-14b
llm = ManagedTextLLM(name="qwen3-14b")

# 定义Prompts模板，其中包含一个系统消息和一个用户消息
messages = [
    {"role": "system", "content": "You are a helpful assistant."},
    {"role": "user", "content": "请回答如下问题: {query}"}]

# 对LLM对象调用generate方法，传入DataFrame和Prompts模板，即可获得返回结果
result_df = llm.generate(df, prompt_template=messages)
```

SQL AI Function

```
1 SELECT AI_GENERATE (
2     bigdata_public_modelset.Qwen3-4B, v1, -- 指定公共模型名称
3     'what is the capital of China?' -- Prompt 内容
4 );
```

说明：百炼模型在**MC**中属于公共模型类型，**用户开箱即用**，不需要创建或购买百炼资源和配置**API KEY**，由**MC**提供全托管的模型能力。

算力层：异构计算覆盖多种资源类型、计费灵活



支持多种计费方式，用户可按需匹配成本与推理性能，获得业务最优解



CU QUOTA
(通用**CPU**资源)

资源优势：
海量资源，支撑超大规模（数十万核）
并发计算

适用模型：
小尺寸模型（ **8B**）

推荐模型：
QWEN 0.6B/4B,
DEEPSEEK R1 1.5B/7B

业务场景：
开发测试场景；
小规模数据量推理任务（性价比极高）



GU QUOTA
(**GPU**智算资源)

资源优势：
支持用户独享

适用模型：
大尺寸模型（ **8B**）

推荐模型：
QWEN3 14B,
DEEPSEEK R1 14B

业务场景：
对推理效率与吞吐有极高要求的大模型
作业（如海量语言翻译、结构化提取）



INFERENCE QUOTA
(按量付费**TOKEN**资源)

适用模型：
百炼商业化大模型

推荐模型：
QWEN3 MAX、QWEN3.6 PLUS
TEXT EMBEDDING V4


业务场景：
希望开箱即用、免底层资源运维；
需要顶级模型质量的复杂分析；
希望按使用量付费，无需花费较高成本
做资源预留（按模型实际**TOKEN**消耗
计费，灵活可控）

存储层：MaxCompute 多模态存储



Blob（Binary Large Object）数据类型是MaxCompute提供的一种用于在表中存储图片、音频、视频、文档等非结构化二进制大对象的数据类型。通过 Blob 类型，可以将多模态数据的原始文件、元信息和标注信息统一存储在同一张MaxCompute表中，使用 SQL 统一查询和维护，通过 MaxFrame 和 SQL UDF 批量加工处理。

MaxCompute Blob - 多模态数据统一存储架构



1

AI 训练数据集管理

将图片、音频、视频与标注标签存储在一张表中，通过 **SQL** 过滤所需样本数据集。

2

多模态数据处理流水线

视频切帧、音频转文本、内容打标等多步骤流水线的中间结果和最终产物统一存储。

3

多模态加工缓存层

作为对象存储等数据源的缓存层，提升 **MAXFRAME**、**SQL** 大规模并行计算的吞吐性能，解决小文件批量请求的 **QPS** 限制。

4

非结构化数据入湖

将分散在外部存储中的文件统一导入 **MAXCOMPUTE**，扩展元信息建立企业非结构化资产库，获得事务保障和统一权限控制。

AI Function: SQL 和 MaxFrame 双引擎统一对接, 开发友好



MC AI Function能帮助用户摒弃繁琐低效的数据搬运过程, 实现“数据即模型输入、结果即模型输出”, 构建Data+AI开发新范式

MC AI FUNCTION 能力列表

SQL AI FUNCTION

兼容SQL生态

- AI GENERATE
- AI CLASSIFY
- AI EXTRACT
- AI SIMILARITY
- AI SENTIMENT
- AI SUMMARIZE
- AI TRANSLATE
- AI EMBEDDING
- ML PREDICT

MAXFRAME AI FUNCTION PYTHON生态

兼容

- GENERATE接口
- TASK接口

选择 MaxCompute AI Function 的6大理由

- 极简低代码开发
一行SQL/Python函数即插即用, 零部署成本, 大幅缩短开发周期。
- 多引擎全面支持
SQL与Python (MaxFrame) 双管齐下, 兼容Pandas风格API。
- 企业级无缝集成
与MaxCompute的模型、计算资源、权限体系完美融合, 对接简单。
- 极致高性能扩展
支持分布式并发执行, 可支撑单次PB级数据处理规模, 线性扩展。
- 支持大规模生产
支持自动并发切分、worker内sleep机制、限流控制, 保障作业稳定性。
- 灵活多维计费
完美适配各种业务场景, 无缝对接MC CU/GU/Token多样化资源池。

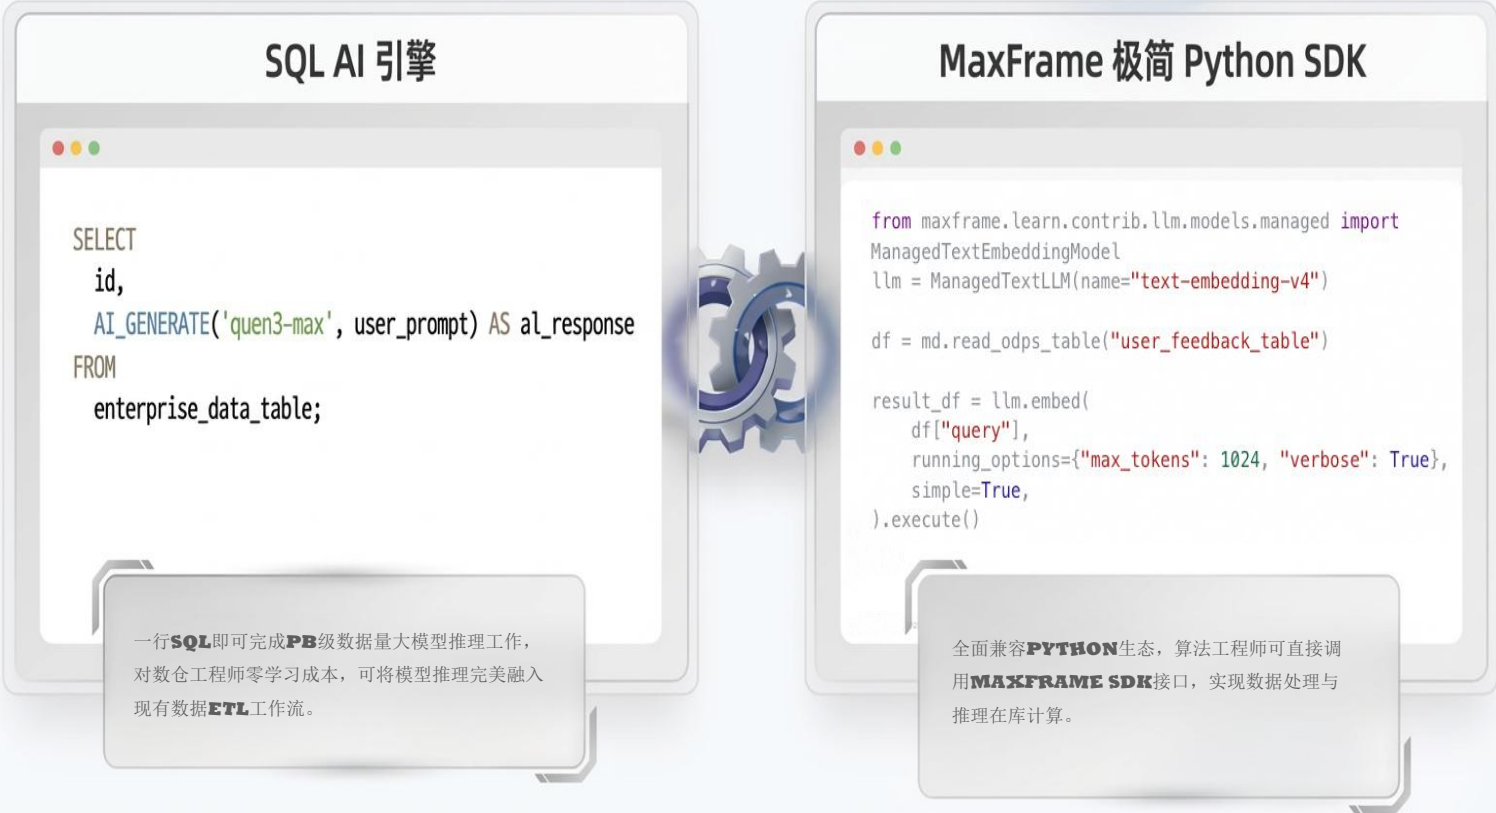
深度集成百炼，赋能大模型推理



模型支持：无缝对接百炼商业化大模型，并同时支持Qwen3、DeepSeek等开源模型，开箱即用

全模态支持：原生支持结构化数据与文本、图像、音视频等多模态数据联合分析与向量化

双引擎统一对接，打造极致开发体验



双引擎无缝适配：提供MaxCompute SQL AI函数与MaxFrame（Python）SDK，满足不同使用者的开发使用习惯

端到端数据闭环：在同一框架内完成数据清洗、预处理、模型推理、打标的完整数据开发链路，降低数据搬迁成本

精细计费与管控，成本可控



Quota资源管控：通过独立Quota方式进行模型推理资源管理，实现模型计算资源与CU等基础计算资源统一定义，即开即用

Token精细化计费：采用Token计费模式，按量计费，成本可控

02

全模态案例场景

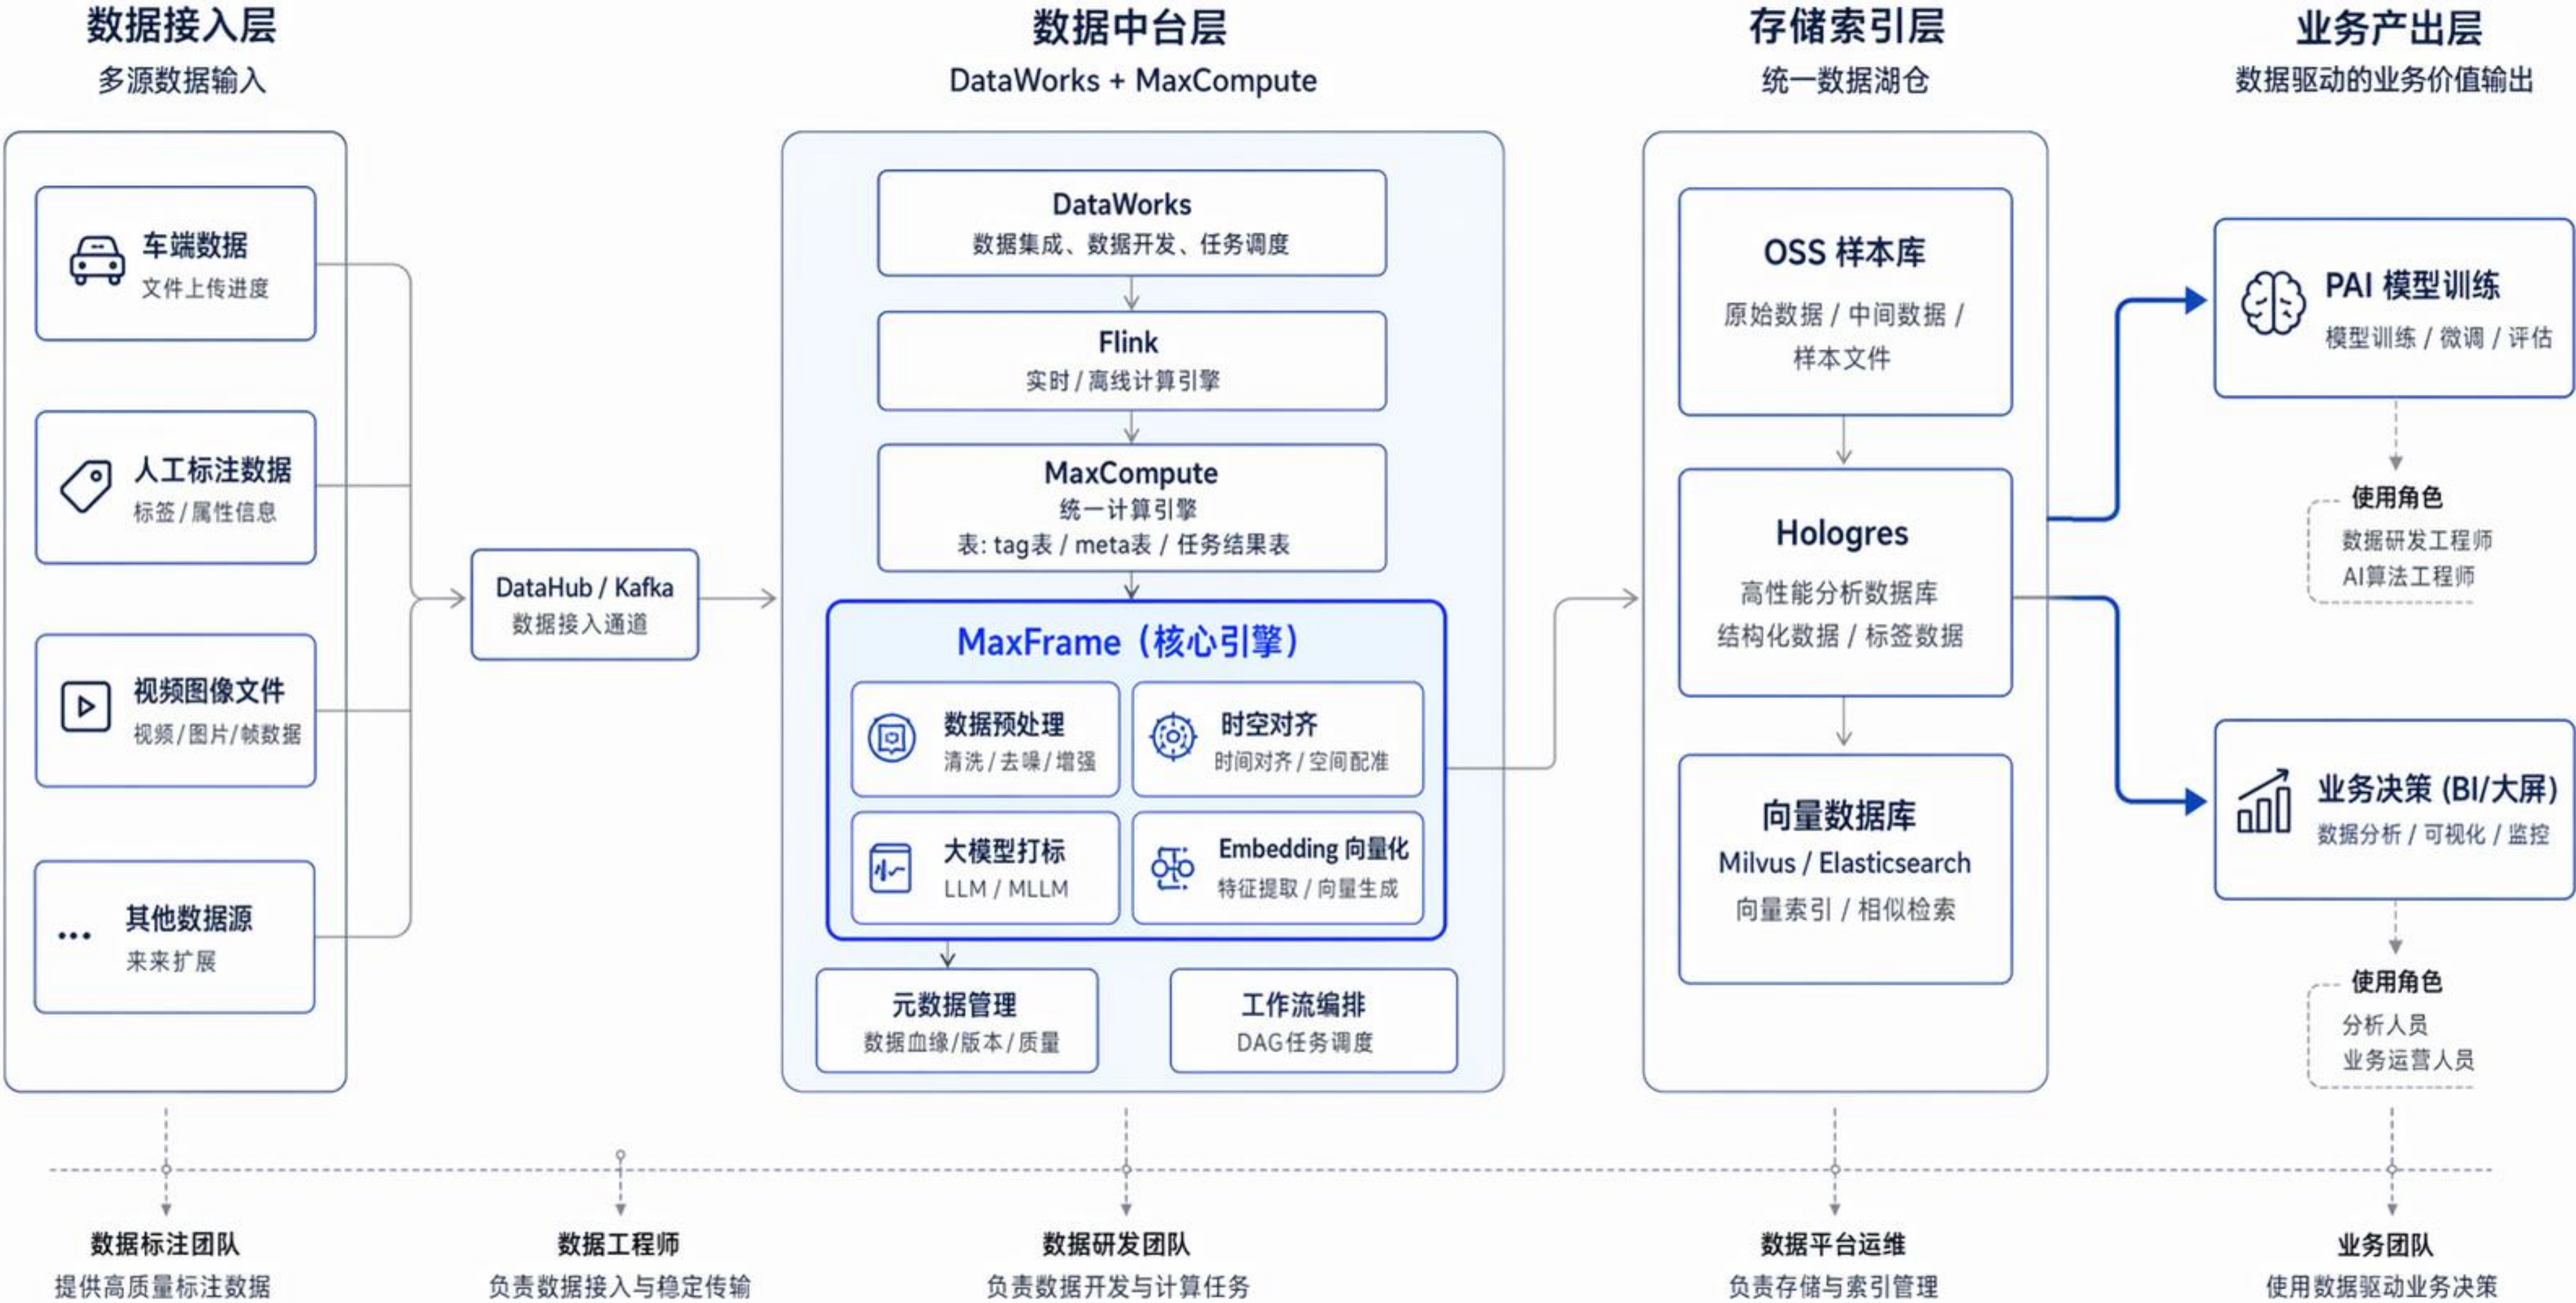
阿里云**MAXCOMPUTE**（原名**ODPS**）

MaxCompute 汽车行业方案：智驾数据处理产线



推出具身行业Skills：支持通过 AI Function + 百炼大模型 进行行业数据打标与向量化全流程，一句话即可生成完整作业

拿下阿里云门户 Skills **热门榜第1名**



MaxCompute 具身行业方案：具身智能 EgoCentric



MAXCOMPUTE CPU GPU 混合算力 可断
点续跑

EgoCentric Pipeline 端到端自动化：从原始视频到可训练数据集，全流程无需人工干预



工程化挑战 **MAXCOMPUTE** 解决方案


容错不中断	单片段失败只记录不阻塞
GPU 显存复用	HAWOR 各阶段顺序执行复用显存
OSS 挂载	避免多 FUSE 写入冲突
断点续跑	每阶段独立 MAXCOMPUTE 表，可从中间恢复

输出格式

LEROBOT V2.0 标准格式：
DATA/ PARQUET (STATE 8D ACTION 7D)
VIDEOS/ MP4 (原子动作视频切片)
META/ JSONL (语言指令)
HDF5
兼容 **PIO / GROOT / OPENVLA**



MaxCompute 分布式AI计算引擎 — 赋能超大规模自动化数据处理产线



03


EMPOWERING DIGITAL WORKERS

阿里云**MAXCOMPUTE**（原名**ODPS**）

Agentic 时代，MaxCompute为数字员工提供丰富的接入方式



MaxCompute 的专属 Agent 可以满足 AiQuery、AiOps 等应用场景，同时提供MCMCP 与 Skills 结合的方式，将底层元数据、计算和存储服务封装成 Agent 可理解、可执行的统一能力接入层，让企业级客户可以通过Agent完成超大规模数据分析、高性价比多模数据加工处理和智能化运维。



MaxAgent

最近1天作业的运行情况

2026年5月21日 14:13:13

正在为您分析，请稍候...

过去 24 小时（2026-05-20 14:12 至 2026-05-21 14:12）的作业运行情况如下：

健康概览

- 作业总数：20 个（终态）
- 失败率：15.0%（3 个失败） — 建议关注
- 当前运行中：0 个（系统处于空闲状态）
- 性能表现：P90 运行时长为 62.17s，呈下降趋势，整体执行效率良好。


Top 资源消耗作业 (CPU/Memory)

排名	实例 ID	CPU (core*s)	内存 (MB)	状态
1	2026052103152...	699.0	7163.0	已结束
2	2026052103144...	681.0	6981.0	已结束
3	2026052103133...	634.0	6494.0	已结束

分析结论与建议

- 失败率偏高：20 个作业中有 3 个失败，失败率达到 15%。建议您使用作业诊断工具（如之前对 202605201031118g8pwm2bm b5d 的诊断），排查这 3 个失败作业的具体原因。
- 资源消耗正常：整体 CPU 和内存消耗处于最低水平，未发现资源异常占用或长尾作业。
- 性能稳定：作业运行时长分布合理，且 P90/P99 指标呈优化趋势。

如果您需要查看那 3 个失败作业的详细诊断信息，请提供它们的实例 ID。



覆盖资源管理、成本治理、业务分析全链路。

免控制台登录、移动端操控闭环，打通钉钉、飞书、微信机器人通道，实现“聊天即服务”的交互。

01 数据开发日常运维

痛点

- 作业失败/慢，排查耗时长
- 查询性能瓶颈，不知如何优化
- 全表扫描浪费资源

MaxAgent能力

- 作业运维与智能诊断
- 物化视图推荐与收益评估
- Auto Cluster 聚簇优化



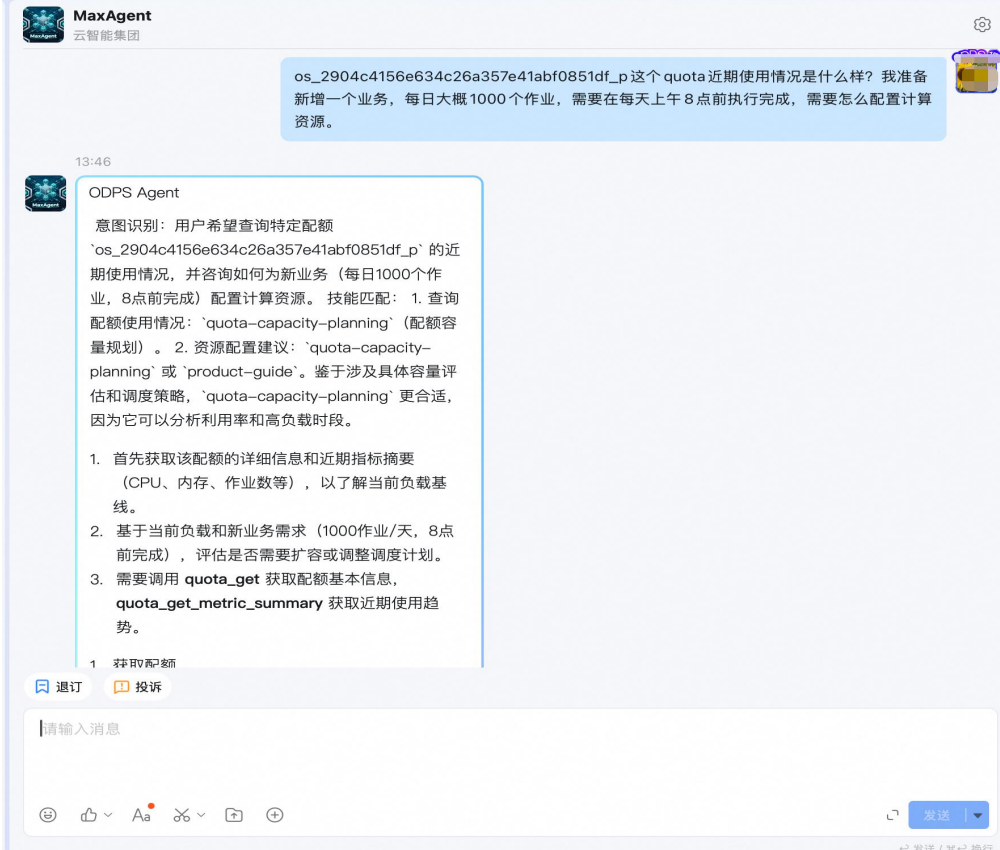
02 资源管理员移动运维

痛点

- 项目配置繁琐，参数易遗漏
- Quota 利用率不明，扩容凭感觉
- 外出告警无法及时处理

MaxAgent能力

- 项目配置与参数管理
- Quota/路由/计划/分时配置
- 机器人移动端闭环处置



03 降本增效

痛点

- 费用增长不知原因
- 存储大户不清，优化无方向
- 优化手段单一，收益不可量化

MaxAgent能力

- 成本智能分析与趋势
- 计量成本归因与Top消费者
- 存储观测与分层推荐



4 智能问数

痛点

- 不懂 SQL，依赖数据团队
- 无法定位和识别目标表和数据业务逻辑
- 日常报表手动制作

MaxAgent能力

- NL2SQL 自然语言查数据
- 上下文追问深度分析
- 跨域联动：查询+诊断



MaxCompute提供的Model Context Protocol（MCP）服务，用户可以使用丰富的Agent生态配置接入MCMCP，借助配套的Skills用户可通过自然语言对话方式管理和分析PB、EB级数据。

方法分组



生产就绪

安全、Agent友好

- 1. 丰富的认证方式，支持 AK/SK、STS、Credentials URI等无AK方式
- 2. 元数据搜索服务，帮用户自然语言找表
- 3. 执行SQL可以约束仅允许只读查询
- 4. 执行SQL前可以走成本评估审批
- 5. 建表时提供表属性选项（生命周期、主键、部分列更新等）

配套SKILLS

- Sql-Generation
- Maxframe-Coding
- Information-Schema
- Project-Qouta-Manage



工作现场已恢复

6 个 Tab · 2 个连接 · 1 个 AI 会话



数据连接 / Region

- 杭州project
cn-hangzhou · 18.2K tables
- 新加坡project
ap-southeast-1 · 并发提交

Catalog 多 Project 树

- ▼ 新加坡project
- ▼ 表 88
- dwd_order_di
order_id BIGINT
region STRING
amount DOUBLE
- ads_roi_summary
- dim_customer

► 视图 12

Meta: 28.4 TB · read/write · 365 分区

SQL 脚本管理

- ▼ SQL
- meta
- ▼ analysis
sales_pivot.sql
quality_check.sql
- ▼ ads
roi_daily.sql
storag_dashboard.sql

存储用量统计.sql

Binary 预览

导入任务

example.sql



SQL Editor

选中执行

单句执行

全文顺序执行

补全 · SET FLAG 提示 · 格式化 · 搜索替换

快捷键 ⌘↵

```
1  -- 一键恢复现场后继续分析
2  set odps.sql.type.system.odps2= true ;
3  with daily_sales as (
4  select region, category,
5  sum(amount) sales
6  count(*) orders
7  from dwd_order
8  group by region
9  ) select * from
```

智能补全 · 基于元数据

- dwd_order_di
- dwd_order_hi
- dim_customer
- ⊗ odps.sql.allow.fullscan

minimap



表格

可视化

透视

质量

JSON

Logview

200 行 · 10.3s · AI 分析

导出

执行进度

100%

扫描数据

2.86 MB

输出记录

5.82 B

多格式导出

CSV · JSON · Parquet

region	category	sales	profit
杭州	电子产品	4,050	1,030
新加坡	家居用品	2,860	520
法兰克福	户外用品	1,730	-48
香港	数码配件	1,280	301
... 还有 196 行			

可视化 · 透视 · 质量

自动匹配列 · XYZ 轴 · 多选堆叠

10+ 图表



空值 0.8% · 极值通过 · Pivot region × category

Logview DAG Summary

Map(M1)

Map(M2)

Reduce(R3)

CPU 338 core-s · 耗时 10.3s · 入 381.8K / 出 3.4K

M MaxMan AI · Data Agent



Agent

多会话

模型服务配置

查询结果 AI 洞察

趋势: 电子产品销售最高, 户外用品利润异常
建议: 按 region × category 透视并追加环比 SQL

生成 SQL

环比分析

SQL 优化建议

1. 分区过滤前置, 扫描 4.5GB → 320MB
2. 聚合字段显式命名, 便于图表识别
3. DESC / SHOW 等 MC 命令结果统一呈现

一键插入原文件

本地文件快速转 Table

Excel

CSV

Parquet

JSON Lines

AI 推断 DDL → 一键建表 → 任务进度追踪

sales_2026Q1.xlsx · 2.3MB · 18,452 行

龙虾实操 ODPS

"找出利润异常 Region 并给出下一步 SQL"

分析中 · 64%

✓ list_tables · ✓ desc_table · 🛠️ run_sql

向 MaxMan AI 询问问题...

发送 ▶

模型: Qwen3-Max · DeepSeek · Claude · 切换 ▾

THANKS

演讲嘉宾：赵弘扬
