

Hologres：一站式 Agentic 多模态检索分析平台

演讲嘉宾：骆擷冬

目录

CONTENT

- 01 Hologres: AI数据底座
- 02 AI Function
- 03 AI 助手
- 04 长记忆服务

01

Hologres: AI 数据底座

全模态实时数仓引擎 + Agent/模型基建，不再是单点“能查向量”

01

第一层 · 全模态实时数仓引擎



全模态数据

结构化 / 半结构化 Variant / 非结构化 Blob



全场景检索

OLAP · KV · 向量 · 全文 · 图 · 空间地理



仓内湖上一体化

同一引擎完成从接入到多模态分析

02

第二层 · Agent 与模型基建



长记忆服务

Agent Memory 持久化 · 精准召回 · 跨会话连续



可观测数据底座

大模型交互日志 实时写入 / 查询 / 分析

03

交付层 · 面向行业场景

AI Function

百炼全托管

混合检索



电商 · 零售 · 金融 行业实时数据服务

02

AI Function

Hologres AI Function 整体功能架构



AGENTIC AI
超级智能体系系统架构峰会

大数据+AI Function: all-in-one, 实现“一份数据、一份计算、多模分析”



一份多模态数据存储

多模态数据一键入仓，索引构建

一键多模式数据计算

一条SQL完成全增量近实时自动加工

一键部署百炼模型

AK一键部署百炼模型，开箱即用

一站式AI数据分析

向量、全文、OLAP、点查、AI推理

AI Function, 简化非结构化数据分析



AGENTIC AI
超级智能体系架构峰会

AI Function: 内置AI函数, 通过标准 SQL 直接调用大模型, 实现非结构化数据向量化、多模推理、智能内容生成等AI应用场景, 兼容 PostgreSQL 生态。

基于阿里云**海量算力池**, 提供丰富的AI Function, 自动调用大模型, SQL化处理结构化和非结构化数据, 简化AI开发, 统一数仓和AI服务。

内容生成与转换

ai_parse_document

文本识别
pdf/word/图片等多模态
数据识别, 转换成文本

文本理解与分析

ai_fix_grammar

语法纠错
用于修复输入文本的语法
错误

向量化与文本切片

ai_gen

智能内容生成
通过提示词调用LLM生成文
案、图片、视频

数据安全

ai_summarize

智能文本摘要
生成一段文本的摘要

ai_translate

多语言智能翻译
将输入文本翻译成一种用
户指定的语言

ai_extract

信息结构化提取
从输入文本中提取用户指
定的标签信息

ai_similarity

语义相似度计算
计算两个输入文本的相似
度

ai_analyze_sentiment

情感倾向分析
对输入进行情感分析

ai_classify

文本分类
根据分类标签对输入进行
智能分类

ai_rank

智能打分
对输入进行相关性打分

ai_transcribe

语音转文本

ai_embed

embedding
对输入进行量化, 产生向
量

ai_chunk

长文本分段
将从文本切成固定大小的分
段

ai_mask

敏感信息脱敏
对输入文本中的敏感信息
进行智能脱敏

Hologres AI Function一键调用百炼模型



AGENTIC AI
超级智能系统架构峰会

购买Hologres模型资源，然后在控制台一键部署模型，通过AI Function（标准SQL）调用，助力业务多模数据处理、智能内容生成、AI推理、向量+全文混合检索等多个AI应用场景

Step1:购买Hologres模型资源

Hologres模型资源

购买说明 开通后，您可以使用Hologres的AI Function，通过标准SQL调用大模型搭建AI服务，包括推理、Embedding、多模态打标...

计费规则 按模型实际使用量进行计费，详情见计费

商品类型

独享实例（包年包月） 独享实例（按量付费） 共享集群（湖仓加速版） 计算抵扣包

存储抵扣包 AI资源（包年包月） AI资源（按量付费） Hologres AI助手

地域

华东1（杭州） 华东2（上海） 华北2（北京） 华南1（深圳）

新加坡

资源类型

托管模型资源

开通后，您即可在所选地域使用Hologres的AI Function，通过标准SQL的方式调用托管模型该服务按量付费、按小时出版。

Step2:一键部署模型

部署模型

模型提供方 Hologres托管模型
由Hologres托管的百炼模型服务，无需提供API KEY，按量付费，支持使用AI Function调用模型。

模型类别 ① qwen3-vi-plus X text-embedding-v4 X qwen-image-2.0-pro X

模型参数配置

模型类别 qwen3-vi-plus
模型名称 qwen3-vi-plus 任务类型 文本生成
模型参数 展开配置 模型重试机制 展开配置

模型类别 text-embedding-v4
模型名称 text-embedding-v4 任务类型 向量嵌入
模型参数 展开配置 模型重试机制 展开配置

模型类别 qwen-image-2.0-pro

取消 确认

Step3:SQL调用AI Function消耗token

运行 执行计划 运行分析 停止 格式化 帮助 文档

```
1 -- Query查询结果默认限制200行，如需更多数据请修改limit，最多展示10000行或20M。
2 CREATE TABLE questions (
3   question TEXT
4 );
5
6 INSERT INTO questions (question) VALUES
7   ('什么是人工智能? '),
8   ('如何提高英语口语水平? '),
9   ('健康饮食有哪些注意事项? ');
10
11 SELECT
12   question,
13   ai_gen('请用 20 个字回答如下问题: ' || question) AS answer
14 FROM
15   questions;
```

适用场景

- 智能搜索与推荐：商品语义检索、相似商品推荐
- 实时风控与异常检测：违规内容识别、IOT设备故障报警
- 智能内容生成：营销文案生成、广告视频素材是创作、语音合成
- 语音处理与交互：语音转写、会议纪要生成等

方案优势


- 零代码集成：仅需 SQL 即可调用 AI 函数，分析师无需学习 Python
- 实时高性能：内核级函数调用，百亿级向量亚秒级响应
- 数据零搬迁：直接在大数据系统中完成全流程，数据不出库，安全可管控
- 灵活和低成本：内置多种百炼模型一键部署，按Token调用按需使用，低成本

预估日均Token

- 轻量场景（文本分类/摘要）：10 万~50 万 Token
- 中等场景（语义检索/实时风控）：50 万~200 万 Token
- 重度场景（大规模向量化/复杂生成）：200 万~1000 万 Token

典型应用场景1：多模数据加工与混合检索

打通非结构化与结构化数据的增量处理、向量检索和 OLAP 分析，实现多模态数据的一体化实时加工与混合检索，显著提升数据处理效率和查询分析能力。



Hologres方案

感知湖上多模数据变化，自动增量加工

- Object Table感知OSS上非结构化数据变化
- Dynamic Table增量对新增数据调用AI Function进行加工和embedding，可以结合结构化数据一起加工，同时存储加工结果
- 应用高性能查询Holo表，使用向量+全文+OLAP混合检索分析多模数据

客户画像

- 数仓存储结构化数据，有非结构化数据与结构化数据混合检索与分析的诉求
- 非结构化数据量大，有加工、处理需求，希望一个系统、SQL完成**实时多模数据**加工与分析，检索和分析都具备高效率
- 典型行业：车联网、智能驾驶、电商、新媒体等

>>最佳实践: AI Function搭建自动驾驶图像高性能分析系统

Q 请输入内容

☆

概览

用量查询

文件管理

文件列表

数据索引

ECS 挂载 OSS

权限控制

数据安全

数据管理

跨区域复制

同区域复制

定时备份

生命周期

Bucket 清单

静态页面

镜像回源

归档直读

禁止文件覆盖写

内容检测

文件列表

对象 (Object) 是OSS存储数据的基本单元, 也被称为OSS的文件。和传统的文件系统不同, Object没有文件目录层级结构的关系。

上传文件

新建目录

碎片管理

授权

前缀匹配

请输入文件名前缀匹配, 仅针对当前目录。

Q

更多筛选

	文件名	文件大小	存储类型
	bdd100k/ images/		
	 b1c66a42-6f7d68ca.jpg	51.972KB	标准存储
	 b1c81faa-3df17267.jpg	29.513KB	标准存储
	 b1c81faa-c80764-5f1c.jpg	33.783KB	标准存储
	 b1c9c847-3bda4659.jpg	70.777KB	标准存储
	 b1ca2e5d-84cf9134.jpg	58.297KB	标准存储
	 b1ca8418-84a133a0.jpg	31.472KB	标准存储
	 b1cac6a7-04e33135.jpg	90.059KB	标准存储
	 b1cd1e94-26dd524f.jpg	32.38KB	标准存储
	 b1cd1e94-549d0bfe.jpg	62.458KB	标准存储

第1步: 准备图片素材上传至OSS


客户案例：某SaaS系统相似票据推荐

客户介绍

某SaaS公司是一家全球领先的企业管理云SaaS公司，旗下拥有多个SaaS系统，为企业提供精细化的ERP等系统服务，是国内的TOP 软件服务公司，并连续多年获得IDC和Gartner等国际机构认可。

方案流程

其商业化的ERP系统有多种搜索推荐的场景，例如计算客户的相似流水单据自动生成发票推荐，合同模板推荐等场景，票据、合同等都是非结构化数据，需要对多种类型的非结构化数据处理，然后向量检索和全文检索双路召回排序，返回最精准的一个结果，通过推荐系统的搭建，来减少客户的重复流程性工作，提升工作效率。



性能结果

混合检索查询性能：

- 单并发：平均Latency **72.8ms**。满足需求，相比其他检索系统提升40%
- 40并发：14万条评测集总处理时长1080.43秒，平均Latency **7.6ms**。

混合检索查询准确率：84.46%。

业务价值

- 毫秒级检索效率：**相比系原统，不管单/多并发性能超出客户目标，检索性能更快，**毫秒级响应**，满足客户需求
- 统一数据存储：****无需将数据导出至其他检索系统**，统一数据存储，减少数据同步的开发和运维，统一数仓团队和算法团队的开发体验
- 成本更低：**显著降低计算资源和数据同步资源
- 使用门槛更低：**纯SQL开发AI服务，成熟的监控运维体系，像使用大数据一样使用AI

客户案例：某零售客户多模数据检索

客户介绍


某零售公司是国内大型连锁便利店企业。客户希望对货架、商品、顾客、门店等数据进行多模检索与分析，方便业务更加精细化的运营和发展

方案流程

其中一个场景是货物摆放智能识别。每个门店需要按照规定的货架模版落地，需要借助多模态的能力，将门店货架照片与货架模版进行匹配，以此来发现是否有错放、缺货等现象，实现智能的精细化运营。

业务价值

- 差异校验准确率90%以上，完全满足客户需求
- 通过**纯SQL**，一个平台完成结构化数据、非结构化数据的混合检索与分析，降低开发门槛、减少运维难度
- 系统架构升级，从数据平台升级为多模数仓，更好支撑业务快速发展



典型应用场景2：智能营销内容生成

通过 Hologres 打通素材、生成与投放分析全链路，实现营销内容的智能化批量生产与效果闭环优化，大幅提升创作效率、内容一致性和投放转化率。



Hologres方案

调用大模型，结合原始素材，生成智能营销内容（视频/图片）

- Object Table读取原始非结构化物料
- 物料表与object table结合生成新的物料素材（图片）
- 使用大模型根据新的物料素材生成分镜脚本
- 调用wan模型，生成视频，选择合适的视频素材进行投放。投放数据使用Hologres分析

客户画像

- 日常需大量生产营销文案/素材的场景，产能瓶颈明显，人工创作效率低，风格不统一，**希望提高创作效率**，自动化流水线
- 多渠道内容分发缺乏一致性管理，生产与效果分析希望能更低成本的架构统一，**提高投放效率**
- 典型行业：游戏、电商、互联网、广告


客户案例：某游戏客户广告视频生成

客户介绍

某国内TOP游戏公司自主开发了游戏广告投放平台，以智能化和数据驱动为核心，依托自研技术实现全渠道、自动化游戏买量与精细化用户运营。

方案流程

Hologres使用object table获取原始物料素材，使用ai_gen调用大模型生成新的物料，然后再调用大模型生成分镜脚本，并调用wam模型生成广告视频，人工核对后进行广告投放



客户痛点

该客户的游戏广告投放数据都使用Hologres统一分析，但是广告内容生成是另外的系统，存在如下痛点：

- **投放与素材脱节**：广告素材、脚本版本和投放效果数据之间缺少统一沉淀，难以形成优化闭环。
- **系统多运维复杂**：多个系统导致后端团队分别许愿同步数据、运维管理，架构复杂且冗余
- **创意生产效率低**：每做一条广告，都需要从头构思主题、筛选素材、撰写脚本并进行视频制作，周期较长。

业务价值

- **全 SQL 链路**：数据工程师仅通过熟悉的 SQL 在 Hologres 中完成 AI 模型调用、素材整合、智能营销内容生成，降低了上手门槛
- **统一管理游戏素材**：由Hologres表结构统一管理游戏的多种素材，可以有效与广告投放数据混合分析
- **端到端自动化**：覆盖从角色变体、分镜脚本到视频合成的全流程，实现秒级/分钟级产出。
- **高效扩展性**：支持多场景的广告营销内容批量生成，大幅提升内容生产效率和投放效率。

典型应用场景3：多语言语音智能处理

面向客服、游戏、智能驾驶、医疗、SaaS 和跨境业务等高语音密度行业，帮助企业将非结构化语音快速转化为结构化、可查询、可分析的数据资产。



Hologres方案

- Object Table读取原始语音素材
- 调用百炼大模型对语音文件处理，包括说话人识别、语言识别、ASR转写等能力统一存储在Hologres的语音表中
- 应用层直接读取语音表内容，对语音做情感分析、工单生成等。

客户画像

- 有大量电话/会议/远程支持等语音数据，希望将语音内容转化为可分析的数据资产
- 强调更加快速、准确、批量处理语音文件，降低人工成本，实时性强，帮助企业从“听录音”升级到“看数据、做决策、闭环管理”
- 典型客户：**高频语音交互的企业客户，重点如客服中心、呼叫中心、电商物流、SAAS、游戏、智能驾驶等客户

03

AI 助手

数仓客户常见使用困境

“开发靠折腾，运维靠经验，分析靠手工，决策靠猜测”



POC新客：上手门槛高

不熟悉SQL，不熟悉功能，上手门槛高，找不到最佳实践



数仓开发：需求开发低效

复杂场景反复调试SQL，缺乏调优智能解读，优化耗时费力
业务临时提需求，资源瓶颈面临技术架构优化，需求堆积不敏捷



数仓运维：被动式救火运维

系统黑盒强，巡检能力弱，故障感知不及时，根因定位需要跨系统拼凑信息



数据分析师：查数门槛高


无法自助分析，不熟悉SQL，依赖数仓团队，业务周期长，可视化门槛高
只能看下过去发生了什么，缺乏对未来的预测，业务低效

Hologres AI 助手：数仓从入门到精通



AGENTIC AI
超级智能系统架构峰会

- 围绕Hologres实例，AI助手基于资深数仓专家沉淀的多个Skills，提供多agent协同支撑数仓全生命周期问题，包含知识问答、实例诊断、SQL调优等丰富的数仓场景，助力数仓从入门到精通，0代码，0门槛，开箱即用。



多场景Agent覆盖

开发、运维、诊断、数据分析多场景多Agent覆盖，一站解决Hologres全生命周期问题

零代码开箱即用

自然语言对话，无需懂SQL，无需写代码

内置专业Skills

多名资深数仓专家沉淀多个最专业skills，助力数仓从入门到精通

知识问答 (QA AGENT)

- 售前技术方案咨询
- 产品规格推荐
- 功能使用答疑

数仓开发 (DEVELOP/OPTIMIZE AGENT)

- 数仓搭建教程
- SQL调优建议
- 功能开发最佳实践

数仓运维 (OPS AGENT)

- 实例资源诊断
- 慢/错SQL诊断
- 成本治理

数据分析 (DATA ANALYZE AGENT)

- 自然语言访问数据
- 报表可视化生成
- 数据解读与趋势预测

Hologres AI 助手使用和能力介绍

DataFun.

AGENTIC AI
超级智能体系架构峰会

Step1:官网开通AI助手

>>>官网开通

使用说明 AI助手基于大模型和Hologres智能 Agent 系统, 提供对 Hologres实例的问答支持、自动化运维、性能优化指导、开发辅助...

商品类型

独享实例 (包年包月) 独享实例 (按量付费) 共享集群 (湖仓加速版) 计算抵扣包

存储抵扣包 AI资源 (包年包月) AI资源 (按量付费) Hologres AI助手

地域

中国 亚太

华东1 (杭州) 华东2 (上海) 华北2 (北京) 华北3 (张家口)

华北6 (乌兰察布) 华南1 (深圳) 西南1 (成都) 中国香港

购买时长

1个月 2个月 3个月 6个月

1年 2年 3年

优惠券 暂无可用优惠券。查看更多优惠券

应付费 ¥0.00 立即购买

Step2:在控制台和Holoweb使用AI助手

>>>Hologres控制台

实时数仓Hologres

【重要通知】Hologres AI助手将于2026年7月1日起结束免费公测, 转为正式商用并

实例列表

AI助手

Hologres AI助手

AI助手ID hologram_agent_public_cn-4b84ti1ce06

剩余天数 24天 续费

地域 华东1 (杭州)

结束时间 2026年7月11日 00:00:00

关联实例

实例ID	实例名称
hgpostcn-cn-3g84tlc09004	hm-5.0测试实例-new
hgpostcn-cn-www3bmc7a00a	技术支持3.1测试
hgprecn-cn-jaj3bkhg2008	1234

用量消耗

汇总 明细

Hello, I'm Hologres AI助手

提供一站式智能服务, 解决Hologres使用、运维等问题

产品使用咨询 Hologres使用、原理与最佳实践问答

CPU使用率诊断 排查 CPU 高负载、异常峰值与瓶颈查询

内存使用率诊断 分析内存占用、OOM 风险与常驻内存对象

慢SQL分析 慢 SQL 分析、执行计划解读与优化建议

运维报告 为关联实例生成运维诊断报告

请输入问题, 浏览历史

强制沙箱 Auto YOLO 深度思考

产品使用咨询

基于Hologres知识库, 提供产品功能知识问答

CPU/内存诊断

基于hologres实例, 快速诊断CPU、内存水位情况, 以及异常的原因以及给出解决方案,

慢SQL诊断

基于hologres实例, 提供全实例的慢SQL、错SQL的诊断以及单SQL的诊断与调优

运维报告

基于hologres实例, 提供实例级别的全方位诊断报告, 涵盖资源、成本、SQL、表等多个维度

>>AI助手使用手册

Hologres AI助手

使用说明

AI助手基于大模型和Hologres智能 Agent 系统，提供对 Hologres实例的问答支持、自动化运维、性能优化指导、开发...

商品类型

独享实例（包年包月）

独享实例（按量付费）

共享集群（湖仓加速版）

计算抵扣包

存储抵扣包

AI资源（包年包月）

AI资源（按量付费）

Hologres AI助手

新

开通AI助手

地域

中国

亚太

华东1（杭州）

华东2（上海）

华北2（北京）

华北3（张家口）

华北6（乌兰察布）

华南1（深圳）

西南1（成都）

中国香港

购买时长

1个月

2个月

3个月

6个月

应付费

¥0.00

查看明细


立即购买

04

长记忆服务

Hologres 长记忆服务典型场景


01



AI CODING 助手

跨会话持续积累项目上下文记忆，Agent 越用越懂你的代码库，让开发效率成倍提升


02



电商购物 AGENT

深度记住用户偏好与消费禁忌，实现因果级个性化推荐，让每次购物都更懂你所需


03



AI 伴学

持续追踪知识断点与遗忘曲线，精准诊断薄弱环节并动态调整学习路径，让提分更有针对性

04



金融理财顾问

基于持仓历史与重大生活事件变化，给出个性化风控与资产配置建议，守护每一笔财富

Hologres 长记忆服务：Agent 记忆一站式解决方案



依托Hologres强大的多模态检索能力与Mem0框架的优秀生态，实现高性能、高性价比、易用的Agent长记忆方案

开箱即用 快速集成

开源框架（Mem0）
100%兼容
API快速接入
Agent应用无缝迁移

全托管服务 成本更优

服务全托管，无需串
联多组件，免运维
支持记忆精炼，大模
型Token消耗显著降
低

一站式解决方案

向量+全文+图+标量
融合检索
一站式服务，系统架
构简洁

高可扩展性

云原生分布式架构
业务灵活扩展，可支
持百亿级记忆数据

高性能

高性能记忆实时写入
记忆写入即可查
毫秒级向量/全文/图
检索，性能、准确率
领先



记忆无遗忘




AGENT共享



免运维


Hologres 长记忆服务 AI 助学场景 Demo



Hologres 长记忆服务 AI 助学场景 Demo



AGENTIC AI
超级智能系统架构峰会



THANKS

