

看见、记住、行动：多模态 Agent 的记忆工程实践

——从手机伴随助手到端侧具身智能体

演讲嘉宾：OPPO AI中心 刘鹏

目录

CONTENT

- 01 AI助手的下一个胜负手
- 02 小布伴随的流式记忆
- 03 X-OmniClaw 的端侧记忆
- 04 展望：下一站，Agent OS

01

AI助手的下一个胜负手

手机AI助手的多元需求

今天天气怎么样？

总结一下我刚刚刷到的几个攻略




这道题怎么做？

打开这个 **APP** 的订票页面

今天的手机助手，不只要答得上，还要看得懂、记得住、做得到

手机AI助手的演进



应用形态变化的背后，是模型、记忆与 Agent 能力的共同演进

02

边看边答：小布伴随的流式记忆

什么是小布伴随？



小布伴随不是一次性识屏问答，而是持续在线的手机使用陪伴

小布伴随的设计理念

常规Agent

- ◆ 多轮思考
- ◆ 多次工具调用
- ◆ 循环试错
- ◆ 适合后台任务

手机伴随 **AGENT**

- ◆ 首包优先
- ◆ 单次编排
- ◆ 模块轻量
- ◆ 可降级兜底




快而可控

- ◆ 减少**AGENT LOOP**
- ◆ 路由前置，并行执行
- ◆ 轻量模块 规则约束
- ◆ 候选链路、兜底

小布伴随既要持续长久的陪伴，也要快速稳定的响应

整体框架

Accompany Agent System Architecture · 小布伴随系统架构



伴随助手的流式记忆 (1/6)

屏幕帧流



ASR 时间窗口



瞬间重建模块




输出

提问瞬间上下文

屏幕内容 + query 文本 → 送入编排中枢


重建提问瞬间

伴随助手的流式记忆（2/6）



屏幕语义时间轴

伴随助手的流式记忆 (3/6)



流式时间轴下的记忆分层于应答全覆盖

伴随助手的流式记忆（4/6）

实验一：VIDEO CAPTION 去噪实验

CAPTION 生成时显式区分：

- ◆ 重点信息：页面主体、用户关注对象、任务状态
- ◆ 非重点信息：导航栏、底部按钮、重复控件、无关 UI

根据场景来选择是否使用非重点信息，在全场景上应答满意度有**1.7**个点的提升。

画面展示由“旅行算法师”发布的“江西5天4夜爆肝攻略 景美·吃爽·不踩坑！”旅游攻略内容，包括“江西旅游住宿指南”、“江西旅游美食推荐”、“江西精华景点介绍”三个板块，分别列出南昌、庐山、景德镇、三清山、婺源、井冈山等地的住宿选择、特色炒菜与小吃、推荐菜馆及景点介绍，例如“南昌：景点市区扎堆！住八一广场、滕王阁或万寿宫附近最方便”、“特色炒菜：蟹粉豆腐、藜蒿炒腊肉、黄豆炒鸡丝”，以及“景点：滕王阁、八一起义纪念馆、庐山、景德镇、三清山、婺源、井冈山”等具体信息，页面还显示 448 点赞、21 收藏、16 评论等互动数据。



【主要信息】画面显示江西旅游攻略内容，其中包括“江西旅游住宿指南”、“江西旅游美食推荐”、“江西精华景点介绍”三个板块，分别列出南昌、庐山、景德镇、三清山、婺源、井冈山等地的住宿选择、特色炒菜与小吃、推荐菜馆及景点介绍，如“南昌：景点市区扎堆！住八一广场、滕王阁或万寿宫附近最方便”、“特色炒菜：蟹粉豆腐、藜蒿炒腊肉、黄豆炒鸡丝”、“景点：滕王阁、八一起义纪念馆、庐山、景德镇、三清山、婺源、井冈山”等具体信息。


【次要信息】该内容由“旅行算法师”发布，页面背景显示“江西5天4夜爆肝攻略 景美·吃爽·不踩坑！”标题，以及“448”点赞、“21”收藏、“16”评论等互动数据。

伴随助手的流式记忆 (5/6)


实验二：持续MEMORY总结

时序问答数据集构造：

- ◆ 实时问答：依赖短时视频信息面
- ◆ 记忆问答：依赖历史局部记忆
- ◆ 回溯问答：需要对过去的总结回溯信息
- ◆ 图文无关问答：问题与画面弱相关
- ◆ 完全无关问答：不依赖屏幕内容



伴随助手的流式记忆（6/6）



无需训练，低成本，可插拔的层级记忆检索框架 **OASIS**:

将不断增长的视频历史 **fold** 成层级化事件记忆，而不是把所有帧或片段平铺保存。它先把短时间内的连续观察聚合为局部事件，再将相关事件进一步压缩成更高层的语义摘要，形成从细粒度片段到粗粒度事件的层级结构。

在推理时，模型先根据问题判断需要哪类证据，再沿着这棵层级记忆从粗到细定位相关时间区域。这样既保留了长视频中的关键信息，又避免了把大量无关历史都塞进上下文。OASIS 因此把 记住更多 转化为 按需展开正确的记忆 。

Model	frames	Perception							Backward			
		OCR	ACR	ATR	STU	FPD	OJR	Avg	EPM	ASI	HLD	Avg
Qwen2.5-VL-7B [‡]	0.5fps	76.51	57.80	68.10	46.63	66.34	56.52	60.93	49.83	58.11	44.62	50.24
+ OASIS	-	85.23	72.48	66.38	52.25	67.33	64.67	67.26	51.85	58.78	48.92	52.61
Qwen3-VL-8B [‡]	0.5fps	83.89	58.72	70.69	56.18	69.31	64.13	66.79	51.18	60.81	43.55	51.19
+ OASIS	-	91.95	80.73	81.03	67.42	67.33	79.89	78.14	61.95	60.14	47.31	57.21

记忆如何被消费？（1/4）

长短时记忆的选取和插入方式，在不同链路和场景条件的约束下有较大差异。

核心影响要素是：

- ◆ 短时记忆选帧策略
- ◆ 长时历史记忆策略
- ◆ **PROMPT**要素设计

对应几个核心理念：

- ◆ 时序信息有选择的保留
- ◆ 多源上下文按需注入
- ◆ 退出、兜底机制
- ◆ 特殊场景特殊设计

SYSTEM PROMPT设计

- 1. 身份认知层
 - ├ 1. 核心身份设定：角色定义，性格基调，品牌归属
 - └ 2. 场景变体身份：标准助手模式，特殊场景模式
- 2. 场景指引层
 - ├ 1. 实体具体化要求：按场景标签动态注入细化规则
 - └ 2. 上游信息采纳规则：结合来源回答，冲突时忽略
- 3. 画面理解层
 - ├ 1. 用户问题
 - └ 2. 多帧画面理解：时间顺序排列，串联完整使用场景
- 4. 历史记忆层
 - ├ 1. 多源上下文注入：RAG，历史视频记忆，记忆仓，用户画像，工具结果
 - └ 2. 采纳原则：注意代词指代，与画面冲突时无视
- 5. 行为约束层
 - ├ 1. 表达风格：语气基调约束，禁用表达范围限定
 - ├ 2. 模态来源隐藏：屏蔽内部信息结构，统一对外表述口径
 - └ 3. 隐私安全：敏感信息统一拒绝
- 6. 判断规范层
 - ├ 1. 禁止模糊/消极/自我质疑表述
 - └ 2. 动态限制追加：根据上下文类型按需注入额外约束
- 7. 输出控制层
 - ├ 1. 字数五档自适应：确认 10-20字 → 攻略 150-300字
 - ├ 2. 内容策略：拓展场景 vs 精简场景
 - └ 3. 质量标准：信息密度高，数据具体，贴合画面

记忆如何被消费？（2/4）

视频场景

- ◆ 短时记忆：与**QUERY**类型强相关，需要判断是否依赖画面，通常需要全量的短时记忆
- ◆ 长时记忆：问题事件通常长上下文关联性强，检索记忆片段和使用全局总结记忆至关重要
- ◆ **PROMPT**设计：场景描述和记忆描述需要完备

例如：

Q：主角被袭击好像在故事前期就有伏笔？

结合长期细节记忆提供关键信心


Q：主角这段时间一共经历了多少挫折？

需要长期细节记忆和总结记忆的共同引导


记忆如何被消费？（3/4）

教育场景

- ◆ 短时记忆：越接近**QUERY**时间的帧越重要，个别问题不需要视频帧
- ◆ 长时记忆：通常是副作用
- ◆ **PROMPT**设计：限制越少越好



模型**PROMPT**长度 满意度



模型输出长度 满意度

记忆如何被消费？（4/4）

伴随留痕：基于视觉感知、对话交互与闪记增强的留痕系统

记忆留痕的主要元素：

- ◆ 视觉感知：屏幕内的重要信息
- ◆ 对话交互：提炼用户交互上下文
- ◆ 闪记增强：用户主动要求重点记下的内容

最终形成可追问，可回溯的记忆，保存在小布记忆里。

黄金高价原因解析

小布陪伴了你1分57秒，我们聊到了黄金昂贵的原因，黄金的形成过程，黄金的特点，关键信息总结如下

■ 屏幕内容核心要点

- **黄金形成过程**：黄金形成于超新星爆炸，通过核聚变使氢元素转变为大质量元素，或地球形成时冲击波使原子核捕获中子生成；地球黄金含量约60万吨，但多数位于地核无法开采。
- △ **黄金稀缺性**：全球可开采黄金储量约26万吨，已开采20万吨，剩余储量仅够维持开采16年，可开采量有限导致稀缺。
- ★ **黄金物理特性**：具有高光泽度（优于银铁），质地柔软便于加工成货币，可长期保存不变质且抗腐蚀性强。

○ 关键对话


- ❓ **黄金形成方式**：你提问“它是怎样形成的？”，小布回答黄金在超新星爆炸核聚变中形成，或地球形成时冲击波使原子核捕获中子生成以捕获火因量的面金属。
- 🌱 **黄金是否可再生**：你追问“这里提到的金源于两生资源吗？”，小布明确黄金不源于两生资源，因形成需几十亿年，已开采20万吨且剩余储量仅够开采16年。
- 🔍 **黄金核心特点**：你追问“这个金属有什么特点？”，小布总结为形成过程特殊，光泽度高，质地柔软且加工，可长期保存不变质，稀缺性强。

🔴 你的关注重点

你围绕“黄金为何昂贵”这一核心问题展开提问，首先聚焦其宇宙级形成超新，将超新星爆炸与地球形成中的核反应过程标记为理解稀缺性的关键逻辑；接着通过追问“可开采量”与“再生属性”，锁定26万吨全球储量与16年剩余开采期这两个关键数据，构建起“储量丰富但获取难度”的认知框架；最后，你系统梳理黄金的五大物理特性，尤其关注光泽度、加工性与稳定性如何强化其作为硬通货的价值属性，形成“天文级形成难度+地球级开采限制+货币级物理优势”的三维认知闭环。


小布和你一起拆解了黄金高价的科学密码，从宇宙星辰到地球财富再到金属特性，层层深入揭开了这个贵金属的价值面纱。如果还想知道其他贵金属的类似分析，随时告诉小布哦~

场景拓展-旅游出行场景



伴随范式 垂域子链路：增强垂域问答执行能力

场景拓展-直播辅助场景




伴随范式 任务前处理：助力直播带货文案生成 在线问答

03

X-OmniClaw 的端侧记忆

X-OmniClaw整体架构



三大要点

Omni Perception

屏幕 + 相机 + 语音统一进入

Omni Memory

工作记忆 + 本地长期记忆

Omni Action

观察 → 推理 → 执行 → 验证

真实 Android 设备运行

X OMNICLAW 是一个集多模态感知、记忆与执行于一体的 多模态安卓端**AGENT**。


X 强调跨模态融合，将多源感知信号组织为统一的任务输入，并进一步驱动真实移动端环境中的跨应用执行；

OMNI 表示系统整合三类感知来源：屏幕内的 **UI** 状态、屏幕外的真实世界视觉上下文，以及语音输入。

Omni Memory: 全时空个性化记忆



Omni Memory






工作记忆保证任务不断线，长期记忆让 **AGENT** 更懂用户
安全控制决定这些记忆能不能真正落地到个人设备场景

用户路径记忆 – 轨迹克隆

X-OmniClaw的两种执行方式


- ◆ Agent Loop: 完成开放性任务，可能有较高的时延和成本
- ◆ 轨迹克隆: 对用户的轨迹做事件级记忆，快速完成用户需要长期记住的行为




其他Demo展示

DataFun.

AGENTIC AI
超级智能体系架构峰会



相机识物→电商询价



屏幕跟随→多步读屏问答




主题找图→一键成片

04

展望：下一站，Agent OS

从 Assistant 到 AgentOS


Evolution of Mobile AI Assistants



AI 从助手入口，走向系统级任务调度层

AgentOS 正在成为手机系统的新方向

- ◆ **GOOGLE ANDROID INTELLIGENCE SYSTEM**
- ◆ **MICROSOFT PROJECT SOLARA**
- ◆ **APPLE APPLE INTELLIGENCE & PRIVATE CLOUD COMPUTE**



端侧记忆: **AGENT OS** 的个人智能基础设施

本地沉淀: 手机、耳机、眼镜、汽车和家庭设备, 在本地记录最贴近场景的多模态记忆

跨设备协同: 每台设备保留局部记忆, 在用户授权下实现安全连接, 让上下文跟随用户流动

持续个性化: 将长期偏好、任务状态与执行经验沉淀为画像和技能, 驱动主动服务

THANKS

演讲嘉宾：OPPO AI中心 刘鹏
