

孢子AI的知识工程与记忆工程

有记忆 · 有知识 · 会进化的 AI 伙伴



算法和数据同等重要

-- Feifei Li

Context is All Agent Need

持续沉淀，动态可发展的知识体系

多源接入与持续积累，构建企业知识底座

01

结构化数仓

STRUCTURED DW

 元数据

 SQL 资产池

 数据看板

 血缘数据



02

非结构化文件

UNSTRUCTURED DOCS

 业务知识文件

 周报、日报

 外部事件

03

人脑中的隐性知识

TACIT KNOWLEDGE

 对话中再次产生的记忆

目录

CONTENT

- 01 结构化数仓的知识工程
- 02 非结构化文档的知识工程
- 03 记忆工程
- 04 未来展望

结构化数仓的知识工程



STEP 01

数据源接入

接入丰富的结构化知识(引擎元数据 / 血缘 / SQL 资产等等), 并叠加紧密相关的文档作为业务支撑, 形成数据 + 文档双源的抽取原

ENGINE METADATA

引擎元数据 • 表/字段/类型/分区

LINEAGE

血缘数据 • 表/字段级上下游依赖

SQL POOL

SQL 资产池 • ETL / 在线查询 / 计算逻辑

DASHBOARDS

看板 / Tab / 图卡 / 筛选变量

DOCUMENTS

库表知识 • 业务 workflow 方法论

STEP 02

确定性解码 + LLM 抽取

规则/查表先把算子、#变量#、字段、SQL 表翻译成成人话(零 LLM); 剩下「是什么业务概念」交给 LLM——但抽取的节点类型与关系类型必须落在预定义的**有界本体 Schema**(8 类节点 • 15 种关系)内, 越界即拒绝。

RAW FILTER

el_vid_type_id - is #pinleil#

↓ 规则解码

DECODED

字段「一级视频类目」= 品类(动漫)

↓ LLM 抽取 • 受 Schema 约束

BOUNDED SCHEMA

8 类节点 • 15 种关系(闭集)

↓

业务指标/分析步骤

业务指标/分析步骤

STEP 03

对抗性质量审查

LLM 抽象是质量风险最高的环节。在抽象与建图之间插入独立的对抗性审查: 生成者(Extractor)与审查者(Adversary)分离, 审查者主动挑错, 打回修正, 有界迭代。

Extractor

业务抽象产物

↓

确定性 Validator

证据真实性 / 类型准入 / 关系白名单 / 覆盖率 / 呈现层泄漏(零 LLM)

↓

审查者 Adversary

类型误判 / 该并未并 / 关系逻辑 / 粒度 / 漏抽(LLM)

↓

Arbiter 裁决

打回修正, 有界迭代

↓

准入图谱

STEP 04

跨源归一 + Grounding + 建图

归一化是防爆炸的关键; Grounding 是可信取数的保证。两者都确定性执行。

看板

播放UV

SQL

播放UV

文档

播放UV 段落

↓ 跨源 • 异构源


MERGED NODE

Metric • 播放UV(多源溯源)

↓ 回接取数坐标

GROUNDING

图卡证据
文章段落
库表字段



METRIC

有效消费 UV

内容当日有效消费去重人数，
是周报 Top 列表 ORDER BY 字段。

别名: 有效消费人数,

消费

UV

有效口径

周报

取数参数 (2)

参数	类型	说明
* imp_date	integer	分区日期, 格式 YYYYMMDD (bigint)
? top_n [:=100]	integer	返回 Top N 条内容, 默认 100

输出

table

每条内
序排列

执行实现 (SQL)

STEP 01

从一句话到相关子图

三个动作把自然语言问题「翻译」成图上可消费的知识
:先切词认名词(NER),再把名词落到具体节点
(Grounding),再让节点辐射出真正相关的邻居(PPR)。

用户提问

「品类播放UV 为何下跌?怎么归因?」

① NER • 认名词

从一句话里挑出业务名词
播放UV • 品类 • 归因

② GROUNDING • 落到节点

名词 → 图上真实概念(而不是字符串)
播放UV → Metric 节点
品类 → Dimension 节点
归因 → AnalysisMethod 节点

③ PPR • 找邻居

从种子扩散,把「真正相关」的东西冒出来

→ 相关工作流:播放波动归因链
→ 相关图卡:品类播放趋势 / 端分布
→ 相关段落:归因方法论文档

STEP 02

组装结构化上下文

把检索出的概念、推荐图卡、工作流链、文档段落、看板筛选变量等等组装成 Agent 可直接消费的结构化上下文,含 field_key / cardId / bizId 等取数坐标。

CONCEPTS

Metric / Dimension + field_key

CARDS

bizId + pageId + cardId 可直接取数

WORKFLOW

Workflow → Step 有序归因链

PASSAGES

段落证据 • 背景 / 方法 / 口径

FILTERS

筛选变量字典 + 默认值

STEP 03

Agent + MCP 取数

Agent 沿工作流链逐步:MCP 取数,读数,取不到真实数据就不编数字。

REASON

沿 Step 链决定下一步取哪张卡



MCP CALL

query_card / sql_query



OBSERVE

读数 • 校验筛选生效



ANSWER

标注筛选/cardId,可信作答

STEP 01

图谱更新

三种更新模式统一入口:replace 覆盖、add 增量补齐、remove 下线。
任何更新都先明确本次目标 source 集,再进同一条确定性流水线。

REPLACE

覆盖:重建目标图

ADD

增量:并入新 source

REMOVE

下线:移出 source

STEP 02

治理 • 受控演化

越界类型待人审,不擅自扩张 schema;冲突进治理台,软冲突不静默覆盖

TYPE PROPOSALS

越界概念候选 • 人审确认


CONFLICTS

同概念不同字段 • 软冲突入库

REVIEW

治理台展示 • 人工裁决

生产、消费、治理互相牵引, 让知识持续沉淀、被使用、被校准。



非结构化文档的知识工程



PDF

自动提取文本内容，保留文档结构和格式，支持表格识别与元数据提取



Excel / CSV

解析表格数据，自动识别表头与数据类型，支持多 Sheet 处理



HTML / JSON

结构化数据解析，支持嵌套对象抽取与字段映射转换



PPT

提取幻灯片文本与备注，保留页面层级关系和演示逻辑



图片

OCR 提取图中文字，支持场景识别与视觉内容描述生成



视频

语音转文字提取字幕内容，支持关键帧抽取与视频主题分析

非结构化文档知识化 • 三种结构 三种检索



狍子AI

DataFun. AGENTIC AI
超级智能体系架构峰会

WHY

为什么三种

同一份非结构化文档入库时被 同时 保留成三种结构：原始段落、稠密向量、知识图谱。

三种结构回答的问题不同 —— 字面命中 vs 语义近似 vs 关系遍历，任何一种都无法替代另外两种，所以检索天然分三种，由 Agent 按问题形态择路。

① Grep 检索

② 向量检索

③ 图检索

① Grep 检索 字面 / 正则 原文段落

HOW • 存 & 查

原文保留不做变换；交给 Agent 用工具按字面 / 正则直接扫，一字不差。

典型场景

"这个字符串在哪份文档里" 编号、型号、条款号、错误码——一个字符都不能错。向量检索会把 HT-2024-0912 和 HT-2024-0921 视为"高度相似"，Grep 逐字符区分，直接定位到对应文档，不被相邻编号污染。

② 向量检索 Embedding 向量空间

HOW • 存 & 查

切分后 chunk 被 embed 成向量入库；查询同样向量化，按语义相近度召回相关段落，问法可以完全脱离原文。

典型场景

"问法和文档字面不一样" —— 用户说人话、文档用行话，同一意图跨表述、跨语种、跨风格。"客户抱怨到账慢" 匹配 "资金结算延迟处理"，关键词一个字都不重。

③ 图检索 Nodes + Edges 知识图谱

HOW • 存 & 查

入库时 LLM 抽取实体与关系，落成实体页 + 关系边；查询先定位入口实体，再沿边遍历拿到关联全景。

典型场景

"答案在实体之间的关系上，而不在任何单段文字里" —— 归属、依赖、演化、影响面。任何单段都说不全"这个条款影响哪些产品"，但从"条款"页出发沿applies_to 一遍遍历就一览无余。



STAGE 1

评分

量化每个节点的健康度，形成可比分数

知识库

chunk 级 **Vitality Index** —— 脉动 25% · 呼吸 20% · 循环 20% · 代谢 20% · 免疫 15%。

知识图谱

图谱级 **Vitality Index** —— 过时页 · 别名冲突 · 弱关系 · 摘要缺失 · 孤立边 · 孤立页。

STAGE 2

检索加权

高活力节点优先召回，冗余内容下沉

知识库

检索结果按活力分重排，高质量内容优先返回，**检索质量随使用而增强**。

知识图谱

图遍历跳过 **已归档 / 低分** 实体页与弱关系，遍历路径始终紧凑，**图谱结构持续自愈**。

STAGE 3

清理

诊断结果自动落成治理动作

知识库

对长期未引用内容递减分值，清理过期片段，输出结构化诊断报告

知识图谱

低活力实体自动归档，冲突实体合并，保持图谱整洁

记忆工程

三类记忆各司其职:个人偏好、项目共识、每日事件流。

● PERSONAL

个人记忆

跨项目通用, 刻画“这个人是谁、怎么合作”。

语义

- 性格 / 沟通风格
- 编码 / 语言偏好
- AI 行为规则
- 兴趣 / 价值观

来源

- 主动洞察 • 用户确认后落库
- 用户主动管理

SCOPE • 用户级 • 跨所有项目通用

● PROJECT

项目记忆

空间内团队共享, 沉淀“这个项目怎么做”。

语义

- 项目事实
- 技术决策
- 架构约定
- 团队规范

来源

- 主动洞察 • 用户确认后落库
- 用户主动管理

SCOPE • 空间级 • 项目成员共享

● DAILY LOG

每日日志

按 session 归档: 讨论了什么、做了什么决策、得到什么结论。

语义

- 近期讨论过的话题
- 敲定的口径与结论
- 因为什么做了某些决策

来源

- LLM 简短摘要, 按天保留
- 系统自动归档 • 会话结束触发

SCOPE • 用户级 • 按天分片 • 事件流



同一批记忆分三路消费:直接注入 prompt、向量检索、图检索,各自擅长不同问法。

① CONTEXT

直接入上下文

不走检索,每轮对话按预算裁剪后拼进 system prompt。

来源

个人记忆 • 项目记忆 • 最近 1 天日志

典型场景

- Agent 遵守用户的硬性偏好与行为规则
- 接着最近一天的话题往下聊,不用重述背景
- 沿用团队已敲定的口径 / 术语 / 架构约定

② VECTOR

向量检索 • 语义相似

分块 embed 成稠密向量,问法与记忆字面不一致时靠语义命中。

来源

个人记忆 • 项目记忆 • 每日日志

加工

- 按 ## section 切块,逐块 embed 向量入库

典型场景

- 换说法 / 口语 vs 术语仍能命中
- 问“周报格式是啥来着” → 命中日志
- “周报采用 概览 + 指标异动 + 结论 三段式”

③ GRAPH

图检索 • 关系遍历


节点按预先规定的类型分层,顺着有向边遍历,答案在关系里而不在正文里。

来源


个人记忆 • 项目记忆 • 每日日志

加工

- 节点按预定义类型分层,不是自由聚类:



- 边按预定义关系类型建立:



典型场景

- 沿着日志与决策之间的连线追溯因果 / 演化
- 问“周报格式为啥改成三段式” → 顺 updates 边找到原两段式漏掉指标异动的反馈日志

三路融合 • 三类记忆按预算直接注入 prompt;向量 + 图两路 RRF 混合检索。

为什么要治理

Why lifecycle

记忆只进不出，几个月就变成 过期偏好、重复条目、临时上下文 的仓库 —— 召回越来越钝，预算越用越紧 。 我们让每条记忆都有一条 “像人一样” 的生命线，五个阶段围绕同一个健康分闭环，让记忆规模 自收敛 。

STAGE 01

写下来

Encode · 建立记忆

值得留下的事实与偏好被写入图谱，并给一个 初始重要度 —— 越关系到“你是谁”，分数越高。

— 类比

像人第一次听到一件事，越关乎身份记得越牢。

STAGE 02

用一次就更牢

Reinforce · 强化

每次被召回命中，这条记忆的“最近使用时间”就被刷新 —— 用得越多，越难被淡忘。

— 类比

像常走的路会被踩出来，常被问起的事实自己会浮上来。

STAGE 03

慢慢淡忘

Decay · 时间衰减

后台每天重算一次健康度 —— 时间把分数往下拉，访问把分数往上抬，全自动、无需人工 。

— 类比

像人的记忆不用就会淡，想不起来说明已经不重要。

STAGE 04

相似的合成一条

Consolidate · 归纳

说法不同意思一样的记忆会被识别为孪生对，分高者胜出、弱者并入，并留下溯源边。

— 类比

像人把多次听到的同一件事，归纳成一条更笃定的印象。

STAGE 05


真正没用的遗忘

Prune · 软删除


健康度过低即打上“已遗忘”标记 —— 不物理删，只是不再召回；身份类记忆永不自动清。

— 类比


像被遗忘但没真消失的往事，关键时刻还能被唤回。



用户对写作相关技能感兴趣，正在...



新加入的成员需要先熟悉现有流程。



决定使用曝光三要素、拍摄步骤、

帮我准备4月29日发的公众号文章，自拟题目，生成内容。

「根据我的记录，你目前已经写过了 data-analytics 、 data-cleaning 等5 篇文章。Statistical Analysis A/B Testing 尚未写过，可以作为新方向。」

		 结构化数仓	 非结构化文件	 记忆
生产 · 来源		元数据 · SQL 资产池 · 血缘 · 看板	业务知识文件 · 周报日报	对话中再次产生的记忆
消费	上下文			✓
	Grep 检索		✓	
	向量检索		✓	✓
	图检索	确定性解码 + Schema-driven LLM 抽取	Schema-free LLM 抽取	Schema-driven LLM 抽取
治理		✓	✓	✓



制作一个知识卡片，展示包子的核心能力，包括知识库、长记忆、多类型AI产物等



执行命令 语义搜索 3s >

执行命令 搜索记忆 486ms >

基于搜索到的信息，我现在来为你制作一个包子核心能力的知识卡片。我将使用 OmegaDash 引擎来生成一个视觉化的卡片。

执行命令 选取工具 1ms >

执行命令 匹配产物风格 22ms >

我选用赛博朋克风格会更适合展示科技产品的能力卡片，让我来生成骨架：

执行命令 生成骨架 HTML 139ms >

骨架已生成，现在逐个填充每个 Section：

执行命令 填充页面区块 x4 169ms >

所有 Section 已填充完毕，进行最终完成：

执行命令 完成 HTML 产物 13ms >

知识卡片已生成！这是一张赛博朋克风格的 包子 AI 核心能力卡片，内容包括：

品牌定位区

- 核心公式：业务知识 × 业务数据 × 市场情报 = 个人参谋部

六大核心能力

> 1 个文件

告诉我想做什么，或输入 @ 引用上下文



Claude Opus 4.6

内容由 AI 生成，请注意甄别

搜索文件

当前会话

包子AI核心能力知识...

平台示例

腾讯控股 (0...

Q1 业绩数...

2026 产品...

用户增长趋...

团队周报

登录页交互...

数据处理脚...

前往知识库

终端 代码 浏览器

存入知识库

历史

包子 PAOZI

业务知识 × 业务数据 × 市场情报 = 个人参谋部

将文档、数据、资讯汇聚到一处，AI 自动整理、智能问答、生成洞察
从「查到信息」到「看到别人看不到的机会」

六大核心能力



知识库

支持文档、文件夹、书签、AI对话记录、IMPA 笔记等多源导入。AI 自动理解、索引、语义搜索，把散落的资料变成随时可调用的活知识。

支持来源

本地文件 / iWiki / 灯塔 / URL / 对话记录



长记忆

AI 会记住你的偏好、写过什么、做过什么决策，越用越懂你。下次对话无需重复背景。



多类型 AI 产物

一句话生成数据看板、Web演示稿、文档报告、图片、表格、代码，所见即所得。



Skill 技能

自定义或安装技能，让 AI 精通你的业务流程。从创建到发布到分享的完整生态。



数据连接

直连灯塔、数据库、MCP 工具，业务数据触手可及，一句话生成分析洞察。

Omega 引擎 · 包子 AI 生成



包子AI

展开

THANKS

孢子AI · 记忆工程与知识工程
