


从“完成任务”到“持续进化” AI Agent 记忆能力的评测与实践

演讲嘉宾：童冰

浙江创邻科技有限公司 高级算法工程师

两个 Agent，谁更适合长期上岗？

Agent A：第一天就很强



- 每次都从当前上下文重新开始；
- 能完成任务，但不会积累经验；
- 犯过的错误仍可能再次发生。

Agent B：一开始没那么强



- 能吸收反馈；
- 能更新知识和状态；
- 能复用有效经验；
- 随着服务时间增长而改善。

一次做对，是能力；做过之后变得更好，才是进化。

目录

CONTENT

01 Agent Memory 的能力边界

02 EvoMemBench 的设计与方法

03 Benchmark 结果洞察

01

Agent Memory 的能力边界

为什么 Agent 开始需要 Memory

01 Copilot: 帮人完成片段工作

人负责流程，AI 提供辅助

→ 记忆主要在人脑里，AI 只需要理解当前问题



02 Task Agent: 完成一个闭环任务

AI 能规划、调工具、执行任务

→ 需要短期状态，知道当前任务做到哪一步



03 Long-running Agent: 长期服务业务

AI 持续服务用户、流程和组织

→ 需要沉淀知识、更新规则、复用经验



Agent 承担的时间跨度越长，
Memory 越从“加分项”变成“基础设施”。

长上下文、RAG 与 Memory 有什么区别

对比维度	长上下文	RAG	Agent Memory
核心作用	带着当前任务的完整过程	需要时去知识库查资料	把重要信息和经验留到以后使用
主要内容	对话、工具结果、中间步骤	文档、知识库、外部资料	用户偏好、业务状态、历史经验
使用范围	当前会话或当前任务	当前任务需要时反复查询	跨会话、跨任务长期使用
如何变化	随对话不断追加	知识库单独维护，按需读取	随交互持续写入、更新和失效

长上下文记住“刚刚发生了什么”，RAG 查询“外部资料怎么说”，Memory 保存“以后还要用什么”。

长上下文、RAG 与 Memory 有什么区别

“帮我退掉刚才那笔海外订单”

Long Context (长上下文)

“刚才那笔”是哪一笔？前面已经完成了哪些工具调用和执行步骤？

RAG (检索增强生成)

当前有效的海外跨境退款政策和合规要求是什么？

Agent Memory (系统记忆)

客户历史偏好是什么？合规审核状态是否已完成？这次经验未来是否值得复用？

三者通常是协作关系，而不是替代关系。

用四个问题理解 Agent Memory



1. 记什么信息?

用户偏好、业务规则、工具结果、任务状态



2. 记成什么形态?

原始日志、摘要、向量、图、流程、技能



3. 给谁使用?

当前任务、同一用户、同类业务、Agent 团队



4. 如何被治理?

来源、版本、权限、失效、删除、安全

Memory 的难点不是“存下来”，而是判断什么该记、怎么更新、何时使用、何时失效。

Agent Memory Benchmark 演进

——从“记住”到“行动”

06 长期可治理

05 主动学习

04 复盘提经验

03 带着记忆做事

02 纠错改答案

01 开卷找答案

关卡	考题	真正考什么
第1关：开卷找答案	过去说过什么？	长对话事实召回
第2关：纠错改答案	新旧信息冲突时信谁？	更新、修正、选择性遗忘
第3关：带着记忆做事	记住的信息能不能指导行动？	工具调用、环境交互、任务执行

Agent Memory Benchmark 演进

—— 从“行动”到“持续学习”

06 长期可治理

05 主动学习

04 复盘提经验

03 带着记忆做事

02 纠错改答案

01 开卷找答案

关卡

考题

真正考什么

第 4 关：复盘
提经验

做过的任务能不能帮
未来任务？

跨任务知识与执行经
验复用

第 5 关：自己
做笔记

连续信息流里什么值
得记？

主动写入、证据选
择、未来复用

第 6 关：长期
可治理

记忆越积越多还能安
全吗？

成本、延迟、删除、
隐私、污染防御

02

EvoMemBench 的设计与方法

现有 Benchmark 缺了什么



01 能力断点

“记住”和“行动”经常分开测

- 有些 Benchmark 只考事实召回或只考任务执行；
- 很难判断记忆是否真正改善了行动。

02 时间断点

“当前任务”和“未来任务”经常分开测

- 单任务内强调状态保持，跨任务强调经验积累；
- 缺少统一视角描述两者之间的关系。

03 比较断点

不同结果之间难以横向比较

- 使用不同任务和模型；
- Memory 更新时机、上下文预算和指标不同。

我们缺的不是更多测试集，而是一套能够同时描述“知识、行动和时间演化”的统一坐标系。

联合研发 EvoMemBench



浙江创邻科技有限公司

图技术与企业级 AI 基础设施实践



香港科技大学（广州）

Agent Memory 方法与评测研究

产学研深度融合，共同推进 Agent 记忆系统与评测标准的发展。

EvoMemBench 自演化记忆

Agent 在交互中持续保存、更新、组织和复用信息，让未来决策因为过去经验而改善。

Knowledge 知识

Execution 执行

In-Episode 任务内

记住并修正信息

用户改口、规则变化、事实冲突

例子：用户先说“普通发票”，后来改成“专票”。

跟踪执行状态

工具结果、当前进度、未完成步骤

例子：用户说“把刚才那个订单金额改一下”。

Cross-Episode 跨任务

积累可复用知识

用户偏好、业务规则、领域知识

例子：长期记住某客户的偏好和业务规则。

复用执行经验

流程策略、失败恢复、操作习惯

例子：多次退款后总结出更稳定的处理流程。

自演化记忆不只回答“过去发生了什么”，还要回答“现在该更新什么、未来能复用什么”。

象限一：任务内知识演化 (INEP-KNOW)

例子 1：用户直接改口

用户：出差喜欢靠窗座位。

(十几轮对话后...)

用户：腿受伤了，改选靠过道。

正确：当前偏好靠过道；靠窗失效。

错误：只记靠窗 / 两者都记但不辨有效性 / 删旧记录丢历史。

例子 2：业务规则更新

旧规则：低于 5 万经理审批。

新通知：超 3 万必须财务审批。

当前申请：4 万元。

正确：应用新规则，需财务审批。

错误：仍用旧规则 / 视为补充不处理冲突 / 忽略时间有效性。

例子 3：多跳信息修正

早期：Alpha 负责人是王经理；王经理的预算由李总批。

更新：Alpha 负责人变为赵经理；赵经理的预算由陈总批。

提问：Alpha 预算谁批？

更新一条实体关系，会影响后续的推理链。

Retention

早期有效信息还能否被找回？

Revision

变化后，能否正确维护当前有效状态？

记住历史并不难，难的是在历史发生变化后，仍然回答“**现在什么是真的**”。

象限二：任务内执行演化 (INEP-EXEC)

连续工具调用故事：修改旅行订单

Step 1: 用户让查下周一去上海航班。

Agent 调工具获三个结果。

Step 2: 用户：“订最早的那个”。

需记：“那个”是哪个、日期、路线。

Step 3: 返回：只剩商务舱。用户：“换第二个，用刚才的乘机人”。

需恢复：第二个航班、原乘机人、已选日期。

Step 4: 用户：“把刚才那个订单改成周二”。

歧义：“刚才那个”是搜索结果、失败订单还是成功订单？

重构一：显式参数改成隐式引用

原始：修改订单 A12345 的日期。

重构：修改**刚才那个**订单。

*迫使 Agent 使用执行记忆恢复实体和参数。

重构二：复杂任务拆成依赖子任务

搜索 → 选择 → 创建 → 根据结果调整 → 修改。

*让后一步真正依赖前一步，聚焦执行状态记忆。

文件系统：建文件夹，把刚下的俩文件移进去，较大的重命名。

需记：哪俩文件、哪个大、路径。

交易工具：卖出刚查股票的一半。低于目标价则撤销剩余。

需记：代码、查询结果、下单状态。

执行记忆最怕的不是忘掉一段话，而是丢失实体、参数和中间状态。
如果 Agent 不知道“刚才那个”指什么，再强的工具能力也无法完成任务。

象限三：跨任务知识演化 (CROSSEP-KNOW)

共享背景：虚构企业差旅制度

向 Agent 提供预训练不可能知道的新制度：

- **规则 1:** P1 级员工乘坐高铁不得选择商务座。
- **规则 2:** 连续出差超 5 天，可报销一次洗衣费。
- **规则 3:** 海外住宿上限提高 30%。
- **规则 4:** 周末返程需单独填写特殊说明。

为什么不是普通 RAG?

RAG 只是重新检索制度。我们要测的是：Agent 是否逐步积累规则、形成可复用知识、不会把特例当通用规则。

Episode 1: 直接事实应用

P1 去北京，能买商务座吗？→ 考察找规则1。

Episode 2: 组合规则

P2 去新加坡 6 天，住宿上限多少？报洗衣费吗？→ 组合海外与时长规则。

Episode 3: 程序性知识

周日从客户现场返程，需什么材料？→ 规则转流程。

Episode 4: 经验规律

提供历史案例（提前订票便宜、展会超标等），让 Agent 判别新方案。

考的不是它原来懂多少，而是给它一套陌生规则后，它能不能越做越熟。

象限四：跨任务执行演化 (CROSSEP-EXEC)

例子 1: 工具调用经验

过去：改驾驶模式失败（车在行驶）。经验：先查状态 → 停车 → 修改 → 验证。

新任务：调能量回收等级。

可复用：改配置前先检查并满足前置状态的“执行模式”。

例子 2: Web Search 经验

过去：查去年发多少产品，仅搜一条新闻出错。经验：官网 → 年报 → 交叉验证。

新任务：查另一公司今年进几国市场？

可复用：寻第一方来源、交叉验证、不信单一结果的策略。

例子 3: 具身任务经验

过去：加热番茄放冰箱。经验：定位 → 取出 → 微波加热 → 开冰箱 → 放入。

新任务：冷却已加热的苹果。

可复用：找目标、查容器、设备使用规律。不能搬：具体位置和容器。

负迁移：当经验导致失败

过去：国内订单先退款，再关工单。

新任务：跨境退款（必须先合规审核）。

若强搬经验则失败。经验复用 ≠ 轨迹复制。真正提炼的是适用条件和边界。

做过一百次不一定叫学习；知道哪些经验可以复用、哪些不能，才叫进化。

数据集选择的三项原则

🔗 原则一：必须真正依赖 Memory

✓ 好任务

用户说“修改刚才创建的订单”，参数只能从历史恢复。

✗ 坏任务

题目已经把订单号、日期和用户信息全部重新给出。

结论：即使没有 Memory，也能完成，就无法说明 Memory 是否有效。

🎯 原则二：尽量只测 Memory

✓ 好任务

把复杂任务拆成连续子步骤，主要考状态跟踪。

✗ 坏任务

同时要求高难度规划、陌生工具调用、复杂数学推理。

结论：失败后无法判断到底是 Memory、规划还是模型能力的问题。

🏗️ 原则三：覆盖不同可复用结构

对话(事实/偏好)；工具(参数/状态)；Web(搜索验证)；具身(动作/环境)。

结论：单一任务上的最优 Memory，不一定适用于其他业务。

EvoMemBench 全景数据图

设置	Benchmark	规模 (样本数)
任务内知识	INEP-KNOW	2,800
任务内执行	INEP-EXEC	800
跨任务知识	CROSSEP-KNOW	884
跨任务工具执行	CROSSEP-TOOL	800
跨任务 Web 执行	CROSSEP-WEB	270
跨任务具身执行	CROSSEP-EMB	200

4 种演化能力、6 个 Benchmark、约 5.8K 个评测样本。

03

Benchmark 结果洞察

模型加上 Memory，真的更会记了吗？

结论：在任务内知识演化中，历史放得下时，直接读原文 > 外部 Memory。


看原文 VS 外部Memory

准确率越高越好 Rank越低越好

方法	路线	Event QA	FC-MH	FC-SH	Overall Rank
Gemini-3-Flash	看原文	98.2	58.0	96.0	1.00
GPT-5-mini	看原文	80.6	24.0	77.0	3.00
BM25	外部Memory	88.8	7.0	54.0	4.17
Mem0	外部Memory	79.2	7.0	49.0	4.50
A-MEM	外部Memory	91.2	5.0	35.0	4.83
DeepSeek-V3.2	无Memory	83.0	10.0	65.0	5.50

3项关键指标：Gemini vs 外部Memory

蓝=直接读原文；橙=外部Memory最高值



简单题可能被 Memory 干扰，难题才拉开差距

#DataFun.

AGENTIC AI
超级智能体系架构峰会

13 种 Memory 方法在不同难度下的表现

任务难度	超过 Baseline 方法数	13 种方法平均变化
Easy (简单)	0 / 13	-6.09
Medium (中等)	6 / 13	+0.32
Hard (困难)	13 / 13	+7.12

二次统计自 Table 5。在简单任务上，没有一种 Memory 方法超过无 Memory 的基线。

为什么简单题加 MEMORY 反而更差？

当前输入明确提示：

“普通员工由直属经理审批。”

+

Memory 召回历史：


- ▶ 海外出差需要财务审批
- ▶ 金额超3万需要副总裁审批
- ▶ 某高管出差曾由 CEO 特批

= 信噪比下降，Agent 开始怀疑正确答案

66 当模型已经知道答案时，Memory 最容易成为噪声。目标不是最大化召回，而是在存在能力缺口时介入。

上下文越短，Memory 越能补齐执行状态

结论：历史越容易被截断，Memory 保存“做到哪一步、参数是什么、下一步该做什么”的价值越明显。



超过无 Memory 基线的方法数

16K	11 / 15
32K	11 / 15
64K	12 / 15
128K	9 / 15

在 128K 上下文下，原始历史已经保留了大量证据。外加 Memory 必须提供真正的信息增量，否则只是在重复、甚至扭曲已有信息。

能找回旧信息 $\neq$ 能更新旧结论

51.6% $\rightarrow$ **18.1%**
Retention 平均表现 Revision 平均表现
Revision 约为 Retention 的 35%

修订难题场景还原

1月： 用户喜欢靠窗座位

6月： 用户腿部受伤，改为靠过道

系统应该如何处理？

- ▶ A. 删除“靠窗”
- ▶ B. 同时保留两条 (大部分 Memory 的做法，导致冲突)
- ▶ C. 保存变化历史，但将“靠过道”设为当前有效

为什么 Revision (修正) 这么难？处理链路拆解：



1. 找到相关记忆
容易 (Search)



2. 识别实体同一性



3. 判断冲突或补充



4. 判断优先级与时间



5. 更新/降权/失效
极难 (Update)

没有最好的 Memory，只有更匹配的 Memory

Memory 范式

工具调用 (Tool)

Web Search

具身任务 (Embodied)

检索型 Memory

5.43 🏆

8.50

6.53

通用长期 Memory

8.22

5.38 🏆

6.08

程序性 Memory

9.24

7.70

5.60 🏆

Meta-Evolution

8.80

13.00

6.00

* 数字为 Family Average Rank，越低越好。

🔧 工具调用

相似案例反复出现。可复用结构：

- ▶ API 名称与参数模式
- ▶ 调用约束与前置状态

→ 召回相似历史有效

🌐 Web Search

需积累验证习惯。可复用结构：

- ▶ 哪类来源更可信
- ▶ 如何交叉验证

→ 长期经验管理更有价值

🤖 具身任务

流程和环境规律重要。可复用结构：

- ▶ 动作顺序及前提状态
- ▶ 失败后的恢复路径

→ Procedure & Skill 匹配

迁移不是复制经验，而是匹配决策过程

Tool Using: 更多正迁移

	12	2	26
2		8	14
20	10		20
16	22	14	

共享决策步骤:
检查状态 → 选择下一次工具调用 → 验证最
终状态

Embodied AI: 正负混杂

16			-8	12	
10	11			8	11
				16	
8	-9		11		
	-13				

环境差异更大:
动作前提、物体位置、执行条件都可能变化

真正可迁移的不是“这次做过什么”，而是“这类任务的决策过程”。

从 Benchmark 结果到 Memory 建设的五条原则

zDataFun

AGENTIC AI
超级智能体系统架构峰会

01 先建立强 Baseline

先比较强模型、长上下文和简单检索，再证明复杂 Memory 的增量价值。

02 不要默认每次都使用 Memory

当前证据足够时，额外 Memory 可能降低信噪比，应该只在存在能力缺口时介入。

03 把更新和失效作为一等能力

企业 Memory 的核心不只是 Add 和 Search，更是 Update、Invalidate 和 Rollback。

04 区分“经验抽象”和“精确状态”

Procedure 可以压缩抽象，但订单号、文件路径和工具结果等现场状态必须精确保留。

05 为经验记录适用条件

历史成功不等于当前适用，跨任务复用必须通过适用性和前提约束控制负迁移。

Memory 净价值 = 任务收益 - Token 成本 - 检索延迟 - 维护成本 - 负迁移损失 - 安全风险

公司介绍

DataFun.

AGENTIC AI
超级智能体系架构峰会

浙江创邻科技有限公司是国内领先的图数据库与图智能服务供应商，具备一支由国家领军人才、国内外名校博硕组成的高精尖研发团队，深耕企业数据互联网技术平台建设，拥有强大的技术研发、解决方案定制和项目实施服务能力，致力于推进客户数智化升级、激发数据要素活力、增益数据资产价值。

2016年

浙江创邻科技有限公司成立
(国家引才项目落地杭州)

2019年

参与制定中国图数据库白皮书标准
参与广东省超算中心国家重点研发图计算项目

2020年

与腾讯云达成合作
实现万亿点边大图线上支持
获得高领、腾讯投资

2018年

获得百度风投天使轮投资

打破五万亿大图世界记录

Galaxybase产品2.0发布

国内第一家商业图数据库

Galaxybase 1.0发布

2021年

获得腾讯、同创伟业、达晨智过亿元投资
交行、民生银行国网、南网、等行业标杆



国家高新技术企业



上榜中科协准独角兽名单

2022年

打破LDBC SNB世界纪录
入选国际四大研报



金融市场份额全国第一

2023年

港科大“创邻图数据实验室”成立
华为、中电子达成合作
保险、公安等行业突破



2024年

获评国家专精特新“小巨人”企业
商飞、上汽等制造业标杆落地



浙江省专精特新企业

2025年

发布AI一体机
发布GraphoraX平台



出版《图数据库理论与实践》

2026年

发布企业级小龙虾
布局具身智能场景



产品介绍

DataFun.

AGENTIC AI
超级智能体系统架构峰会

图平台 Galaxybase

- 面向“实体—关系—路径—网络”数据结构的国产高性能分布式数据库产品
- 对海量复杂关联数据进行高效存储、管理与实时查询
- 支撑复杂业务场景下的在线分析与决策
- 打破LDBC SNB测试世界记录
- 打破万亿大图世界记录
- 国内最早商业化图平台
- 长期服务国内头部企业

图智能平台 Graph Intelligence

- 构建在图数据库之上的图分析与图智能平台产品
- 围绕图数据开展自主建模、图模式识别、图特征计算与图算法分析，形成可沉淀、可复制、可持续演进的图智能能力



行业图谱方案

- 面向希望快速落地图智能能力的客户，提供从知识建模、图谱构建到行业场景分析应用的一体化解决方案
- 更低门槛实现图智能业务价值

AI智能体

行业智能体

- 行业智能体是面向特定垂直领域深度定制的AI智能体系统，能够基于行业知识、业务规则与合规要求，自主感知环境、理解任务、规划路径、调用工具、跨系统执行并持续优化，最终交付可衡量的业务结果
- 情报分析、故障成因分析、科研项目查重、客服智能问答等

GraphRAG HybridRAG

- 融合向量检索、关键词检索与图谱关系检索的企业级检索增强系统
- 显著提升大模型在企业本地知识场景中的准确性、可解释性与复杂关系理解能力

GraphoraX 企业AI大脑

- 面向企业场景深度重构的智能体生产力平台，企业的“数字员工中枢”，实现从“对话交互”到“任务执行”的范式升级

THANKS

演讲嘉宾：童冰

浙江创邻科技有限公司 高级算法工程师



关注公众号，了解更多



www.galaxybase.com



400-882-6897