

AGENTIC AI
SUMMIT 2026

大模型时代 智能文档 Benchmark 落地实践

从评测设计到数据合成 — 构建面向真实企业场景的文档智能评测体系

演讲人：刘青

阿里巴巴企业智能 算法智能团队

UniKIE-Bench · MMM-Bench · CC-OCR V2 · DocScope

解析

分类

抽取

问答

TABLE OF CONTENTS

目录

01

智能文档介绍

核心任务 · 技术架构 · 核心挑战

02

文档智能 Benchmark 构建方式

数据采集 · 难度分层 · 文档合成

03

文档智能 Benchmark 实践案例

CC-OCR V2 · MMM-Bench · UniKIE · DocScope

04

未来规划和总结

路线图 · 开源共建

PART

01

智能文档介绍

理解文档，是自动化企业流程的第一步

INTRO 01

文档 - 可信企业流程的基石

业务流程维度 交易闭环



跨境 ⇌ 本地交易 • 收款 / 付款闭环

法律合规维度 权利义务锚点

合同类文档



主合同
补充协议
三方协议
合同披露

法律诉讼全流程



起诉状



传票



调解书

敏感场景



知识产权



保密协议



劳动合同


身份与资质维度 主体可信性




身份证



护照



学历证书



营业执照



开户许可证



商标注册证




国际身份证件



大陆 · 港澳台

INTRO 02

文档智能整体技术架构






INTRO 03

四大核心任务与三大核心挑战

四大核心任务

1 文档解析



2 文档分类

附件检测清单

- 身份证正面 ✓
payerIdCardFront-原付款人身份证(人像面).jpg 上传
otherAttachments-广东汇鑫法人身份证(人像面).jpg 上传
- 银行回单 ✓
otherAttachments-交易记录.jpg 上传
- 代收付证明 ✓
refundProof-退款代收付款证明(加盖公章).jpg 上传
- 身份证反面 ✓
payerIdCardBack-原付款人身份证(国徽面).jpg 上传
otherAttachments-广东汇鑫法人身份证(国徽面).jpg 上传
- 营业执照 ✓
businessLicense-广东汇鑫模块化房屋科技有限公司营业执照.pdf 上传
businessLicense-广东鑫建设有限公司营业执照.jpg 上传

3 关键信息抽取

基础抽取



+ 定位 Grounding

4 智能问答



三大核心挑战

来源复杂

扫描 · 拍照 · 电子PDF · 网页

版式多样

表单 · 合同 · 报告, 布局各异

结构差异

同类文档字段定义大不相同

结论: 单一维度测试无法反映真实生产环境表现

PART

02

文档智能 Benchmark 构建方式

数据采集 · 难度分层 · 文档合成



数据采集



难度分层



文档合成

PART 02 PRINCIPLE

设计思路与原则

01 全域覆盖

覆盖企业核心业务场景，不遗漏关键领域

02 全任务覆盖

覆盖解析 · 分类 · 抽取 · 问答全链路任务

03 分层建模

从简单到困难，多维度多粒度分层评测

落地目标 · 四步走通

沉淀高价值文档

→ 统一数据与指标

→ 标准化自动化平台

→ 权威开源基准

PART 02 DATA

构建方式 · 数据采集三管齐下



01

企业内部真实业务文档

从阿里 60+ 个核心业务域采集近百万份真实文档，脱敏后用于评测

百万份 60 业务域



02

公开数据集整合再标注

从多个公开文档理解数据集筛选样本，按统一规范再标注，保证一致性

多源统一标注



03

生产系统错误样本回收


系统性收集实际部署系统中的失败用例与边界 Case，最能反映真实能力

20% HARD CASES


PART 02 MINING

构建方式 · 错误归因驱动的难例挖掘

错误归因树 · 五大任务类型



难例挖掘闭环 · 四步



评测 - 归因 - 补样 · 持续迭代闭环，精准覆盖当前模型的能力盲区

PART 02 SYNTHESIS

文档合成框架 SAYRE[1] • 场景感知文档合成

Path A • 通用生成

Few Exemplars



Scene Perception (Content + Layout)



Doc-Schema-Anno Triple



Rendered Image

Path B • Error-Driven 生成

Failure Cases



HTML Template 提取版式结构



Content Rewriting + 重标注



Hard Training Examples

✓ 无手工模板

✓ 可扩展

✓ 覆盖长尾场景


PART 02 RESULTS

SAYRE 实验效果 • 数据质量&模型规模


UniKIE-Bench 平均 F1 对比

Method	Constrained-Category			Open-Category				Avg.
	Bus. Trans.	Pub. Serv.	Reg. Rec.	Receipt	Form	Invoice	Contract	
On-Server LMMs								
Claude-Sonnet-4.5	64.53	68.29	66.33	39.62	40.21	36.65	42.38	51.14
GPT-4o	68.16	67.14	73.14	59.09	39.45	46.20	42.01	56.46
GPT-5	64.62	67.37	71.86	60.12	41.03	47.57	40.85	56.20
Qwen-VL-Max	74.19	82.51	76.23	70.35	67.63	68.71	73.12	73.25
Qwen3-VL-Plus	76.00	83.26	81.70	69.70	68.34	71.52	72.88	74.77
Gemini-3-Pro	77.03	86.58	83.87	86.03	79.79	82.84	77.93	82.01
On-Device LMMs								
Ministral-3-8B	33.28	39.31	41.16	41.88	42.41	40.04	42.00	40.01
MiniCPM-V4.5-8B	64.24	74.50	61.25	62.37	45.08	50.49	52.47	58.63
InternVL3.5-8B	64.56	70.54	68.09	66.86	40.73	45.19	44.75	57.25
MiMo-VL-7B-RL	67.91	74.11	63.22	64.48	54.72	54.78	68.22	63.92
GLM-4.1V-9B	65.69	75.76	67.74	59.51	55.64	57.42	61.69	63.35
Qwen3-VL-2B	64.03	68.00	72.98	59.14	48.77	50.86	58.57	60.34
Qwen3-VL-4B	68.89	72.23	77.79	57.60	55.44	56.16	61.62	64.25
SAYRE								
SAYRE-2B	67.56	78.35	78.99	76.10	56.48	63.13	72.72	70.47
SAYRE-4B	70.38	80.73	80.97	78.15	59.97	64.89	75.36	72.92

合成数据量 Scaling 曲线



错误字段解决率



Sayre-2B 超越所有同规模开源模型 • 4B 逼近商用水平

随数据量增长, 性能持续上升, 未见饱和

关键结论 数据质量与覆盖率 与 模型规模 同等重要 — 弥合端侧模型与云端大模型的差距

PART

03

文档智能 Benchmark 实践案例

四个互补的 Benchmark，构成完整评测矩阵

CC OCR V2

企业困难样本综合评测

MMM BENCH

多模态多层次分类

UNIKIE BENCH

开放域信息抽取

DOCSCOPE

长文档可验证问答

PART 03 1 CC OCR V2 1

企业困难样本文档智能综合评测

5 大 OCR 核心任务 Track



7,093

高难度样本

74

细分场景

32

语言覆盖


特色 20% 未公开生产困难样本 • 48% 新增标注 • 唯一同时覆盖 5 大任务的综合评测基准

PART 03 1 RESULTS

CC-OCR V2 • 五大任务模型表现

Top 模型在 5 大 Track 上的表现

Model	Document Processing Tasks					Average
	Recognition	Parsing	Grounding	Extraction	QA	
On-Device LMMs						
 Step3-VL-10B	40.95	29.36	6.90	56.50	74.60	41.66
 InternVL3.5-8B	46.36	53.99	9.02	54.75	75.04	47.83
 MiniCPM-o 4.5-8B	61.09	50.91	9.34	50.68	83.41	51.09
 Qwen3.5-9B	83.89	58.62	43.37	62.55	84.64	66.61
On-Server LMMs						
 GPT-5.4	72.35	62.59	10.44	57.94	78.82	56.43
 Qwen-VL-Max	81.77	54.92	2.41	64.40	83.33	57.36
 Claude Opus 4.6	80.74	58.69	6.39	63.00	84.09	58.58
 Claude Sonnet 4.6	82.90	61.84	6.75	63.02	83.52	59.60
 Gemini 3.1 Flash	93.61	64.67	6.91	62.17	79.41	61.36
 Kimi K2.5	87.26	67.94	5.50	67.13	88.74	63.32
 Kimi K2.6	84.74	67.61	19.04	66.73	88.50	65.32
 Gemini 3.1 Pro	93.99	66.51	37.01	69.38	83.98	70.17
 Seed 2.0 Pro	92.48	66.78	54.56	63.80	83.11	72.15
 Qwen3.5-Plus	91.11	61.92	57.12	68.27	86.75	73.03
 Qwen3.6-Plus	92.31	64.97	65.73	68.48	87.34	75.77



关键发现

① Grounding 是最大短板
SOTA 仅 65.73，多数 <50

② 任务间严重不平衡
Rec/QA vs Grd/Ext 差距大

Qwen3.6-Plus 综合最优 • Gemini 3.1 Pro 识别和提取最强 • Kimi K2.5 解析和问答最强

结论:

即便是 SOTA 模型，在真实企业场景中的文档处理能力仍不够理想 — Grounding 对可审计、可追溯的高可信应用尤为关键

PART 03 1 GRANULAR


CC-OCR V2 • 文档类型细粒度分析

③

文档类型差异巨大

Receipt & 手写最难

Distribution of Document Types



十类文档表现对比

✓ 最易类别

Books / Reports → 规则布局、清晰文字模式

✗ 最难类别

Receipts • Handwriting

密集布局 / 小字体 / 低质量 • 书写风格巨变

关键主张

平均分掩盖弱点，细粒度评测揭示部署风险

Model	Document Categories										Average
	Books	Reports	Marketing	Legal	Forms	Receipts	Medical	Handwrit.	Charts	Screens	
On-Device LMMs											
 Step3-VL-10B	54.65	68.82	73.03	67.32	51.66	37.26	59.51	42.11	62.29	63.63	58.03
 InternVL3.5-8B	62.68	81.45	74.19	72.17	53.34	39.70	51.69	55.43	65.52	65.04	62.12
 MiniCPM-o 4.5-8B	73.38	79.24	81.48	71.52	51.66	35.85	57.24	55.61	71.11	46.72	62.38
 Qwen3.5-9B	82.66	79.46	82.05	78.52	68.27	61.80	78.62	63.72	77.84	72.47	74.54
On-Server LMMs											
 GPT-5.4	73.31	81.30	75.09	72.65	53.51	43.19	39.58	62.37	76.12	77.72	65.48
 Qwen-VL-Max	80.54	81.25	78.91	71.97	53.37	39.10	42.18	63.72	77.06	71.21	65.93
 Claude Sonnet 4.6	80.09	81.10	78.53	73.76	54.57	42.57	52.72	61.60	77.84	79.42	68.22
 Claude Opus 4.6	79.32	82.66	79.60	75.97	54.71	41.46	58.76	57.08	74.76	79.27	68.36
 Gemini 3.1 Flash	87.89	81.60	77.33	76.43	57.19	44.48	71.71	67.33	73.29	70.18	70.74
 Kimi K2.5	86.61	86.26	87.05	77.05	55.99	44.30	56.52	71.06	85.88	80.59	73.13
 Kimi K2.6	85.34	<u>85.42</u>	<u>86.52</u>	78.44	60.68	48.57	56.22	70.34	<u>84.54</u>	78.19	73.43
 Gemini 3.1 Pro	<u>87.77</u>	83.05	81.61	78.66	66.94	58.12	79.22	<u>72.57</u>	80.38	84.87	77.32
 Seed 2.0 Pro	87.38	84.39	81.11	79.01	74.31	61.61	74.21	73.11	80.38	80.70	77.62
 Qwen3.5-Plus	85.35	84.79	83.85	<u>80.16</u>	<u>77.15</u>	<u>65.32</u>	<u>75.90</u>	67.51	81.53	<u>84.03</u>	<u>78.56</u>
 Qwen3.6-Plus	86.36	83.09	84.55	81.71	80.01	67.92	73.89	67.25	83.30	82.20	79.03

PART 03 2 MMM BENCH 1

多模态多层级细粒度文档分类

五层层级分类体系

L1 Business Function 业务功能

L2 Business Object 业务对象

L3 Business Stage 业务阶段

L4 Business Form 业务形态

L5 Document Class 文档类别

与阿里企业域业务团队共建 · 反映真实业务组织逻辑

数据概览

5,990

真实文档

12

业务域

5

层级深度

与现有分类 Benchmark 对比

BENCHMARK	层级	多域	多模态
RVL CDIP	平坦	×	部分
DOCLAYNET	平坦	×	✓
WIKISECTION	2 级	×	×
MMM BENCH	5 级	✓	✓

★ 首个同时具备深度层级 + 多域覆盖 + 多模态内容的文档分类 Benchmark

PART 03 2 MMM BENCH

自适应文档分类体系拓展算法

层级树自适应拓展算法


STAGE 1 输入 & 初始化



STAGE 2 分类 (第1轮) → 文档分配到节点

LLM 将每份文档路由到对应叶子节点
密度检查: 合同类 $p=4 >$ 阈值3 → 触发深度扩展 未覆盖 $p=1$ → 触发宽度扩展

STAGE 3 扩展 → 深度扩展 + 宽度扩展



→ 重新入队 BFS 继续下一层

STAGE 4 后处理: 先扩展后修剪



例: 合同类(非叶子) → node_kv_schema:
("合同编号": "", "签约方": "甲", "金额": "", "签署日期": "")

输出



层级树拓展流程示例

STAGE 1 粗粒度骨架



STAGE 2 文档分配节点




密度检查: 合同类 $p=4 >$ 阈值3

STAGE 3 扩展后的树




STAGE 4 后处理: Schema 生成示例



最终分类树 (含Schema)



企业域文档分类树



PART 03 2 CHALLENGES

MMM-Bench • 四大核心挑战

1 细粒度语义区分困难

准确率随层级递降


L1: 95% → L5: 60 70%

Model	Accuracy @ Level (%)					Macro-F1 @ Level (%)					HF1
	L1	L2	L3	L4	L5	L1	L2	L3	L4	L5	
Weights Models											
Qwen2.5-VL-7B	65.78	23.25	5.61	0.00	0.00	47.03	18.75	6.39	0.00	0.00	6.66
Qwen2.5-VL-8B	68.78	30.53	11.90	12.75	0.00	49.87	37.63	11.26	14.51	0.00	14.40
Qwen2.5-VL-8B	89.11	66.32	41.75	39.22	13.33	79.80	67.09	41.02	38.82	20.00	38.69
Qwen2.5-VL-8B	93.40	77.19	57.91	57.84	53.33	82.18	76.10	56.88	57.74	50.00	51.75
Qwen2.5-VL-8B-A3B	91.68	72.19	50.62	49.02	53.33	80.33	70.40	49.53	51.89	45.38	
API Models											
Claude-Opus-4.5	95.63	82.98	71.04	77.45	80.00	84.39	79.67	69.74	77.13	75.00	61.59
Claude-Opus-4.6	95.11	83.77	74.07	71.57	86.67	84.07	81.89	73.23	71.40	87.50	64.01
GPT-5.2	94.00	78.07	62.18	69.61	93.33	83.27	75.97	60.59	68.16	95.00	54.35
GPT-5.4	94.60	80.18	64.42	75.49	86.67	85.98	78.11	62.00	75.10	87.50	55.85
Qwen2.5-VL-235B-A22B	91.51	71.14	52.19	57.84	20.00	85.00	71.83	51.99	57.53	21.43	48.13
Qwen2.5-VL-235B-A22B	89.02	76.84	63.08	60.78	26.67	82.32	77.38	64.51	63.96	36.67	58.26
Gemini-1.1-Pro-Preview	95.80	85.51	72.22	80.39	80.00	86.10	79.94	75.91	80.14	75.00	64.98
MiniMax-M2.7	92.37	76.4	56.23	49.02	20.00	81.30	76.14	58.54	48.62	26.67	51.36
GLM-5	73.24	67.19	60.72	49.02	13.33	77.81	74.23	63.95	56.23	20.00	54.67
Kimi-K2.5	94.08	79.21	65.32	53.92	46.67	84.04	76.62	64.59	53.27	51.67	57.06

2 领域敏感

结构化域强 / 非结构化域弱

LEGAL 最优 → MARKETING 最差



3 模态融合瓶颈

纯文本 > 文本+图像+布局

全模态融合能力不足

Model	Text	Image	Layout	L1	L2	L3	L4	L5	HF1
Qwen2.5-VL-7B-SFT	✓	✓	✓	91.27	89.05	86.69	93.58	96.43	83.98
	✓	✓	✓	84.96	87.15	85.70	80.62	87.86	81.21
	✓	✓	✓	81.43	73.78	69.06	90.37	86.67	68.50
	✓	✓	✓	89.73	93.37	92.41	95.03	95.00	88.46
	✓	✓	✓	97.36	96.27	94.85	97.52	87.50	93.20
Qwen2.5-VL-8B-SFT	✓	✓	✓	92.17	91.18	90.16	90.76	96.43	86.80
	✓	✓	✓	85.78	88.73	88.73	81.15	83.10	84.04
	✓	✓	✓	92.05	84.71	79.27	92.18	95.00	78.52
	✓	✓	✓	92.93	95.08	95.06	97.74	95.00	92.74
	✓	✓	✓	98.44	96.39	95.66	99.17	95.00	94.17
Qwen2.5-VL-8B-SFT	✓	✓	✓	91.62	92.17	89.37	93.75	96.43	86.79
	✓	✓	✓	88.28	87.04	86.13	88.35	92.86	82.86
	✓	✓	✓	89.63	86.86	81.56	90.28	80.36	79.28
	✓	✓	✓	94.80	92.07	90.46	91.08	95.00	88.03
	✓	✓	✓	95.07	94.94	94.68	96.15	100.00	92.88

4 样本分布不均衡

长尾分布拖累整体表现

头部 92.1% → 尾部 60.2%

Class Group	Condition	Avg. Samples	Macro-F1
Head	$n \geq 500$	1,368	92.1%
Middle	$100 \leq n < 500$	358	87.7%
Tail	$n < 100$	54	60.2%

PART 03 3 PARADIGM


Schema-Guided 统一评测范式

传统 KIE 评测

逐字段问答式，每个字段独立推理 • 无法捕捉字段间结构关系 • 效率低

Our Schema-Guided 评测

给定图像 + 抽取
Schema，一次推理输出
完整结构化键值对；支
持跨场景统一评测



统一任务定义

文档图像 x

+

抽取 Schema s



$$y = M(x, s)$$

输出：结构化键值对（一次推理完成全部字段抽取）

STRUCTURED

ONE SHOT

CROSS SCENE

PART 03 3 UNIKIE BENCH 1


开放域文档信息抽取 Benchmark

Two Complementary Tracks

CONSTRAINED CATEGORY

场景预定义 Schema

反映实际应用中的字段抽取需求




4,472 文档
3 领域
11 场景

OPEN CATEGORY

KIE

每条文档独立 Schema • 无场景假设

要求抽取文档中所有显式关键信息



1,661 文档
4 类型
2 语言

与现有 KIE Benchmark 对比

Benchmark	LMM-Ready	Track		Taxonomy		Size
		Constrained	Open	#Domains	#Scenarios	
OCRBench (Liu et al., 2024c)	✓	✓	✗	—	3	200
DocILE (Šimsa et al., 2023)	✗	✓	✗	1	—	600
OCRBenchV2 (Fu et al., 2025)	✓	✓	✗	—	6	800
RealKIE (Townsend et al., 2024)	✗	✓	✗	1	5	1,867
CC-OCR (Yang et al., 2025)	✓	✓	✓	—	6	2,008
UniKIE-BENCH	✓	✓	✓	3	11	6,133

3

领域

11

场景

6133

样本

★ 业界首个同时支持约束类别与开放类别 KIE 的统一评测基准（规模扩大 3×）

PART 03 3 FINDINGS

UniKIE-Bench • 实验分析

① Close-Category

Method	Business Transactions				Public Services				Regulated Records			Avg.
	Ret.	Cat.	Com.	Acco.	Post.	Admi.	Edu.	Adv.	Tax.	Med.	Nut.	
Close-source LMMs												
Claude-Sonnet-4.5	69.24	73.65	45.92	69.29	79.45	69.20	39.46	85.06	67.79	63.96	67.24	66.39
GPT-4o	75.79	79.33	49.67	67.86	82.95	64.26	47.77	73.56	75.33	67.57	76.51	69.15
GPT-5	71.90	71.33	45.94	69.29	80.95	62.79	50.26	75.48	72.05	67.71	75.83	67.59
Qwen-VL-Max	86.67	84.68	49.33	76.07	84.85	79.96	82.46	82.76	77.94	75.62	75.14	77.77
Qwen3-VL-Plus	89.12	86.45	50.57	77.86	83.55	78.91	87.44	83.14	78.93	76.46	89.72	80.20
Gemini-3-Pro	89.27	83.54	53.87	81.43	90.74	84.32	80.71	90.54	81.54	77.60	92.47	82.37
Open-source LMMs												
SmolVLM2-2.2B	17.80	57.22	28.52	18.92	34.98	8.63	3.87	27.16	34.97	18.00	10.51	23.69
Gemma-3-12B	54.32	68.73	30.68	53.93	72.30	37.14	17.56	36.78	56.81	48.54	52.20	48.09
InternVL3.5-8B	77.23	72.23	41.64	67.14	73.90	72.10	63.08	73.08	72.81	65.94	65.53	67.70
Ministral-3-8B	6.47	57.01	26.24	43.39	75.80	32.37	29.54	19.53	65.85	51.46	6.17	37.62
MiniCPM-V4.5-8B	68.37	74.91	45.91	67.76	83.60	71.89	63.21	79.31	69.57	70.00	44.18	67.15
GLM-4.1V-9B	62.32	77.33	46.67	76.43	76.46	78.75	65.83	81.99	70.68	72.08	60.47	69.91
Kimi-VL-A3B	86.49	63.12	42.87	61.79	83.40	68.72	80.37	72.41	77.80	64.93	25.72	66.14
MiMo-VL-7B-RL	77.45	77.66	49.01	67.50	76.70	76.81	76.65	66.28	74.86	68.70	46.10	68.88
Qwen3-VL-8B	88.26	86.23	51.14	71.07	83.80	78.90	87.39	81.23	78.74	77.19	86.36	79.12

② Open-Category

Method	Chinese				English				Avg.
	Receipt	Form	Invoice	Contract	Receipt	Form	Invoice	Contract	
Closed-source LMMs									
Claude-Sonnet-4.5	37.59	31.20	29.12	20.88	41.64	49.22	44.18	63.87	39.71
GPT-4o	39.66	30.82	35.31	16.67	78.51	48.09	57.08	67.35	46.69
GPT-5	39.61	31.97	37.64	17.47	80.64	50.09	57.50	64.24	47.39
Qwen-VL-Max	69.94	69.75	66.62	69.68	70.76	65.52	70.80	76.57	69.95
Qwen3-VL-Plus	71.14	69.87	69.59	70.95	68.27	66.82	73.45	74.81	70.61
Gemini-3-Pro	78.50	79.17	78.63	75.96	93.57	80.41	87.06	79.90	81.65
Open-source LMMs									
SmolVLM2-2.2B	5.74	1.51	3.05	2.15	36.49	11.64	19.73	22.36	12.83
Gemma-3-12B	25.71	14.17	17.36	9.42	76.24	38.32	30.23	35.77	30.90
InternVL3.5-8B	54.26	37.83	40.97	39.43	79.46	43.64	49.41	50.06	49.38
Ministral-3-8B	25.21	35.80	24.42	26.18	58.54	49.01	55.66	57.82	41.58
MiniCPM-V4.5-8B	52.33	42.69	44.54	39.46	72.41	47.46	56.44	65.49	52.60
GLM-4.1V-9B	55.19	56.63	55.52	54.68	63.83	54.66	59.31	68.70	58.56
Kimi-VL-A3B	62.98	52.85	50.72	54.94	73.91	55.96	52.67	64.64	58.58
MiMo-VL-7B-RL	57.63	56.60	51.93	65.90	71.34	52.83	57.64	70.55	60.55
Qwen3-VL-8B	68.93	64.70	63.38	65.59	71.40	61.46	67.34	76.08	67.36

闭源和开源模型之间仍存在明显差距，Open-Category Track上 最好闭源模型Gemini-3-Pro在取得81.65分，而最佳开源模型Qwen3-VL-8B为67.36


不同文档类型的难度差异巨大。Form类文档由于碎片化布局和灵活的字段边界，成为所有模型最头疼的类型；而Receipt类文档由于布局规则、键值明确，表现最好。

跨语言鲁棒性仍是关键挑战。几乎所有模型在英文文档上的表现显著优于中文文档，这与视觉语言预训练中英语数据的优势分布密切相关。

PART 03 3 ANALYSIS

UniKIE-Bench • Faithfulness 与错误分析

F1 与 Faithfulness 相关性



更高的 F1 通常伴随更高的忠实度，但相近忠实度下 F1 差异仍可能显著


三类典型错误模式

①

视觉感知失败

如 2.32 → 4.32 数字混淆

OCR 基础识别不足




②

布局感知失败

字段与空间区域错误关联

识对文字但关联错区域




③

语义理解失败

面对复杂 Schema 字段语义混淆

字段语义边界模糊




看到 ≠ 理解 • 感知 → 布局 → 语义 三级能力共同决定最终 F1


PART 03 4 DOCScope 1

DocScope • 长文档可验证推理问答

任务定义



数据构建



1,124 questions from 273 documents
average 51.3 pages per document

首个要求模型输出完整可验证推理轨迹的长文档问答基准

PART 03 4 CHALLENGES

DocScope • 可验证推理的实验分析

① 答案准确率 ≠ 推理可信度

答案对但过程错, >70% “答对”并未真正理解文档

② 跨页远距离证据聚合困难


关键证据分散时, 跨页聚合对所有模型极具挑战

③ "为文档专门设计" ≠ "表现更好"

通用大模型的基础视觉-语言能力仍是当前天花板

Evidence-chain status	Ratio
Complete	29.06%
Completely unreliable	19.02%
Partially reliable	51.92%

即便答案正确, 完整证据链
最高通过率仅 29%



真正让文档问答变难的, 是
证据的"散布方式", 而不是
文档有多长

Model	Params			Page Localization			Region Grounding			Fact			ACC		
	Total	Act.	P	F1	Strict F1	Loose F1	F1	Cons.	Ans.	Unans.	Ans.	Unans.	Ans.	Unans.	Ans.
Proprietary Models															
Gemini 1.5 Pro [Google DeepMind, 2024]	-	804	82.1	87.4	50.7	58.9	68.7	78.1	75.1	78.9	-	-	-	-	-
Gemini 1.5 Flash [Google DeepMind, 2024]	-	804	82.1	87.4	50.7	58.9	68.7	78.1	75.1	78.9	-	-	-	-	-
Claude-3.5-Sonnet [Anthropic, 2024]	-	83.9	88.2	89.0	42.9	51.0	77.4	76.2	69.4	70.0	-	-	-	-	-
Claude-3.5-Sonnet [Anthropic, 2024]	-	79.9	88.1	89.0	42.9	51.0	77.4	76.2	69.4	70.0	-	-	-	-	-
GPT-4.5 [OpenAI, 2024]	-	85.6	72.4	78.0	87.4	71.9	59.4	64.0	64.0	62.1	-	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	-	73.5	85.4	78.0	70.6	42.5	66.4	67.0	65.1	66.6	-	-	-	-	-
Open-source Models															
Llama 3.3 Pro [Meta et al., 2024]	171	728	72.7	8.9	11.0	16.0	20.7	18.8	34.4	42.9	34.9	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	307B	178	78.3	70.4	54.1	24.3	48.8	35.7	61.0	73.1	61.0	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	171B	108	70.1	42.2	30.1	26.2	42.4	27.4	40.1	77.1	63.6	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	72B	72	76.8	6.1	8.1	10.1	20.1	18.1	31.1	41.1	31.1	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	270B	228	81.8	77.0	72.1	21.2	47.7	34.4	49.0	80.0	71.4	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	128	128	80.1	68.0	68.1	16.7	48.0	51.0	67.1	67.1	67.1	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	308	18	50.1	48.1	48.1	24.6	44.1	25.1	31.1	71.1	34.1	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	88	88	21.1	21.1	21.1	21.1	21.1	21.1	21.1	21.1	21.1	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	118	118	11.1	11.1	11.1	11.1	11.1	11.1	11.1	11.1	11.1	-	-	-	-
Gemini 1.5 Pro [Google DeepMind, 2024]	248	48	50.1	61.1	56.1	7.5	9.5	27.1	30.1	83.1	34.1	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	148	148	10.1	10.1	10.1	10.1	10.1	10.1	10.1	10.1	10.1	-	-	-	-
Qwen2.5-72B [Qwen Team, 2024]	88	88	70.4	42.1	51.0	14.6	34.1	44.1	36.1	34.1	36.1	-	-	-	-
Document Understanding Frameworks (Agentic RAG)															
SingleDoc [Bai et al., 2023]	-	-	-	-	-	-	-	-	51.2	40.8	50.1	-	-	-	-
ViDoc [Bai et al., 2023]	-	-	-	-	-	-	-	-	22.1	9.1	21.1	-	-	-	-
Document Understanding Specific Models (DUE)															
ViDoc [Bai et al., 2024]	88	88	-	-	-	-	-	-	13.1	24.1	14.1	-	-	-	-
DocScope [Bai et al., 2024]	88	88	-	-	-	-	-	-	6.7	20.1	7.1	-	-	-	-
DocScope [Bai et al., 2024]	70	70	-	-	-	-	-	-	4.1	40.1	4.1	-	-	-	-

开源模型在长文档可验证推理上已具备竞争力, 但
与闭源模型的差距集中在精确空间定位和事实忠实
提取两个阶段

长文档理解需要轨迹级评测, 而非仅靠答案正确率

PART

04

未来规划和总结

从评测标尺，走向方向的灯塔

● — ● — ● — ● — ROADMAP →

SUMMARY

总结 • 评测驱动进步

好的 Benchmark 不仅是标尺，
更是方向的灯塔。

01

方法论

全域覆盖 • 分层建模 • 统一任务范式

02

数据构建

真实数据 + 困难样本 + SAYRE 场景感知合成

03

开源成果

4 个 Benchmark + 统一评测框架 + 完整实验分析

★ 所有数据与评测工具均已开源

UNIKIE BENCH

MMM BENCH

CC OCR V2

DOCScope

PART 04 ROADMAP

未来规划 · 四大方向

评测维度扩展

多页文档 / 表格嵌套 / 跨文档推理, SAYRE 迭代升级, 突破手写文档和
挑战更复杂企业场景



STEP 1

数据合成增强

SAYRE 迭代升级, 突破手写文档和
混合模态文档合成能力



STEP 2

评测平台化

在线评测平台, 一键式模型评
测 · 自动化报告 · 动态
Leaderboard



STEP 3

学术生态建设

联合业界共同制定评测标准, 推动
开源共建



STEP 4

长期愿景

让文档智能评测像 ImageNet / GLUE 一样, 成为行业公认的能力标尺, 驱动模型持续进步

Thank *You.*

Questions & Discussions