

超越 Benchmark 从Coding Agent到通用Agent的 专家在环评测

王冲 | 一面千识 技术 VP

目录

CONTENT

01 为什么 Benchmark 还不够

02 专家在环的交互式评估

03 从 Coding Agent 到通用 Agent

04 Expert Evals as a Service

自我介绍

王冲



一面千识 · 技术 VP

负责 Expert Evals 团队与前沿 Benchmark 探索

蚂蚁集团
技术专家

掌阅科技
前端负责人

一面千识
技术 VP · 现在



从真实评测现场出发，
判断 Agent 能不能做成事、能不能协作、结果是否值得信任。

真实项目里的 Agent 评测实践

服务过的产品



豆包

服务过的模型



Seed



评测实践数据

50+

累计评估期数

7

评分维度

1300+

参与评估专家数

4. 28h

单题评估平均耗时

01

为什么 Benchmark 还不够


Why Benchmarks Fall Short

为什么 Benchmark 还不够

公开 Benchmark

榜单分数持续提高

可量化 · 可追踪 · 可复现



不是谁对谁错
而是**衡量对象不同**

真实使用

信任与采用意愿没有等比例提高



01 题目不同

02 成功标准不同

03 工作方式不同

题目不同：真实Agent还要先把题目搞清楚

Benchmark

题目已经定义好

目标明确 · 条件固定 · 标准预设



开始解题

真实工作



只有一个目标



理解语境

背景信息？
相关干系人？
历史情况？



补齐信息

缺什么？
从哪里找？
如何验证？



确认约束与成功标准

有哪些约束？
成功的标准是什么？
如何衡量？



开始执行

制定计划
分解任务
推进落地

赢的标准不同：通过判定不等于真正解决问题



自动化检查

有没有

测试 · 格式 · 关键字段

专业判断


好不好 · 靠不靠谱 · 敢不敢用

方案 · 证据 · 风险 · 采用意愿

通过只是最低门槛，真正解决问题才值得采用

工作方式不同：一次作答vs持续协作与收敛

第一次独立作答



专业反馈



01 听不听得懂

02 能不能改对

03 要花多少轮

交互轮次 · 额外提示

Benchmark 看第一次能不能做对；真实工作还要看它能不能在协作中做成

02


我们的方案：专家在环的交互式评估

Our Method: Expert-in-the-Loop Interactive Evaluation

专家在环的交互式评估

Benchmark


一次性、跑完即止



VS

专家在环 *Expert in the loop*

多轮协作 · 收敛即止



一个真实的项目案例

一次模型在 Coding GSB评估项目

* 评估过程中会对模型进行匿名处理，模型代称A、B、C、D

126

真实评测题目

4

评估模型数

7


评估维度

38

参与评估专家人数


从真实研发场景出发

本期评估构成



最贴近日常场景的0-1 生成、Feature 迭代、Bug 修复三类合计占比70%+
90%的题目涉及多文件改动，近一半需要跨模块甚至跨系统协同；

模型多维能力画像



真实七维分值

分值 1 - 5 · 图中刻度 3.0 - 4.5

- 模型 A
- 模型 B
- 模型 C
- 模型 D

A > B > C > D

共同强项 架构边界

4.05 - 4.33 · 分差 0.28

最大分差 用户体验

3.13 - 3.88 · 分差 0.75

谁在哪一维度更强

	交付完整性	指令遵从	任务规划	语义理解	工程质量	用户体验	架构边界
模型 A	3.99	4.10	4.03	4.02	3.95	3.88	4.33
模型 B	3.80	3.98	3.87	3.80	3.72	3.82	4.19
模型 C	3.78	3.87	3.63	3.56	3.60	3.48	4.17
模型 D	3.53	3.68	3.52	3.47	3.40	3.13	4.05

最大差距出现在**用户体验：0.75 分**

模型 A 3.88 vs 模型 D 3.13

两两对战：胜率与画像互相印证

让B模型与 A、C、D模型分别对比并打分

* 其中A模型是国外SOTA模型、B模型是用户模型、CD是国内竞品模型

每组 126 场

模型 B vs 模型 A

模型 B 48%

模型 A 52%

模型 B vs 模型 C

模型 B 62%

模型 C 38%

模型 B vs 模型 D

模型 B 68%

模型 D 32%

对 C、D 胜率均超过六成

与模型 A 接近，仅相差 4 个百分点

专家准入靠证据，后续治理看表现

01 招募

多源招募

02 面试

AI 面试

03 匹配

匹配判别

04 评级

动态评级

05 准入


项目准入



入口看能力匹配，入项后看持续表现

一条数据的质检流程

AI 自动校验



专家质检 + 题目评定

质检专家审核



专家交叉审核

01 题目评分

02 专家优劣标签

03 机审反馈

数据
交付

发现问题 → 返回对应环节

● AI 自动校验 ● 专家提交与互审 ← 不通过返回

每一次机检和互审，都让最终交付更可信

同一起点，同一尺度，结果才可信

标准化 Docker 环境



专家连接 · 正在运行的容器

保证公平 · 可复现

- 统一镜像
- 相同初始态
- 无 Git 历史与参考答案
- 隐藏测试独立注入
- VS Code 实时观测
过程可见 · 产物可验



标准化评分表

维度	1	2	3	4	5	证据
🔍	○	○	○	○	○	—
🔍	○	○	○	○	○	—
🔍	○	○	○	○	○	—
🔍	○	○	○	○	○	—
🔍	○	○	○	○	○	—

- 统一维度
- 明确分档锚点
- 证据记录
- 一致打分

保证准确 · 可比较

环境锁定起点，评分表锁定尺度

公平

准确

可复现

可审计

03

从Coding Agent到通用Agent

From Coding Agents to General Agents

系统把主观判断变成有标准、有证据的共识

评测标准化流程



不是消除主观判断, 而是让判断有标准、有证据、能交叉验证

每一份专家交付都有一份可追溯的质量报告

文件基础校验服务



沉淀为可复用的基础服务

统一文件解析


规则引擎

证据记录

异常定位

系统负责可规则化的检查，专家负责真正需要**专业判断**的部分

专家池的价值，是持续为任务找到真正懂行的人



更深的专家池 → 更严格的筛选 → 更精准的匹配

04

Expert Evals As A Service

标准底座保证专业交付，可选模块按需裁剪

服务配置



标准底座 | 每个项目默认包含

专家匹配

任务设计

结构化 Rubric

独立评审

过程质检

证据记录

多维评估

不从零搭建：底座复用，模块按需组合

同一套服务，可以为不同目标重新组合

三种典型组合

模型选型

能力对照

Majority Vote

多维画像



选出更适合真实任务的模型

版本迭代

新版模型准入门槛

跨版本追踪

失误归因



看清进步发生在哪里

训练改进

结构化评分标准

轨迹与证据

Golden Solution



转化为训练与奖励信号

可裁剪的不是专业标准，而是围绕目标的服务组合

让真正懂任务的人回到评测回路，
我们才能知道 Agent 是否真的胜任

王冲 | 一面千识 技术 VP