

从“能跑”到“可信”

AI 评测驱动 AI Agent 自迭代

1688 Agent 自动化评测实践

寇宏达

阿里巴巴淘天集团 · 1688-AI评测负责人

10+ 年数据科学 | B2B · 近场电商 · 金融风险

AI + 数据 workflow 改造 | AI 应用 Agent 评测体系

TWO LOOPS · ONE TRUSTED ITERATION

业务 Agent 自动化评测

提效

● 真实任务 → ● 可信判定 → ● 问题改进 → ● 回归准出

持续迭代 · 每次改进都回到验证

评测系统持续提准

提准

● 报告自检 → ● 偏差检测 → ● 复审修正 → ● 历史验证

持续迭代 · 每次改进都回到验证

两条主线并行：一边支撑业务迭代，一边保证结论可信

评测系统自己，也需要被评测。

三种评测，解决的是三类不同问题

从确定逻辑，到模型通用能力，再到真实任务中的复杂系统

01 传统软件测试

被测对象	代码与确定逻辑
核心问题	功能是否正确，改动是否回归
常用方法	单测 / 集成测试 / Assert
典型输出	Pass / Fail、缺陷定位

02 AI 基模评测

被测对象	模型的通用能力
核心问题	知识、推理、安全与鲁棒性
常用方法	Benchmark / 题集 / 模型对比
典型输出	能力分数、排名与能力边界

本次重点

03 AI 应用 / Agent 评测

被测对象	模型 + Prompt + 工具 + 数据 + 环境 + 交互
核心问题	真实任务能否稳定完成
常用方法	重复运行 / Trace / Outcome 线上日志 + 离线黄金集
典型输出	可信判定、根因、准出与改进

● 样本与分析

代表性采样 / 版本对照
结果波动、切片归因与置信判断

● 评测工程

数据集 / SOP / 环境
Trace 与 Outcome 证据

● Judge 工程

Rubric / 规则 / LLM Judge
校准、复审与偏差治理

● Agent 工程

评测 Skill / 工具调用
自动编排、Loop 与回归

Agent 评测评的不是一个模型，而是一套在真实任务中运行的系统。

一条电商任务，可能在6个地方“看起来成功”

从用户意图到最终交付，是一条长链而不是一次问答

用户要求寻找符合泰国标准的插座



真实坏例：召回含“通用孔 / 万能孔”的商品，用户连续多轮纠错仍未收敛。

任务确实返回商品，但强属性约束、纠错收敛和最终交付同时失败。

Agent 评测不能只看答案：还要看任务、重复运行、轨迹与结果

Task × Trial × Trace × Outcome, 把非确定性变成可测量对象

工业化评测单元

同一真实任务：重复运行 → 保留完整轨迹 → 核验真实环境结果

一次结果只是样本



从“一次答对”转向“多次稳定、过程可证、结果真实”。

第一版评测集很“干净”，也因此不够真实

离线固定集解决回归，线上日志负责发现未知问题

离线固定测试集

优势

- 条件可控、版本可比
- 适合回归与准出
- Badcase 可长期沉淀

盲区

输入太规整，覆盖不了真实分布；
甚至可能出现泄题、矛盾和映射错位。

线上真实日志

发现

- 用户真正高频的任务
- 系统无响应、额度、限流
- 多轮纠错与新增需求信号

挑战

日志缺失、版本混杂、无标准意图，
需要先做意图识别、筛选和可评测化。

不是二选一：固定集回答“改动有没有退化”，线上日志回答“用户到底遇到了什么”。

首次线上真实日志分析，问题不只在模型

6月线上日志抽样：从真实分布反推评测与产品改进

878

用户 Session

覆盖真实使用而非脚本仿真

946

意图单元

一个 Session 可包含多个意图

288

有效抽样阅卷

聚焦主力版本和已有标准

64.2

整体均分

完全完成率仅 42.4%

未满分案例的主要根因

Agent 无响应



38%

积分 / 额度异常




22.2%

交付关键内容缺失



22.2%

系统执行报错



9.5%

71.6% 的问题首先来自系统与基础设施；模型能力只是其中一层。

评测的真正断层，在报告之后

发现问题 → 驱动修复 → 验证改进，三步缺一不可

人驱动协同

能力已经存在，但每一步都要等人发起



自动化串联

把同一能力链编排起来，让结果直接进入下一步



评测能出报告 ≠ 能驱动迭代；只有改进被验证，闭环才真正成立。

双轨评测让 Agent 持续变可信：一条 SOP，四个技术关口

离线黄金集守住已知质量，线上真实日志发现未知问题；两类证据汇入同一改进闭环

两类评测方式 一个守住已知质量，一个持续发现未知问题



标准 SOP 两类输入进入同一条工程链路

人工把关：标准确认 · 异常复核 · 发布决策



SOP 之上：4 个持续技术关口 流程可以自动串联，但可信度必须长期治理



业务 Agent：线上发现 → 修复 → 离线回归 → 线上观察

评测系统：自检 / 偏差 → 修正 Rubric & Judge → 历史 Case 验证

先定义“完成”，再定义“优秀”

把可发布判断拆成两个独立门槛

准出 = 执行完整率 $\geq 90\%$ AND 端到端结果分 ≥ 80

门槛 1

执行完整率

必经步骤是否完成？
工具是否真的调用？
任务是否中断或被兜底掩盖？

门槛 2

端到端结果分

结果完整性 + 结果有效性
有没有给全？能不能直接用？
数据、计算、逻辑是否可信？

双门槛避免“结果写得漂亮，但关键步骤根本没执行”的假通过。

“结果合理”不是标准，机器无法执行模糊共识

把业务语言改写成检查项、通过条件、证据和门控

差的写法

“推荐结果合理，报告完整。”

问题

- 不知道检查哪些字段
- 不知道多严重算失败
- 无法从轨迹找到证据
- 同一 Judge 会自由发挥

可执行的契约

检查项

推荐商品 ≥ 5 条且不重复

通过条件

国别标准属性必须命中

证据

引用轨迹原文 / 工具返回 / 交付字段

严重度

核心项 / 一般项 / 加分项

门控

强约束不满足 $\rightarrow$ 总分直接不通过

Rubric 的价值不是“描述更详细”，而是让判定可复现、可审计、可回归。

确定性长链任务：固定 Rubric 像一张“飞行检查单”

适合采购、跟单、补货、经营分析等有明确 SOP 的任务



同一条轨迹被三类检查同时复用

执行完整性

必经步骤 / 工具 / 状态

输出完整性

字段 / 表格 / 章节

内容有效性

事实 / 计算 / 逻辑 / 合规

固定 Rubric 的核心不是“固定答案”，而是固定必须发生的业务事实。

开放式任务：一把固定尺子，会把“具体需求”磨平

为每个输入生成实例级检查清单，再用统一规则聚合

固定 Rubric

适合：确定性链路

- 必经步骤明确
- 字段和终态可枚举
- 同类任务共享检查单

例：采购必须完成
找品 → 过滤 → 询盘 → 交付

实例级动态 Rubric

Query：夏日冲锋衣

红线

类目不能偏离；关键信息不得编造

重要

轻薄 / 透气 / 夏季适用证据充分

重要

防风防泼水与目标场景匹配

加分

给出清晰选购建议与取舍

动态生成“评什么”；规则引擎仍决定“怎么算”。

两类能力并行：确定性任务守住流程，开放式任务尊重实例差异。

多模态评测不能只看总分：整体 7/9，位置识别仍然可以是 0

同一张肖像图，整体准确率 77.8%；能力切片后，位置关系识别为 0/1

真实案例

77.8%

9 个问题 · 答对 7 个



总体看起来 “还不错”

模型描述覆盖了人物、物体、动作
和场景的大部分信息

一切片，盲区就暴露

总分相同，不代表关键能力相同

对象计数		2 / 2	100%
对象识别 / 动作		3 / 3	100%
场景主旨		1 / 1	100%
对象属性		1 / 2	50%
对象位置		0 / 1	0%

位置关系没有被识别出来，却被总体准确率稀释了。

动态 Rubric：按任务生成对象 / 属性 / 数量 / 动作 / 位置检查项，并对关键维度单独门控。

Judge 可信的前提：每个结论都能穿透到原始证据

Observation → Analysis → Conclusion



示例

观察：工具返回的商品属性为“万能孔”，用户已明确要求“泰规”。


分析：强属性约束未命中，且用户连续纠错后仍未收敛。

结论：意图理解偏差 + 数据过滤缺失，门控失败。

LLM 负责“看懂证据”，规则引擎负责“计算分数”；模型不能同时当裁判和计分员。

机器阅卷不是终点：业务问题修 Agent，评测问题修标准

报告先分流，再把评测偏差变成下一版 Rubric、Judge、规则与数据集



业务侧确认问题是否真实；评测侧保证结论可信，并验证修改真的有效。

我们扫描了 900 条 Verdict 记录, Judge 的“偷懒”有固定模式

260 个文件 · 10,026 个判项的早期全量扫描

56.7%

Fail 证据弱

短于 20 字符或缺轨迹锚点

46.4%

Pass 走过场

大量使用“前置未触发”

4.7%

同 Case 分差 ≥ 30

跨会话一致性不稳定

1.7%

分数与扣分不一致

LLM 还会算错加减法

根因不是“模型突然变笨”

单次 Prompt 判太多项 → 后半段注意力衰减

证据格式宽松 → seq=3 也能过

模型同时判定和算分 → 错误没有确定性兜底

评测自动化的最大风险：把人工不一致，规模化成机器不一致。

防幻觉 / 防偷懒：把“纪律”写进运行时，而不是只写进 Prompt

G1

证据强度

短证据自动重判

G2

反证原则

无反证不允许 Fail

G3

模板化检测

理由雷同整条重判

G4

过度跳过

Pass 率异常触发复审

G5

分数重算

规则引擎重新计分

G6

方差裁决

跨会话差异触发仲裁

G7

数值对账

Python / 规则计算优先

输入侧：微批次 + 顺序随机化 | 输出侧：证据三段论 + 单项重试

能用确定性规则解决的，绝不再问一次大模型。

复审 Skill 让 Judge 不再“一次判定”

Worker 先判，Checker 复核；只对异常项有限重判，把人审留给真正的分歧



Recheck Loop: 检测异常，不等于无限重跑

单条异常 → 同标签子集定向重判

批次异常 → 整批最多重判一次

仍不确定 → 小样本人工仲裁

验证未通过就记录原因，下一轮从经验 Memory 继续，而不是让人重新从头盯一遍。

已落地

逐条隔离 · 原文证据 · 分数重算 · 一致性审计

推进中

自动复审 · 有限重判 · 跨轮 Memory 与经验复用

准确率来自证据、规则、复审与有限重判；人审从逐条复核退到少量异常仲裁。

Agent 评测的两种入口：离线评测与线上日志评测

上线准出建立在离线评测之上；线上日志负责发现真实分布与未知问题

01

离线评测

回答：改动后有没有退化？现在能不能发？

- 样本 版本化黄金集 + 历史 Badcase
- 方法 重复运行、版本对照、关键切片回归
- 产出 稳定性结论、退化定位与修复验证

上线准出 离线集上的整体 + 关键切片双门槛

02

线上日志评测

回答：真实用户正在遇到什么？

- 样本 真实调用日志、异常链路与高频需求
- 方法 分层采样、聚类归因、异常与新需求发现
- 产出 未知问题、真实分布与 Badcase 素材

线上发现 → 脱敏与分层 → 回流离线黄金集 → 修复回归 / 准出 → 上线继续观测

线上把真实问题带回来，离线把修复是否可信说清楚。

两类入口共享 Task、Rubric、Judge、归因标签和报告契约。

一个 94.41 分的策略，为什么仍然不准出？

结果很漂亮，但执行完整率没有过门槛

渠道热门商品查询 · 28 条评测记录

端到端结果分

94.41

≥ 80 · 通过

AND

执行完整率

89.29%

< 90% · 不通过

最终判定：不准出。高分不能抵消关键步骤缺失。

从分数到根因：7,170 个 Session 自动归成 10 类问题

一轮全量评测：3,206 个问题 Session，12,354 条失败明细

44.7%

Session 含失败项

每个问题 Session 平均 3.9 条

10 类

统一失败标签

跨策略、跨模型可比较


标签必须落到“失败明细”粒度

而不是给整个 Session 贴一个大标签。

同一条任务可以同时存在：

- 规划缺失
- 工具参数错误
- 交付字段缺失

Top 失败根因



这让报告从“谁分低”变成“应该修哪一层”。

评测不是验收终点，而是下游应用的“问题翻译器”

把用户拒收点翻译成可开发、可验证的改进项

标题改写

用户拒收点

用户连续两次指出
“超过 30 汉字 / 60 字节”

→ 改进项

输出后置长度校验
违规自动回炉重写

验证指标：同类约束违反率持续下降

主图生成

用户拒收点

首轮没有吸收
用户上传的参考图

→ 改进项

入口提取主体 / 色调 / 构图
注入生成约束

验证指标：首轮交付通过率

采购找品

用户拒收点

“泰规”被当成通用孔
4 轮纠错仍未收敛

→ 改进项

国别认证变成硬过滤
负反馈压实 Query

验证指标：纠错收敛轮数 ≤ 2

不捏造“提升了多少”：没有复测结果时，只给明确的验证指标与下一轮实验。

三阶段演进：变化的是发起权、编排方式和结果消费者

第一阶段也有人 + Skill + LLM，只是每一步都由人发起



业务 Agent

问题证据 → 自动归因 → 问题路由 → 修复 → 自动回归 → 不退化才准出

评测系统

偏差检测

修正候选

历史 Case 门控

低风险微调自动上线

重构 / 换代人工审批

记录有效修正

+ 可回退

8 个坑：大多数失败不在“选哪个 Judge 模型”

01

只看最终答案

漏掉工具、数据和交互边界

02

标准写得很像共识

但没有阈值、证据和门控

03

评测集过度干净

线上真实分布完全不同

04

评测集自身污染

泄题、矛盾、映射错位

05

让 Judge 自己算分

高分偏置与算术错误叠加

06

一次判太多项

位置衰减催生模板化偷懒

07

自动报告只追求快

错误结论被规模化传播

08

只给总分不归因

下游不知道应该修哪一层

如果只能先做三件事：把完成定义清楚、强制证据、离线与线上同时评。

三个结论

让 Agent 从“能跑”走向“可信、可发布、可进化”

01

评测的对象不是答案

而是意图、轨迹、交付和行为边界

02

Judge 不是终点

它需要证据、规则闸门与复审 Loop

03

分数不是价值

能归因、能回流、能验证修复才是闭环

评测系统自己，也需要被评测。

Q&A



欢迎讨论：评测集、Judge、线上日志、动态 Rubric 与评测闭环

评测结论可验证+系统可自动进化。