

统一算力底座：Ray 混合计算 实践

建设统一平台，支撑在线推理、离线训练与大数据计算

自动驾驶AI数据闭环平台

从数据采集到模型部署的全流程闭环





当前资源分配现状

按组分配



按业务线分配



多人共用一台机器



从分散算力到统一底座


— Ray on TKE 混合计算实践 · 背景与挑战 —

01 资源孤岛，利用率低



- 多集群，多地域独立运行，资源分散
- 缺乏统一调度，资源利用率普遍偏低
- 运维成本高，扩缩容效率低

02 峰谷无法互补，GPU 空转



- 业务波动明显，跨集群资源无法互补
- 高峰期资源紧张，低谷期大量 GPU 空转
- 资源浪费严重，成本居高不下

03 用户入口多，学习成本高



- 多套平台并存，入口分散
- 使用方式不统一，学习成本高
- 用户体验割裂，协作效率低



建设统一算力平台，基于腾讯 TKE 部署 Ray 集群



统一资源调度方案



TKE统一资源池 + 云API/KubeRay双通道 · 博世ARENA平台集成管控



博世ARENA统一管控台

统一入口：创建/销毁/扩缩容/监控 所有K8S工作负载



云API管控通道

- 腾讯 Ray 集群全生命周期管理
- 控制台可视化 + 监报告警



K8S API通道

- KubeRay Operator 灵活控制
- 非Ray负载原生K8S管理

Ray Job Ray Serve Spark 自定义Pod 其他服务



TKE 统一资源池

CPU节点池 | NVIDIA GPU节点池 | 海光DCU节点池
自动扩缩容 | 资源配额 | 节点亲和性调度



两个关键收益



三类部署需求，一个统一底座



Ray on TKE 支撑推理服务、数据处理、模型训练



推理服务

自动标注 · tagging · embedding
快速响应 · 持续在线



数据处理

去畸变 · 抽帧 · 清洗 · 挖掘
批量 CPU 任务 · 高吞吐



模型训练

数据驱动 · 持续迭代
稳定大算力 · 长时间运行



Ray on TKE 统一部署底座


CPU 节点池 · NVIDIA GPU 节点池 · 海光 DCU 节点池
统一入口 · 统一调度 · 统一扩缩容

推理服务：数据闭环中的关键一环



Ray 集群部署 · 异构资源调度 · 模型 actor 常驻

智驾数据闭环



按任务调度异构资源



模型 actor 加载一次 · 常驻共享内存 · 推理响应更快


Ray 推理服务的两个核心优势



流水线并行 · 单卡多实例 · 弹性启停


优势一：天然流水线并行

以自动标注为例



优势二：单卡多实例 + 弹性启停

以 tagging / embedding 为例



快速恢复 · GPU 按需释放




提升 GPU 利用率 · 灵活响应业务峰谷 · 降低推理成本

数据处理：Ray Data 统一编排海量预处理



镜头去畸变 · 视频抽帧 · 异常帧清洗 · 有价值场景挖掘

智驾原始数据预处理



Ray Data 编排价值

数据从 COS 自动读取 → 分布式分片处理 → 自动写回存储



自动拆分任务



统一管理并发



平台负责调度与容错

Ray Data 分片容错：失败只重跑，不影响全局



海量数据处理 · 稳定高吞吐 · 不担心前功尽弃



传统痛点：任务量大，失败代价高



大批量去畸变



抽帧



挖掘任务

Ray Data 解法：分片独立处理



分片独立



失败局部重试



已完成分片不受影响

业务同学无需担心中间失败 · 整条链路稳定高吞吐

模型训练：从训练到推理的产线闭环



· 异构 GPU 集群统一调度 · 开发即产线 · 排队与抢占 ·

两类训练集群，自动按需调度

NVIDIA GPU 集群

生态成熟 · 适合主流模型训练




平台按模型适配情况自动调度



Ray 调度器

海光 DCU 集群

国产化适配 · 满足自主可控需求



开发即产线，训练到推理无缝衔接

1 训练环境



环境 · 镜像 · 依赖

2 模型训练



Ray Train / 分布式训练

3 Ray 推理集群



直接上线 · 无需重新调试环境

环境完全一致



排队与抢占

低谷期更快拿卡



高峰期保障

关键任务优先调度

从申请资源到业务闭环：统一算力底座



THANKS

感谢您的聆听!

2026.07.16