

DataFun Agentic AI Summit · 腾讯云大数据专场

# 腾讯 WorkBuddy

## 基于 AI DLC 打造持续进化的 AI Native 数据底座

## 三个绕不开的数据难题

01

### 数据量增长异常快

任务量爆发，数据体量增速远超预期，处理能力必须足够弹性。

数据体量月增速

> 100%

02

### 超大字段的处理压力

对话、文档、图像等多模态字段极大，常规引擎读取与解析都很吃力。

单字段最大

1 GB+

03

### 众多数据方 · 高权限要求

数据需求方数量多、角色杂，权限边界必须清晰且可审计。

数据需求方

10 +

[ 虚线数值为示例参考，请按实际数据校准 ]

# 数据湖计算 DLC

一个 Serverless 底座，五个我们最看重的能力。

01

## Ray × Spark 双引擎

一份算力同时驱动数据处理、后训练与在线推理。

02

## Serverless 弹性

算力秒级伸缩，按任务 / 时长计费，免集群运维。

03

## Xpark 多模态引擎

SQL-First AI Function  
， 50+ 多模态 / LLM 算子。

04

## TCLake 元数据


数据对象 + AI 对象统一  
纳管，全流程血缘。

05

## MCP / Open API

底座可被 Agent 编排调用，  
串联数据与训练。

## 接入 AI DLC 后的整体架构



## 超大字段的高效处理

痛点：对话、长文档等单条记录字段极大，常规按行读取会拖慢一切。

### DLC 方案

- 列式存储

只读用到的字段，避开整行大对象。

- 冷热分离

大字段与元数据分开存储，检索、统计更轻。

- Xpark 多模态引擎

50+ 多模态 / LLM 算子承接重解析，峰值临时扩容。

#### 单条记录 · 字段构成

id

时间

用户

状态

#### 超大字段 · 对话 / 长文档正文

最大 1 GB+ / 条

占单条记录体积的绝大部分 —— 列式读取时可整块跳过

收益

超大字段任务耗时

↓ 60%

任务成功率

↑ 至  
99%

扫描数据量

大幅下降

## 引擎性能：我们的实测数据

同一批数据、同一条管线 —— 切换 DLC 前后的真实对比。

**5h → 1h**

**同数据处理耗时**

同一批数据端到端跑完，从 5 小时降到 1 小时，吞吐提升 5 倍。

**↓ 80%**

**CPU 使用率**

按同等负载换算，处理同样的数据只需约 1/5 的算力开销。

100% 兼容 Spark · 存量作业零改动迁入

〔 WorkBuddy 同数据集实测，口径以内部报告为准 〕

# MLOps: 串联数据与后训练

背景：数据与训练割裂、靠人工串联。

## 01 Agent 轨迹 / 反馈 · 沉淀入湖

API

## 02 Xpark 数据处理 · 特征提取

API

## 03 Ray Train 后训练 · SFT / RL


API

## 04 评估 / 回流 · 反哺 Agent

🔄 轨迹与评估自动回流数据湖，持续反哺后训练 —— Agent 越用越聪明

### 流水线 · 实际运行界面

IMAGE



收益

数据 → 训练交付周期

↓ 70%

人工搬运

↓ 90%

流程

可复用

# TCLake: 全流程自动血缘

数据对象 + AI 对象统一纳管 —— 可追溯 · 可分析影响 · 合规可交代。

## 数据加工

直接注册

## 特征工程

直接注册

## 模型训练

直接注册

## 模型服务


直接注册

## Agent 轨迹 / 记忆

引擎直接注册元数据与运行状态 —— 数据到模型全链路可追溯

## 血缘图谱 · 实际界面

IMAGE



收益

血缘覆盖率

95% +

问题排查时间

↓ 80%

额外成本

≈ 0



## 弹性算力，从容应对增长

痛点：数据体量增速远超预期，固定集群要么闲置浪费，要么高峰不够。

### DLC 方案


#### ■ 线性扩展

处理能力随资源同步线性增长；CPU / GPU 异构算力池统一纳管、动态调度。

#### ■ 按需获取

每个任务按处理量与时效独立申请，Serverless 按任务 / 时长计费，闲时按量收缩。

数据量 → 算力 · 线性扩展



算力随数据量线性增长，每个任务按需获取。

收益

峰值处理时延  
↓ **65%**

启动速度  
**分钟级**

闲时算力成本  
**≈ 0**

## 精细化权限，服务多数据方

痛点：数据需求方多、角色杂，权限边界必须清晰且可审计。



收益

授权到位  
**分钟级**

越权风险  
**可控**

操作审计  
**全程留痕**

Tencent 腾讯 | 腾讯云大数据

# 感谢聆听



扫码了解更多