

Kimi 大模型在 长程 **Agentic** 任务中的应用

Agentic AI Summit·深圳·2026




KIMI

<https://www.moonshot.cn>

模型能力进步带来
的开发范式转换

Progress on AI benchmarks in the past five years



CodeBuddy Code

Claude Code

Q Search models...

MODELS (7)

CODE

WEB

OFFICE

SECURITY

AVG ▾



Claude Opus 4.8

PROP

Anthropic

74.4%

68.1%

82.4%

64.4%

75.0%



GLM-5.2

OPEN

Zhipu

71.5%

67.4%

79.6%

76.3%

72.9%



GPT-5.5

PROP

OpenAI

72.9%

61.1%

82.0%

64.4%

72.0%



HY-3

OPEN

Tencent

62.9%

67.7%

82.1%

64.5%

70.9%



MiniMax-M3

OPEN

MiniMax

60.1%

58.0%

78.3%

74.1%

65.5%



DeepSeek-V4-Pro

OPEN

DeepSeek

58.9%

54.6%

79.1%

70.0%

64.2%



DeepSeek-V4-Flash

OPEN

DeepSeek

55.7%

47.3%

77.5%

67.1%

60.2%

Opus 5


	Opus 5	Fable 5	Opus 4.8	GPT-5.6 Sol
Agentic terminal coding Frontier-Bench v0.1	43.3%	33.7%	21.1%	34.4%
Knowledge work GDPval-AA v2	1861	1747	1593	1736
Novel problem-solving ARC-AGI-3	30.2%	—	1.5%	7.8%
Agentic search BrowseComp	90.8%	87.4%	84.3%	90.4%
Multidisciplinary reasoning Humanity's Last Exam	56.3% no tools	56.5% no tools	49.8% no tools	—
	64.7% with tools	63.9% with tools	57.9% with tools	—
Computer use OSWorld 2.0	70.6%	66.1%	55.7%	62.6%
Agentic coding DeepSWE v1.1	68.8%	69.7%	59.0%	72.7%
Agentic coding FrontierCode v1.1, Main	53.4%	53.5%	46.5%	47.5%
Business workflows AutomationBench	26.0%	17.4%	17.0%	18.1%
Legal Legal Agent Benchmark, Held-out	11.7%	13.3%	10.4%	2.5%
Health	59.8%	Mythos 5 44.2%	57.4%	60.5%




Agents' Last Exam

Challenge and measure AI agents on economically valuable and real-world tasks.


Agents' Last Exam is building the largest-scale, broadest-coverage agent evaluation benchmark to date, measuring performance on long-horizon, economically valuable tasks with verifiable outcomes. Led by Berkeley RDI and 300+ industry experts, it now spans all 55 targeted sub-industries covering most major fields of professional work performed on a computer, with 1,500+ tasks collected toward a 5,000-task target, keeping scores objective, comparable, and meaningful across domains.

[GitHub](#)[Leaderboard](#)[Agent traces ↗](#)[arXiv](#)[Watch 1-min overview](#)[Contribute a Task →](#)[Open for co-authorship ↗](#)

Architecture



Neuroscience



ALE-CLI
(linux task only)

Near-term
(partially solvable today)

Full-Spectrum
(50+ industries)


Last-Exam
(frontier difficulty)

Pass Rate


Pass Rate

Score

Both




1	—	Best per task	—	56.6%	78.8%	—	—	—	—
2	Codex	gpt-5-6-sol	XHigh (Best) ▾	30.6%	53.6%	\$762	94h 39m	762.9M	3.8M
3	Codex	gpt-5-6-luna	XHigh (Best) ▾	29.6%	48.3%	\$235	66h 7m	1.4B	4.2M
4	Kimi Code	Kimi K3	Max	28.3%	51.6%	—	186h 5m	1.4B	7.5M
5	Codex	gpt-5-6-terra	Max (Best) ▾	28.0%	50.5%	\$545	118h 39m	1.2B	5.8M
6	Claude Code	Kimi K3	Max	27.0%	50.7%	\$773	215h 32m	6.0B	7.4M
7	Claude Code	claude-opus-4-8	Max (Best) ▾	27.0%	45.1%	\$3,985	179h 18m	1.7B	22.1M
8	Codex	gpt-5-5	XHigh (Best) ▾	26.6%	47.9%	\$602	97h 8m	560.5M	6.4M
9	Claude Code	claude-fable-5 40% tasks downgraded	XHigh (Best) ▾	25.7%	48.7%	\$4,340	70h 0m	2.7B	10.4M
10	ALE-Claw ↗	gpt-5-5	High	23.0%	45.8%	\$310	35h 34m	334.3M	2.3M
11	OpenClaw	gpt-5-5	High	21.1%	41.0%	\$447	82h 38m	469.3M	3.3M

Rank	Name	Solved	Time
1	 St. Petersburg State University	11	1478
	2-255 2-53 C 1-37 3-150 1-20 3-298 2-195 1-42 2-81 3-128 1-19		
2	 The University of Tokyo	10	1116
	1-206 1-271 C 1-25 1-184 1-34 G 1-95 1-66 2-72 1-126 1-17		
3	 Beijing Jiaotong University	10	1425
	2-225 2-204 1-290 1-57 2-270 2-52 G 2-132 2-84 2-107 1-148 1-6		
4	 Tsinghua University	9	865
	3-139 B 1-225 1-33 1-174 2-27 1-299 1-71 1-87 2-84 1-157 1-13		
5	 Peking University	9	887
	1-180 B C 1-14 2-168 1-50 G 1-113 1-57 1-76 1-183 1-26		
6	 Harvard University	9	995
	1-124 B C 1-35 1-238 4-78 G 2-190 1-62 1-101 1-69 1-18		
7	 University of Zagreb	9	1075
	1-15 1-242 2-77 G 3-175 2-64 1-64 1-118 2-24		
	 Massachusetts Institute of Technology	9	1123
	1-291 C 1-14 1-113 1-36 G 6-204 4-121 1-145 2-27		
	 University of Science and Technology of China	9	1128
	C 1-41 1-286 1-31 2-224 1-14		
	 National University of Science and Technology	9	1119
	3-282 C 2-259 1-238		
	 University of Novi Sad	9	1119
	1-297 C 1-238		

● Gemini ● Fastest university team

*Faster than university team



Unless marked, Gemini passed the problem with 1 try.

⚙️ Customize

Rank	User	Score	A	B	C	D	E
1	🇺🇸 OpenAI	8300 (7) 390:36	900 30:05	900 32:11	1500 28:48	2500 (2) 174:24	2500 (5) 355:36
2	🇨🇳👑 tour1st	4300 (3) 412:25	900 (1) 397:25	900 58:13	-	2500 (2) 362:29	-
3	🇨🇳👑 jiangly	1800 111:07	900 27:21	900 111:07	-	-	-
4	🇨🇳👑🔍 turmax	1800 (1) 147:57	900 (1) 102:16	900 142:57	-	-	-
5	🇨🇳👑🔍 gblaasnicse	1800 160:48	900 160:48	900 42:16	-	-	-
6	🇨🇳👑🔍 tourist	1800 (2) 180:01	900 (2) 170:01	900 46:45	-	-	-
7	🇨🇳👑👑 Kevin090228	1800 (1) 232:45	900 70:43	900 (1) 227:45	(1)	(2)	-
8	🇨🇳👑🔍 liuhengxi	1800 (4) 255:08	900 (4) 235:08	900 223:39	-	-	-
9	🇯🇵👑🔍 noimi	1800 403:53	900 119:31	900 403:53	-	-	-
10	🇯🇵👑🔍 Nachia	1800 (4)	900 (4)	900	-	-	-

Contest Duration: 2026-07-07(Tue) 08:00 - 2026-07-08(Wed) 18:00 (local time)


[Back to Home](#)

[Top](#) [Tasks](#) [Clarifications](#) [Submit](#) [Results](#) [Standings](#) [Custom Test](#) [Editorial](#)

Customize				
Rank	User	Score	A	A-Final
1	OpenAI	1,999,878,828,865 2013:54	50,000,000,000 (61) 2013:54	1,999,878,828,865 2013:54
2	Shun_PI	481,395,927,450 1960:36	12,511,595,075 (36) 1960:36	481,395,927,450 1960:36
3	yosupo	403,384,272,283 2038:31	8,411,185,061 (23) 2038:31	403,384,272,283 2038:31
4	eijirou	324,056,684,900 2033:40	6,912,698,281 (21) 2033:40	324,056,684,900 2033:40
5	MathGorilla	308,336,644,874 2011:11	6,938,636,630 (30) 2011:11	308,336,644,874 2011:11
6	asi1024	252,791,351,731 2012:20	5,474,421,853 (22) 2012:20	252,791,351,731 2012:20
7	Rafbill	137,517,587,063 1935:58	3,494,667,377 (14) 1935:58	137,517,587,063 1935:58
8	terry_u16	100,569,394,030 1673:51	2,152,767,208 (21) 1673:51	100,569,394,030 1673:51
9	montplusa	51,070,263,582 2039:10	1,120,308,502 (20) 2039:10	51,070,263,582 2039:10
10	yokozuna57	45,348,703,682 2002:09	1,085,751,045 (42) 2002:09	45,348,703,682 2002:09

Token Usage By Source Type

 OpenF





Anonymous on A digestion of the Jacobian co...
Various News Items |... on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...



Emmanuel Audigé on Gilbreath's conjecture:...



Terence Tao on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...



David Speyer on A digestion of the Jacobian co...



David Speyer on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...



Terence Tao on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...



Anonymous on A digestion of the Jacobian co...

A digestion of the Jacobian conjecture counterexample

21 July, 2026 in [math.AG](#) | Tags: [Jacobian conjecture](#), [polynomials](#) | by Terence Tao

The notorious [Jacobian conjecture](#) can be formulated concretely over the complex numbers as follows.

Conjecture 1 (Jacobian Conjecture) Let $F : \mathbb{C}^n \rightarrow \mathbb{C}^n$ be a polynomial map in n complex variables, whose Jacobian $\det DF$ is a non-zero constant. Then F is invertible (with polynomial inverse).

The condition that the Jacobian $\det DF$ is non-zero is equivalent to F being locally invertible. (The implication of local invertibility from non-vanishing Jacobian follows from the inverse function theorem; the converse implication can be derived from the [Weierstrass preparation theorem](#), but is omitted here.) Also, from the fundamental theorem of algebra, once the Jacobian polynomial $\det DF$ is non-zero, it must be constant. So the hypothesis “Jacobian $\det DF$ is a non-zero constant” can be replaced with “ F is locally invertible”. So the Jacobian conjecture can be viewed as an assertion that local invertibility implies global invertibility. The complex numbers can be easily replaced with other fields of characteristic zero by the [Lefschetz principle](#), but I prefer to work in the concrete setting of the complex numbers.

It was [recently shown](#) (using the Fable AI) that the conjecture is false in three dimensions (and thus in higher dimensions as well):

Theorem 2 (Counterexample to conjecture) There exists a polynomial $F : \mathbb{C}^3 \rightarrow \mathbb{C}^3$ which has non-zero constant Jacobian, but is not invertible.

The conjecture remains open in two dimensions, and is easy to establish in one dimension.

The example can be stated completely explicitly: one can take

科技圈 🧡 在花频道 📌

🔗 Telegram 被曝存在零点击崩溃漏洞，桌面版已静默修复

安全研究人员披露，Kimi K3 在 Telegram 客户端中发现了一个零点击漏洞。据目前公开信息，该漏洞可能影响 Telegram Desktop 和 iOS 客户端，攻击者可通过特制消息导致客户端内存耗尽并崩溃。

Telegram Desktop 已发布新版并完成修复，但更新日志中没有明确提及该漏洞。研究人员还公开了测试机器人 [@kimifuckingbot](#)，用于触发并验证崩溃问题。该机器人具有实际破坏性，不建议使用主账号或未更新的客户端测试。

建议桌面端用户立即更新至最新版本；iOS 用户也应及时检查 App Store 更新。在官方确认前，应避免使用长期未同步上游代码的第三方 Telegram 客户端。

[原文](#) | [测试机器人](#) | [桌面版更新](#)

🌸 在花频道 · 茶馆水群 · 投稿通道

🌟 🤖 133 😄 35 ❤️ 10 👍 9 🥰 3

👁 11.9K edited 23:06



KernelBench: Can LLMs Write GPU Kernels?



Anne Ouyang*
Stanford



Simon Guo*
Stanford




Azalia Mirhoseini
Stanford

Materials

[HF Dataset](#)

[Codebase](#)

[Leaderboard](#)




A benchmark designed to evaluate the ability of LLMs to generate efficient GPU kernels for optimizing neural network performance

从 桌面 到 移动

随时随地 vibe coding

当我在这里



从创意到生产环境

通过手机贯穿整个开发生命周期，完成端到端工作。


推动工作进展

通过手机启动新的智能体，并继续向现有智能体发送提示。




获取工作成果演示

云端智能体会测试并确认其工作，然后返回视频、截图和日志等产物。



随时掌握进展

通过 Live Activities 查看实时状态，并在智能体完成任务或需要您处理时收到通知。




与 Cursor 对话

使用语音输入，像和同事交流一样，把您的创意直接说出来。



提供可视化反馈

打开标注工具，在图片上做标注，并在固定位置添加评论。



用手机交付代码

借助专为移动端设计的聚焦 diff 和源代码管理功能，审查并合并 PR。




- Now relaunch: AgentSwarm with resume_agent_ids (32 failed) + items (26 aborted, same template). The template ... (7 more lines, ctrl+o to expand)

- Agent Swarm - 重发失败/中断的页面修复

001	[■■■■■■■■■■]	✓ 任务完成 ...	002	[■■■■■■■■■■]	✓ 任务已完 ...
003	[■■■■■■■■■■]	✓ 任务完成 ...	004	[■■■■■■■■■■]	✓ 迁移完成 ...
005	[■■■■■■■■■■]	✓ 迁移完成 ...	006	[■■■■■■■■■■]	✓ 任务完成 ...
007	[■■■■■■■■■■]	✓ 迁移完成 ...	008	[■■■■■■■■■■]	✓ 全部完成 ...
009	[■■■■■■■■■■]	✓ 迁移完成 ...	010	[■■■■■■■■■■]	✓ 完成。页 ...
011	[■■■■■■■■■■]	✓ 迁移完成 ...	012	[■■■■■■■■■■]	✓ 迁移完成 ...
013	[■■■■■■■■■■]	✓ 完成。汇 ...	014	[■■■■■■■■■■]	✓ 迁移完成 ...
015	[■■■■■■■■■■]	✓ 迁移完成 ...	016	[■■■■■■■■■■]	✓ 迁移已完 ...
017	[■■■■■■■■■■]	✓ 任务完成 ...	018	[■■■■■■■■■■]	✓ 迁移完成 ...
019	[■■■■■■■■■■]	✓ grep 无输 ...	020	[■■■■■■■■■■]	✓ 迁移完成 ...
021	[■■■■■■■■■■]	✓ 完成。汇 ...	022	[■■■■■■■■■■]	✓ 任务完成 ...
023	[■■■■■■■■■■]	✓ 迁移完成 ...	024	[■■■■■■■■■■]	✓ 迁移完成 ...
025	[■■■■■■■■■■]	✓ 任务完成 ...	026	[■■■■■■■■■■]	✓ 迁移完成 ...
027	[■■■■■■■■■■]	✓ 迁移完成 ...	028	[■■■■■■■■■■]	✓ 迁移完成 ...
029	[■■■■■■■■■■]	✓ 迁移完成 ...	030	[■■■■■■■■■■]	✓ `develope...
031	[■■■■■■■■■■]	✓ 迁移完成 ...	032	[■■■■■■■■■■]	✓ 任务完成 ...
033	[■■■■■■■■■■]	✓ 迁移完成 ...	034	[■■■■■■■■■■]	✓ 迁移完成 ...
035	[■■■■■■■■■■]	✓ 迁移完成 ...	036	[■■■■■■■■■■]	✓ 任务完成 ...
037	[■■■■■■■■■■]	✓ 迁移完成 ...	038	[■■■■■■■■■■]	✓ 迁移完成 ...
039	[■■■■■■■■■■]	✓ `grep` 无 ...	040	[■■■■■■■■■■]	✓ 迁移完成 ...
041	[■■■■■■■■■■]	✓ 迁移完成 ...	042	[■■■■■■■■■■]	✓ 迁移完成 ...
043	[■■■■■■■■■■]	✓ 迁移完成 ...	044	[■■■■■■■■■■]	✓ 迁移完成 ...
045	[■■■■■■■■■■]	✓ 任务完成 ...	046	[■■■■■■■■■■]	✓ 完成。`ts...

一个例子



ull: 180 · crew: 25

ports discovered


2 / 131

discoveries

0 / 110



o ashore [L] land/re-board [Esc] leave [wheel] zoom [M] music [I] log [`] dev



Market

Bar

Dock

Harbor

Inn

Palace

Jobs

MSC

Bank

Shop

Church

Fortune

核心论点：从「知识提供者」到「任务执行者」

本文系统探讨 Kimi 大模型（月之暗面科技）处理长程 **Agentic** 任务的核心能力、技术架构与实际应用价值。

长程 **Agentic** 任务，指需要模型在**多轮交互**、**复杂规划**、**工具调用**与**持久化记忆**之间持续协调，跨越大量上下文窗口才能完成的复杂目标导向型任务。

本文从超长上下文、**Agentic** 架构、多模态推理、挑战与对策四个维度展开，并结合 Kimi K3 的公开基准与真实案例验证其效能。

核心判断：Kimi K3 在 6 项真实 **Agentic** 基准中赢得 5 项，单任务成本较同级旗舰低 50–65%，长程任务能力进入全球第一梯队。

01 超长上下文

1M tokens 窗口：整书、代码库、长视频序列的统一理解

02 Agentic 架构

自主规划 → 工具调用 → 结果整合的执行闭环

03 多模态感知与推理

视觉在环：看运行结果，再回头改代码

04 挑战与对策


记忆管理、规划反思与幻觉控制

Kimi Agent Road

- Kimi Explorer Edition 2024-11
- Kimi Deep Research 2025-06
- K2 Model 2025-07
- OK Computer 2025-09
- Kimi Agent Swam 2026-01
- Kimi Claw 2026-02



长程 Agentic 任务：四种能力必须持续协调



长程任务的核心痛点

上下文窗口截断 → 任务状态与中间结果丢失 → 长程依赖断裂。

最终表现为：**完成率与准确性随任务长度急剧衰减**——这正是传统模型无法胜任长程任务的根本原因。

Kimi K3 的应对

- 1M tokens 上下文窗口，全窗统一计价
- 单 Agent 连续 48 小时自主运行（芯片设计案例，见第 14 页）
- 上下文压缩策略：300K 触发压缩仍保持 BrowseComp 全球第一

数据来源：[Moonshot 《Kimi K3 Tech Blog: Open Frontier Intelligence》](#)，2026-07-14。

Kimi K3：为长程 Agentic 任务而生的开放旗舰

发布时间	2026-07-16 发布；开放权重 2026-07-27（Modified MIT，可商用）
参数规模	2.8T 总参数稀疏 MoE；每 token 激活 16 / 896 专家，约 50B 活跃参数
上下文	1,048,576 tokens（1M）；文本 + 图像输入，文本输出
注意力架构	Kimi Delta Attention（KDA）+ Attention Residuals；百万 token 解码提速最高 6.3×
Agent 形态	Kimi App / Kimi Work 3.1+ / Kimi Code CLI / Kimi API（kimi-k3）
API 价格	输入 \$3 / MTok（缓存命中 \$0.30），输出 \$15 / MTok；编码负载缓存命中率 >90%

2.8T

总参数 · 迄今最大开放权重模型

1M

tokens 上下文窗口 · 全窗统一计价

6.3×

百万 token 上下文解码提速（KDA）

来源：[Moonshot《Kimi K3 Tech Blog》](#)（2026-07-14）；[Bleap《Kimi K3 Review 2026》](#)（2026-07-22）。

超长上下文：长程任务的基石

三大典型场景

整本长篇小说理解

人物弧光、伏笔回收与跨章节一致性，需要全书同时"在场"

大规模代码库分析

架构文档、相关服务、测试历史与多文件约束同窗处理，而非检索拼接

长视频 / 多文档序列推理

财报、论文、日志与视频素材的跨证据关联推理

技术机制：极长文本中如何保持聚焦

KDA 混合线性注意力

线性复杂度建模长程依赖，让 1M 窗口从"标称可用"变为"工程可用"

上下文压缩

BrowseComp 在 300K 处触发压缩策略，长程检索成绩不降反稳（91.2）

关键信息检索与长程依赖建模

注意力聚焦与逻辑一致性，抵抗"读到后半段开始忘事"的长文衰减

本章要点：上下文窗口的长度决定长程任务的"续航上限"，而注意力机制决定窗口的"有效利用率"——K3 的 KDA 架构同时推进了这两条曲线。

长文实证：检索精度与细节定位双双第一

BrowseComp · 长程网页信息检索基准

91.2

300K 压缩策略下全球第一（GPT-5.6 Sol 90.4、Claude Fable 5 88.0）。

1M 全窗、无压缩管理仍达 **90.4**——长窗口本身就是长程检索的护城河。

对长程任务的意义：深度研究类 Agent 的单次任务往往消耗数十万 token 的网页证据，检索精度每提高一分，最终报告的事实性就稳一分。


第三方实测 · 8 万字研报 10 道细节题

模型	答对题数
Kimi K3	10 / 10
GLM-5.2	9 / 10
DeepSeek V4	9 / 10
Qwen3.8-Max	8 / 10
豆包 Seed-2.0	7 / 10

测试者评价：K3「细节定位精准」，长文本传统强项进一步巩固。

来源：[Moonshot《Kimi K3 Tech Blog》](#)（2026-07）；[掘金《2026 下半年五国产大模型全测》](#)（2026-07-22）。

从「对话」到「执行」：规划—调用—整合的自主闭环



Kimi Work · OK Computer

深度研究、网站构建、演示文稿、图像生成与复杂数据处理。

Widgets / Dashboard 将结果沉淀为长期可复用的交互面板，而非一次性输出。

Kimi Code CLI

开源终端编程 Agent：读仓库、改代码、跑测试、看报错再回修。

已集成 VS Code / Cursor / Zed，支持长时无值守会话。

开放工具生态

Function Calling、外部 API 与 MCP（如 Blender MCP）。

Hermes 等第三方 Agent 框架可直接接入 kimi-k3 与视频分析工具。

范式意义：模型的交付物从"一段回答"变为"一个可验证的任务结果"——研究报告、可运行系统、可交互作品，这是 Agentic 架构与纯对话模型的分水岭。


Agentic 基准总表：6 项真实任务基准，K3 赢得 5 项

基准（越高越好）	Kimi K3	GPT-5.6 Sol	Claude Fable 5	Claude Opus 4.8
Terminal-Bench 2.1 · 终端操作	88.3（第 2）	88.8	84.6	84.6
Program Bench · 编程	77.8（第 1）	77.6	76.8	71.9
SWE Marathon · 长程软件工程	42.0（第 1）	39.0	35.0	40.0
BrowseComp · 网页深度检索	91.2（第 1）	90.4	88.0	84.3
SpreadsheetBench 2 · 电子表格	34.8（第 1）	32.4	34.7	31.6
Automation Bench · 任务自动化	30.8（第 1）	29.7	29.1	27.2

唯一未夺第一的 Terminal-Bench 2.1 也仅落后 0.5 分；全部模型均在 max thinking 档位评测。

来源：Moonshot 发布数据（2026-07-16），经 [K3 vs GPT-5.6 vs Claude 对比报告](#)（2026-07-19）整理；厂商自报数据，独立复测待权重开放。

SWE Marathon: 长程软件工程，K3 领先幅度最大的一项




SWE Marathon v1.1 得分（越高越好）· 考察持续数小时的多步工程任务

考什么	差距有多大	成本账
持续数小时的工程会话：读仓库、改代码、跑测试、再迭代，极少人工介入。	K3 得分约为 GPT-5.5 的 3 倍（42.0 vs 14.0）——长程能力拉开代际差距。	单任务成本约 \$0.94，仅为 Claude Fable 5（\$2.75）的约三分之一。

来源：[Moonshot《Kimi K3 Tech Blog》](#)（H20 校准分支，Claude Code harness）；成本数据经 [k3-kimi.com](#) 整理。

视觉在环（Vision in the Loop）：看见结果，再改代码



模型读取程序运行时的画面反馈，持续修正输出

为什么"看"比"读日志"更直接

网页游戏、3D 场景、前端页面、CAD 设计——这类任务的对错写在画面上，纯文本反馈很难描述"哪里不对"。

视觉在环让 Agent 直接检查渲染结果，把"看效果调整"变成标准开发动作。

K3 官方案例

- Three.js + WebGPU 开放世界游戏（森林、村庄、雪山、动态天气）
- 黑洞可视化、长征十号火箭仿真、GBA 模拟器
- 56 段视频素材：镜头筛选、节奏匹配、音频处理与多轮剪辑修改

来源：[VenturePost（转引 The Decoder）](#)（2026-07-16）；[Moonshot 官方发布（新浪财经转载）](#)（2026-07-16）。

lychees / dol-k3-2

code

Issues

Pull requests

Agents

Actions

Projects

Wiki

Security and quality

Insights

Settings

main

+

Q

Go to file

T

test_boarding.py

test_buildings.py

test_console.py

test_dev.py

test_dialog.py

test_final.py

test_fleet.py

test_jobs.py

test_land.py

test_maids.py

test_mates.py

test_npc.py

dol-k3-2 / tests

lychees

Mate skill system (UWO-style): 10 skills with levels and growth

✓

Name	Last commit message
..	
screenshots	Mate skill system (UWO-style): 10 skills with levels and growth
test_battle.py	Dock: buy/sell/refit ships, duplicate models allowed
test_bgm_dir.py	Refactor main.js, add DESIGN.md, reorganize repo layout
test_blackjack.py	Blackjack in the bar + fix old-save cabin migration TDZ
test_boarding.py	Refactor main.js, add DESIGN.md, reorganize repo layout
test_buildings.py	Teleport double-click + job house cargo requests & bounty hunts
test_console.py	Pretty-print ports.json/port_meta.json (indent=1); fix teleport cour
test_dev.py	Refactor main.js, add DESIGN.md, reorganize repo layout
test_dialog.py	Refactor main.js, add DESIGN.md, reorganize repo layout

Lisbon

time: day

buildings: 11

ports discovered

1/130

discoveries

0/98

Inn




A warm bed and a hot meal await the weary traveler.

/ leave

W A S D / move enter go ashore leave zoom music





Preview

Code

Blame

401 lines (388 loc) · 23.7 KB



Raw



4. "上传到 github 并配置 github page"

- Initialized git, pushed to <https://github.com/lychees/dol-k3-2>
- Enabled GitHub Pages (main branch, root); game served at <https://lychees.github.io/dol-k3-2/game/>

5. "港口的贴图是不是不太对? 也没法访问建筑" (bugfix round)

- **Building access:** building tiles are unwalkable by design (ids 42/44/46/170); in uw2ol the player stops in front of the door. Fixed the proximity check to trigger on the nearest building within 2 tiles instead of requiring the player to stand ON the (unwalkable) building tile.
- **Port textures — root cause: off-by-one tile ids.** PORTMAP bytes are 0-based (uw2ol does `byte + 1`), but the shader assumed 1-based ids like the world map. Every port tile was drawn as the previous tile (water rendered as beach-edge tiles → the mystery "vertical stripes"). Fixed by uploading a +1-shifted copy of the port map to the DataTexture.
- **Color fix:** removed `SRGBColorSpace` from tileset textures — the custom ShaderMaterial does not re-encode to sRGB, so decoded-linear output looked dark/over-contrasted. Textures now pass through raw, matching the PNGs.
- **Filtering:** tilesets use LinearFilter + mipmaps + max anisotropy with a GLSL3 `textureGrad` shader (continuous derivatives, no tile-boundary artifacts); texel-center sampling keeps magnified pixels crisp.
- Verified on real GPU (RTX 4090) + SwiftShader: Lisbon/Istanbul ports match the PIL ground-truth render; full regression test passed.

7. 港口建筑交互 (完整游戏循环)

- **Player state** (localStorage `uw-save-v1`): gold, fame+title (Squire...Duke), provisions/fatigue/hull (drain at sea per in-game day, penalties at 0), ship tiers (Sloop/Caravel/Galleon: speed/cargo/hull), cargo hold, bank balance (2% daily interest), telescope, quests, discoveries — all persisted.

前端与视觉实证：从盲测第一到「一句话出原型」

LMArena 前端代码盲测

1679 Elo · 第 1 名

匿名双输出盲投，领先 Claude Fable 5（1631）与 GPT-5.6 Sol（1618）。

上线首日登顶，7 个前端类目中拿下 6 项第一。

爱范儿连夜实测

89% 模拟进球概率

点球最优解：将脚感、角度、球速、门将反应建模后做大规模蒙特卡洛模拟，得出 $v_0 \approx 25 \text{ m/s}$ + 侧旋 $\approx 8 \text{ rev/s}$ 的最难扑射门策略。

「云驰 Aeris」专注 App：一句话提示，数小时做到可玩产品原型水准。

社区 4 天实测

\$3.24 一个游戏

网友单提示做出 CS:GO×Portal 风格游戏，消耗约 60 万 tokens。

社区同任务成本测试：K3 约为 Fable 5 的 1/3 到 1/10。

案例启示：多模态能力不止"看懂图片"，而是参与完整生产流程——从物理模拟、程序化建模到可交付的应用原型，成本已进入"几美元级"。

来源：[Bleap K3 Review](#)（2026-07-22）；[爱范儿《连夜实测 Kimi K3》](#)（2026-07-23）；[moclaw.ai《Kimi K3 Use Cases》](#)（2026-07-21）。

长程任务的三大挑战，与 K3 的对策

记忆管理 超长交互中任务状态与中间结果如何不丢失

对策：1M tokens 窗口 + 300K 触发的上下文压缩 + Mooncake 分离式推理架构（编码负载缓存命中率 >90%，长会话成本可控）。

规划与反思 任务分解之后，执行过程如何不漂移

对策：执行中自我纠错（跑测试 → 看报错 → 回修代码）；ASIC 行业研究案例中，K3 经过 120+ 轮递归自我改进逐步收敛报告质量。

幻觉控制 长程生成中如何保持事实准确与逻辑连贯

对策：证据边界意识——IRB 投研测评显示 K3 在证据不足时主动标注缺口、不顺着错误前提作答，时效纪律等四项对 GPT-5.5 与 Opus 4.8 领先 15 分以上。

诚实边界：AA Omniscience 测得 K3 准确率 46%（K2.6 为 33%）提升的同时，幻觉率升至 51%（K2.6 为 39%）。对"必须说对"的生产级 Agent 工作流，建议在 K3 之上叠加护栏层。

来源：[AlphaEngine IRB 投研测评（钛媒体）](#)（2026-07-20）；[Bleap K3 Review](#)（2026-07-22）。

四大应用场景 × K3 实证案例

领域	K3 实证案例	效能数据
学术研究	复现计算天体物理 I-Love-Q 普适关系：阅读并交叉验证 20+ 篇论文，评估 300+ 种状态方程，生成 3,000+ 行 Python，产出交互式分析仪表盘	约 2 小时 ≈ 资深研究人员 1-2 周
软件开发	HotPulse 热点追踪全栈 MVP（抓取→分析→通知全链路，含数据库、队列与测试）；从零构建 MiniTriton 编译器工具链（DSL→MLIR→PTX）	单 Agent 持续完成"拆解—编码—测试—修复"循环
商业分析	Kimi Work 生成 ASIC 行业 42 年研究：120+ 轮递归自我改进，2,800+ 次网页搜索抓取、1,100+ 次终端取数，处理 87 份季报与 99 份 PDF 共 11,000+ 页	交互式报告 + 可复用 Dashboard 沉淀
内容创作	56 段视频素材的镜头筛选、节奏匹配、音频处理与多轮剪辑修改；长篇小说 / 剧本级长文本的一致性生成	多模态直接进入内容生产流程

来源：[Moonshot 官方发布（新浪财经转载）](#)（2026-07-16）；[JavaGuide《Kimi K3 实战》](#)（2026-07-21）。

无人值守数小时到两天：Agent 的「续航」实证

案例 A · 48 小时芯片设计

48h 4mm² 100MHz

连续运行时长 | 芯片面积 | 时序收敛频率

单个 K3 Agent 连续自主运行 48 小时，使用开源 EDA 工具完成一款小型芯片的设计、优化与验证全流程。

这是长程自主推理的极限演示：中间无需人工接管，任务状态在超长会话中全程保持。

案例 B · 15 小时 CUDA 内核优化

15h -60%

无人值守运行时长 | 内核延迟降幅

Moonshot 官方演示：K3 在 15 小时无人值守会话中，将 CUDA kernel 延迟从 283.6ms 优化到 114.4ms。

反复"改代码—跑基准—读结果—再改"的闭环，正是长程 Agentic 价值的直接度量。

长程任务的核心指标正在从"单轮回答质量"变为「可持续运行时长 × 任务完成率」——这正是 K3 设计目标的中心。

来源：Moonshot 发布演示：[moclav.ai 《Kimi K3 Use Cases》](#)（2026-07-21）；[EvoLink K3 模型页](#)（2026-07-16）。

K3 基模驱动网页游戏研运，从创意到可玩原型全链路闭环

覆盖创意策划 → 代码生成 → 视觉验证 → 迭代打磨，让 H5 游戏、营销页、落地页快速上线

① 客户与业务背景

客户为国内头部网页游戏平台，研运节奏快、版本多，传统链路长、人力瓶颈明显。

创意到可玩 Demo 周期长，难以快速验证玩法

营销 H5/落地页需求碎片化，开发资源被反复占用

多角色协作导致视觉与交互反复返工

② 解决方案：K3 全链路智能研运

提出创意/需求

策划输入玩法概念与视觉风格

AI 生成代码/设计

K3 一键输出 H5/网页/素材

本地启动验证

浏览器即点即玩、截图自检

多轮迭代打磨

视觉在环持续优化至上线


依托 K3 的 100 万 Token 长上下文、原生视觉理解与多智能体协作能力，单个创意可在数小时内完成从文案到可交互原型的闭环。

③ TOP 高频场景

网页游戏原型  ≈35%

营销 H5 活动页  ≈28%

SaaS 落地页  ≈22%

素材/文案批量生成  ≈15%

“ K3 将创意到上线周期从数周压缩到数天，让研运团队共用一套智能基座。

降低原型成本

加速营销上线

提升迭代速度

从选品到出库，Kimi 成为国内头部服饰电商供应链业务的「智能值班员」

对接商品审核、WMS 仓储、价格管理、OQC 产能等内部系统


1 客户与业务背景

客户为国内头部服饰电商（特卖模式），业务链路长、时效强、节奏快（日常特卖 + 大促双模式）。

核心业务链路：服装选品招商 → PDC 商品审核 → PS 价格/供应商审核 → WMS 仓储作业 → OQC 出库质检与产能统计

痛点：系统多、环节多，依赖人工盯盘与定时报表，异常发现滞后、重复工作繁重。

2 TOP 高频落地场景（125 条样本抽样占比）



3 解决方案：K2.6 接入内部系统，贯穿全链路



价值总结：K2.6 已嵌入国内头部服饰电商「选品 — 审核 — 仓储 — 产能」全链路，把高频重复的盯盘、审核、统计、推送工作交给 AI 定时执行。

覆盖多系统

高频刚需 ≈ 近 4 成

从工具走向业务流程

与同级旗舰对比：Agentic 第一梯队，成本减半以上

模型	AA 智能指数	上下文	单任务成本	开放权重
Kimi K3	57.1 (#4)	1M	\$0.94	✓ (07-27)
GPT-5.6 Sol	58.9 (max)	—	约 \$1.90+	✗
Claude Fable 5	59.9	1M	\$2.75	✗
Claude Opus 4.8	55.7	200K 级	约 \$1.90	✗

结论：综合智能指数 K3 与闭源旗舰同处第一梯队；6 项真实 Agentic 基准赢 5 项，单任务成本低 50–65%，且是唯一开放权重者。

诚实边界：Moonshot 官方明确表示 K3 整体仍落后 Fable 5 与 GPT-5.6 Sol；上表多数分数为厂商自报（2026-07-16），独立复测有待权重开放后进行。

来源：Artificial Analysis Intelligence Index v4.1（2026-07），经 [Bleap K3 Review](#) 整理；成本为 Moonshot 发布口径。

研究价值：大模型从「知识提供者」走向「任务执行者」

范式转变

模型不再只回答问题，而是交付可验证的任务结果——报告、系统与作品。

技术结论

超长上下文 × Agentic 架构的结合，显著降低了复杂任务中因上下文截断导致的性能衰减。

实践参考

K3 的基准与案例，为 Agent 系统的能力评估与架构设计提供了可复用的坐标系。

目标读者


- 大模型技术研究者与工程师
- 智能体（AI Agent）系统开发者
- 企业级 AI 应用架构师
- 关注长文本处理与自主任务执行的技术决策者

主要资料来源

[Moonshot《Kimi K3 Tech Blog》](#)（2026-07）
Artificial Analysis Intelligence Index v4.1（2026-07）
[Bleap K3 Review](#)（2026-07-22）
[爱范儿 K3 实测](#)（2026-07-23）· [掘金五模型横评](#)（2026-07-22）
[AlphaEngine IRB 测评](#)（2026-07-20）· [moclaiw.ai 案例集](#)（2026-07-21）

Token Efficiency革命 告别Adam的二阶优化器

Loss曲线对比：Adam vs 新型二阶优化器



核心技术突破

- 技术突破：自主研发新型二阶优化器，融入Weight Decay机制，匹配RMS更新尺度等关键技术
- 效果量化：2倍Token Efficiency，达到相同Test Loss仅需一半的Token
- 战略价值：在数据墙时代，同样的15T Token预算，K2产生比别人多一倍的智能密度

2×
Token Efficiency

15T
训练数据规模

1T
模型参数规模

Data wall?
我们用架构创新翻越

Kimi Linear 长上下文架构的历史性突破

技术痛点:传统线性注意力虽快但在长距离任务性能下降,无法适应Agentic时代长程依赖需求

Kimi Linear核心创新


Fine-grained对角化矩阵 (αt)

下一时刻状态 S_t 在 S_{t-1} 基础上通过线性KV计算更新,细粒度控制状态向量每个维度的记忆流动

$$S_t = S_{t-1} + \alpha t \cdot (\text{Key} \cdot \text{Value})$$

工程优化

通过公式变换得到比DPLR更高效的新形式,减少矩阵层操作,百万级上下文端到端速度提升6-10倍



All comes down to taste 当工程遇见审美

非同质化智能：智能不同于电力或货币，每个模型产生的Token都是非同质化的，体现"品味(Taste)"差异


Token efficiency

- Agentic 推理本质上是一种搜索
- 搜索能力取决于先验（prior）
- 更高的 token efficiency → 有限数据中沉淀更强的先验 → 更强大的 agent


Long context

- Agentic 行为需要工作记忆（working memory）
- 更长的上下文 → 更强的环境感知 → 更强的 agent
- 跨长程的连贯性与复杂规划能力，涌现自对长程依赖关系的建模。

Kimi 模型 演进时间轴



最新模型
KimiK2.6



Kimi K3, Moonshot AI's latest open-weights model, ranks 1st on our single-shot Frontend Arena with an Elo of 1408. This is 10 positions higher than Kimi K2.6 and 16 positions higher than Kimi K2.7 Code, marking the largest jump we've ever seen in the Moonshot model line.



Design Arena

@DesignArena

关注

World's first benchmark for real-world design with 5M+ creators and counting. Made by @intelligence_ai

有什么新鲜事

新加坡 的趋势

Bitcoin

新加坡 的趋势

#ADogAndAPlaneEP9

EXO 趋势

chanyeol

新加坡 的趋势

Iranian

显示更多

Kimi服务和团队



Kimi ToB/ToC 产品/技术全景图



Moonshot AI 背后是一支超高人才密度的世界级团队

团队 300 余人，囊括语言、视觉、强化学习和基础设施方面的新生代世界级人才



杨植麟 清华大学-卡耐基梅隆大学博士
Kimi 创始人、CEO

300余位AI先锋: 汇聚语言模型、计算机视觉、强化学习及基础设施领域的突破性专业实力，并拥有多篇研究论文发表；

数百万月活用户，5,000+企业已基于K2.5构建应用；
数十亿美元以上融资总额，获一级投资机构支持；



“

AGI 不是某一级台阶，你爬到了就突然实现。
它是一个方向，是一条没有尽头的雪山。

- 杨植麟 月之暗面 创始人

”





Scale up!

References

- [A Survey of Vibe Coding with Large Language Models](#)
- [Google Engineering Practices Documentation](#)
- [Context-Engineering-for-AI-Agents-Lessons-from-Building-Manus](#)
- [Linear Transformers for Efficient Sequence Modeling](#)
- [Why Did MiniMax M2 End Up as a Full Attention Model?](#)
- [Everything about AI infra](#)
- [The Second Half](#)
- [Attention Residuals 回忆录](#)
- [how anthropic use claude code](#)

一起探索「Agentic」的上限！

AI 不只是普通工具，而是人类文明的放大器，探索未来世界的钥匙



KIMI

<https://www.moonshot.ai>