

基于 AgentScope 的金融数据平台 Agentic 进化之路

王博 · 瓴岳科技

目录

CONTENT

- 01 数据领域的 Agentic 演进
- 02 方案选型与 DataAgent 整体架构
- 03 落地挑战与解决思路
- 04 未来演进与总结

01

数据领域的 Agentic 演进



2026 Agentic 规模化落地 · 生产级门槛

2026: Agentic 规模化落地, 垂直数据 Agent 涌现



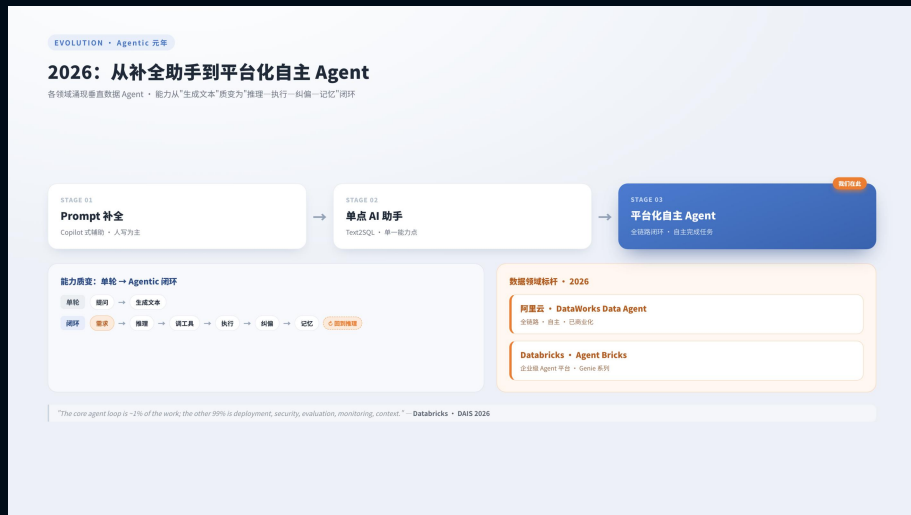
AGENTIC AI
超级智能体系架构峰会

从 Copilot 补全, 迈向 Agent 自主完成任务

标杆已商业化: 阿里云 DataWorks Data Agent、Databricks Agent Bricks

能力质变: 推理 → 调工具 → 执行 → 纠偏 → 记忆的闭环

但能力只是入场券, 「生产级」才是真正的分水岭



"The core agent loop is ~1% of the work; the other 99% is deployment, security, evaluation, monitoring, context." — Databricks · DAIS 2026

生产级门槛：金融数仓的复杂度与三维要求

现实复杂度：全球化部署、协作链路长、表多且口径不容错

喂得准（知识可信）：元数据规范化·口径统一·脏数据清洗

改得对（效果可控）：系统可观测·效果可评测·回归可追踪

敢执行（边界可守）：高危拒答·权限前置·全链路审计·不越权

而这三维，恰恰是通用 Agent 框架给不了的——今天的暗线



02

方案选型与 DataAgent 整体架构

AgentScope Java · 六层架构 · 三服务协同




年初横评主流框架：Spring AI / LangChain / LangGraph / Google ADK / AgentScope

定位差异: Spring AI 强在「接入抽象」, AgentScope 强在「Agent 运行时」

要的正运行时：原生 ReAct、Hook 门控、PlanNotebook 开箱即用

决定性主因：Java 技术栈一致 · 部署/CICD/监控无缝 · 与官方团队共建

实践验证：稳定支撑平台化 Agentic 落地

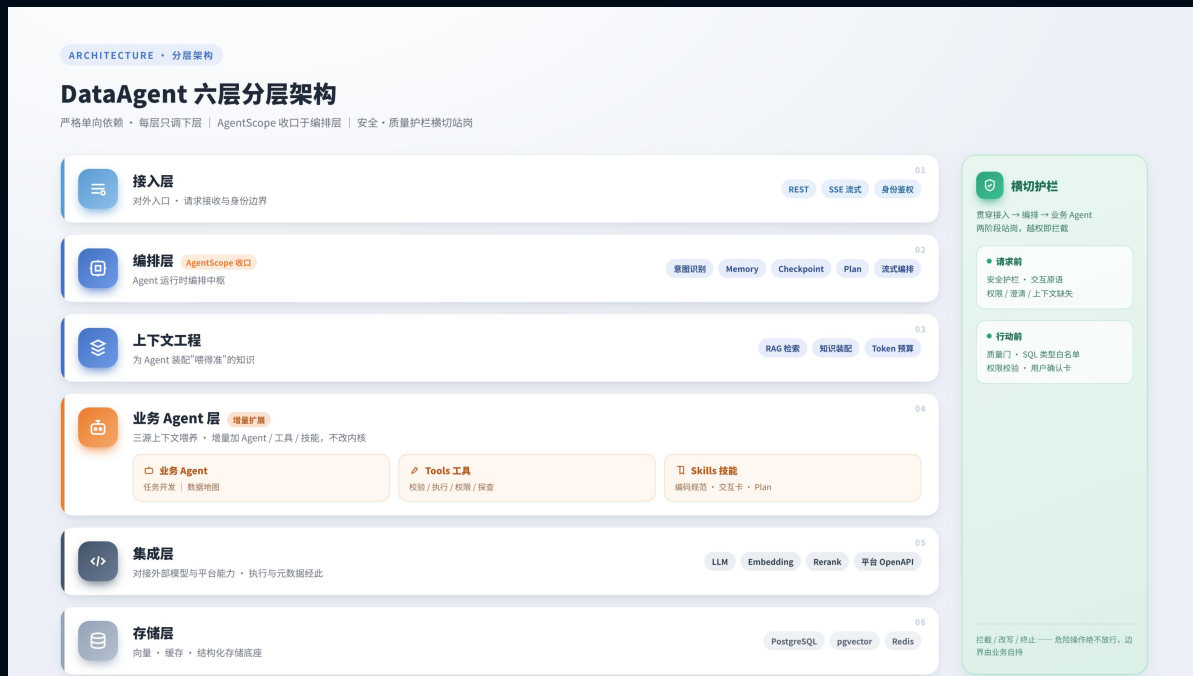


DataAgent 六层分层架构 + 横切护栏

六层严格单向依赖，禁止环依赖

业务 Agent 三源上下文：
Tools · Skills · RAG

横切护栏两阶段站岗：请求前 + 行动前



蓝 = 框架内核 · 橙 = 业务 Agent (含 Tools/Skills) · 绿 = 安全/质量护栏 · 箭头 = 严格单向依赖

全链路 Harness: Agent 编织进数据加工链路

DataFun.

AGENTIC AI
超级智能体系架构峰会

不是外挂聊天窗，而是介入
建模→开发→校验→发布→质
量→运维

左翼上下文工厂「喂得准」，
右翼评测飞轮「改得对」

中心内核在受控边界里「敢
执行」



全场主线三角：喂得准 × 改得对 × 敢执行

三服务协同：职责边界与调用闭环

DataPilot 做基座 | DataAgent 长其上 | DataBench 在旁护航

基座供给：平台经 OpenAPI 提供知识与执行

依托生长：Agent 只管编排/意图/Plan/上下文

护航驱动：Trace 上报 → 评测回归 → 反向迭代



03

落地挑战与 解决思路

喂得准 · 改得对 · 敢执行



从 Demo 到生产：三大落地挑战

① ReAct 可靠性：元数据幻觉、推诿跳过工具、高危误操作

② 工程集成：流式中断丢消息、跨线程上下文、Plan 跨请求恢复

③ 效果量化：改好还是改坏，缺一把可信的标尺

下面用「三支柱」逐一回应

LANDING CHALLENGES · 落地挑战

从 Demo 到生产：真正撞到的三类坎

每一类都实打实 fix 过 —— 下面按解决思路逐一回应

挑战一

ReAct 链路可靠性

不是教科书式“编造工具名”，而是更具体的三种

- 元数据幻觉
伪造不存在的函数名 / 字段
- 推诿 / 跳过工具
逻辑不通，反复套参数，直接喊苦累
- 高危操作
SQL 注入 / DOS 攻击

挑战二

生产级工程集成

框架给运行时，工程细节要自己兜住

- 流式拼接与中断
SSE 中断丢消息
- 跨线程上下文丢失
跨步执行丢失会话上下文
- Plan 跨请求恢复
多次请求间的状态衔接

挑战三

金融场景评测量化

把“效果好不好”变成可追踪的工程问题

- 效果无标尺
没好没坏说不清
- 难以归因
不能发现归因“模型能力不强”
- 回归无基线
缺少可复现的评测锚

三类挑战恰好对应三支柱 —— 锚得准，改得对，能执行，下一页给出映射

解决思路总览：三支柱 ↔ 三挑战

- 敢执行 | 能力：意图 · 生成执行 · 门控 · Plan
- 喂得准 | 上下文：上下文工程 + 上下文工厂
- 改得对 | 评测：评测飞轮 + LLM 评委



意图识别：先便宜后贵、逐层短路

短路优先：前端带意图 / 指定业务域，直接跳过分类

串行三层：L1 规则（毫秒拦截）→ L2 LLM 分类 → L3 安全护栏

现状规模：2 个业务域、20 个一级意图

扩能力只在路由表加处理器，内核不动

INTENT - 意图识别

先便宜后贵、逐层短路的意图路由

编排层第一道关 · 短路优先 → 串行三层 → 汇聚路由表



代码生成 + 执行闭环：自动落盘与版本回退

生成 → 多层校验 → 执行 → 报错回流纠偏，形成闭环

自动落盘：只覆盖开发版草稿，生产版本零污染

Checkpoint：会话内快照，随时回退历史版本

交互卡（HITL）：权限 / 澄清 / 高危变更，人工确认才继续

CODE LOOP · 生成执行闭环

生成 → 校验 → 执行 → 纠偏，自动落盘 + 版本回退

报错回流形成闭环 · 只改开发版不污染生产 · 每次交付存快照可回退



代码生成 · SQL 交互卡

广告活动数据回溯表含义

```
SUM(CAST(cost AS DOUBLE)) AS cost,  
SUM(CAST(app_installs AS DOUBLE)) AS app_installs  
FROM  
[redacted]  
WHERE  
  dt >= '${p7_date}'  
  AND dt <= '${p_date}'  
  AND provider = 'G'  
GROUP BY  
  stat_date  
ORDER BY  
  stat_date
```

说明

维度

详情

数据源

筛选条件 provider = 'G' (Google 广告平台)

时间范围 \${p7_date} ~ \${p_date} (最近 7 天)

聚合粒度 按 stat_date (数据统计日期) 分组

输出指标

注意：由于表中指标字段类型为 string，SQL 中已通过 CAST(... AS DOUBLE) 转换后再做 SUM 聚合，确保数值计算正确。

● 已完成 查询Google广告最近一周数据

✓ 编写聚合查询SQL

✓ 校验SQL语法

✓ 交付代码卡片

描述目标，我会先制定计划...

+ qwen3.7-max v

PLAN v



工具门控：把边界站在「行动前」

执行前先过质量门 / 安全栅栏，而非事后补救

SQL 类型白名单：放行
SELECT/INSERT/只读，拒绝
DDL/DELETE/UPDATE

四出口分流：直接拒绝 · 改写自愈 · 交互卡 · 安全放行

「能不能执行」沉淀成规则，不靠模型自觉



工具门控·权限卡/确认卡

会话

搜索会话...

生成...骨架

annika_test

14:09

撰写...告

cn_data_platform_datap...

2026-06-09

撰写...告

cn_data_platform_datap...

2026-06-09

分析...容

cn_data_platform_df_dw...

2026-06-09

月度...设计

cn_data_platform_datap...

2026-06-09

deb...品目录数据指标表

cn_data_platform_datap...

2026-06-09

新会话

cn_data_platform_df_ta...

2026-04-09

没有更多了

生成...骨架

✦ DataPilot 14:09

> Thought for ...

👤 You 14:09

确认执行

✦ DataPilot 14:10

> Thought for 96.6s

请在交互卡片中进行选择后继续。

✖ 失败 生成 INSERT 骨架 SQL

✅ 编写 INSERT 骨架 SQL

✅ 校验 SQL 语法

📄 查看 Plan

↔ 对比 草稿 × 线上

✖ 暂无访问权限

权限校验未通过，请先申请下列表的访问权限: cn_data...

缺失只读权限 cn_data...

📄 申请表权限

描述目标，我会先制定计划...

+ qwen3.7-max

生成 INSERT 骨架 SQL

背景与目标

根据 d... 表结构，生成一个 INSERT INTO ... SELECT 形式的骨架 SQL。每个字段使用 NULL 占位，并以字段注释作为行内注释标注（注释占位）。INSERT 目标表只写表名（不带库名），SELECT 部分无 FROM 子句（用户后续替换为实际来源表），方便用户在此基础上填充数据来源。

预期产出

生成包含全部 53 个字段、注释占位的完整 INSERT INTO 骨架 SQL，通过 Spark SQL 语法校验，以 code_card 交付给用户。

执行步骤

✅ 编写 INSERT 骨架 SQL — 根据已获取的 d... 表结构（53 个字段），生成 INSERT INTO d... (字段列表) SELECT NULL AS 字段名 形式，每个字段上方添加其字段注释作为占位注释，不含 FROM 子句，末尾加注释说明需替换为实际来源表。

✅ 校验 SQL 语法 — 调用 validate_spark_sql 校验生成的 INSERT 骨架 SQL 是否语法正确，若有错误则修正后重新校验。

注意事项

• 当前状态: ABANDONED

• 执行进度: 2/2

• 执行结果: STOPPED: Agent 退出但未调用 finish_plan

Plan 模式：人机协同 + 三轨持久化

如何进入：由运行模式决定，
与复杂度无关、非模型自主

两阶段状态机：规划 → 硬停
等确认 → 自动执行

三轨持久化：对话记忆 · 会话
快照 · 计划独立存储



▶ AgentScope 管运行时，Plan 真值业务自己存

Plan 模式 · 计划草稿卡片

广告活动数据回溯表含义

聚合粒度 按 stat_date (数据统计日期) 分组

输出指标

注意: 由于表中指标字段类型为 string, SQL 中已通过 CAST(... AS DOUBLE) 转换后再做 SUM 聚合, 确保数值计算正确。

● 已完成 查询Google广告最近一周数据

✓ 编写聚合查询SQL

✓ 校验SQL语法

✓ 交付代码卡片

查看 Plan

与 对比 草稿 x 线上

9dffeeb08a6648be9b6e625b723fa697

You 10:59

我要统计每家供应商的, 近30日数据以及 需要按照 展示数计算 各家供应商 占比, 同时 按照占比倒排

DataPilot 10:59

> Thought for 53.7s

● 待执行 供应商近30日广告数据占比统计

查看 Plan

开始执行

0/2 ^

描述目标, 我会先制定计划...

+ qwen3.7-max

PLAN

供应商近30日广告数据占比统计

背景与目标

基于 表, 统计所有广告供应商 (provider) 近30日的广告投放核心指标, 并计算各供应商展示数占总展示数的比例, 按占比倒序排列。

关键参数:

- 时间范围: 近30日 (dt >= \${p30_date} AND dt <= \${p_date})
- 聚合维度: provider (供应商)
- 核心指标:
- 占比计算: (百分比, 保留2位小数)
- 排序: 按占比倒序
- 字段类型: string 类型指标字段需 CAST AS DOUBLE 后聚合

预期产出

生成完整的 Spark SQL 查询语句, 按供应商聚合近30日广告数据, 包含展示数占比字段, 按占比倒序排列, 并通过语法校验

执行步骤

- ☐ 校验SQL语法 — 调用 validate_spark_sql 校验完整的 Spark SQL 语句
- ☐ 交付代码卡片 — 通过 show_interaction_card(code_card) 交付最终可执行 SQL 给用户

注意事项

- 当前状态: TODO
- 执行进度: 0/2

Plan 模式 · 计划完成

广告活动数据回溯表含义

```
> check_task_edit_lock 工具 check_task_edit_lock 已完成
> update_subtask_state 工具 update_subtask_state 已完成
> validate_spark_sql SQL 语法校验已完成
> finish_subtask 工具 finish_subtask 已完成
> update_subtask_state 工具 update_subtask_state 已完成
> evaluate_plan_progress 偏差评估已完成
> show_interaction_card 交互内容已就绪
> finish_subtask 工具 finish_subtask 已完成
> finish_plan 工具 finish_plan 已完成
> evaluate_plan_progress 偏差评估已完成
```

计划已全部完成 ☒。代码已自动写入任务编辑器。

生成的 SQL

```
WITH base AS (
  SELECT
    provider,
    SUM(CAST(impressions AS DOUBLE)) AS impressions,
    SUM(CAST(clicks AS DOUBLE)) AS clicks,
    SUM(CAST(cost AS DOUBLE)) AS cost,
    SUM(CAST(app_installs AS DOUBLE)) AS app_installs
  FROM
```

描述目标，我会先制定计划...

供应商近30日广告数据占比统计

背景与目标

基于 [redacted] 数据，统计所有广告供应商 (provider) 近30日的广告投放核心指标，并计算各供应商展示数占总展示数的比例，按占比倒序排列。

关键参数：

- 时间范围：近30日 (dt >= \${p30_date} AND dt <= \${p_date})
- 聚合维度：provider (供应商)
- 核心指标：[redacted]
- 占比计算：[redacted] × 100 (百分比，保留2位小数)
- 排序：按占比倒序
- 字段类型：string 类型指标字段需 CAST AS DOUBLE 后聚合

预期产出

生成完整的 Spark SQL 查询语句，按供应商聚合近30日广告数据，包含展示数占比字段，按占比倒序排列，并通过语法校验

执行步骤

- ☐ 校验SQL语法 — 调用 validate_spark_sql 校验完整的 Spark SQL 语句
- ☐ 交付代码卡片 — 通过 show_interaction_card(code_card) 交付最终可执行 SQL 给用户

注意事项

- 当前状态：TODO
- 执行进度：0/2

上下文工程：两层装配 + 动态 Token 预算

两层装配职责切开：编排前装代码/摘要/引用；schema 与知识留到 ReAct 按预算装

好处：避免编排层与运行层两套 Token 配置漂移

表名精确预取 + 精简模式，语义知识按需调工具拉

预算降级：先裁 RAG 知识 → SQL 换占位 → 最后整体截断

对话历史独立治理：滑动窗最近 x 轮 + 超阈值摘要压缩



上下文工厂：从源头规范化到多领域知识库

源头规范化：数据探查 → LLM 元数据推荐 → 人工复核 (AI + 人 双保险)

按业务域沉淀：表 / 字段 / 指标 / 枚举
组织成数仓知识库

保新鲜：增量同步 Agent RAG,
Schema 变更触发更新

分工：数仓定义知识、Agent 消费知识——真值在业务手里



上下文工厂·字段元数据推荐

level

上下文完善度 100% | 已确认字段 13 / 13

数据库 / 数仓分层 DWD / 表负责人

展开

表级上下文

DWD层风控用户等级明细表，记录用户在不同评分类型下的风险等级信息。按日全量快照存储

字段 11

数据预览

血缘

创建表语句

脚本信息

搜索字段名或描述...

状态 全部

#	字段名	类型	字段描述	标准字段	枚举映射	状态
1	loan_account_id	STRING		已关联标准字段	—	已确认
2	type	STRING		已关联标准字段	USER_1 = / C_ / C_	已确认
3	type_name	STRING		—	/ C_ NULL = 空值	已确认
4	level	STRING		—	F = / J = 1 A = A	已确认
5	status	STRING		已关联标准字段	I =	已确认
6	created_ts	BIGINT	创建时间戳	—	—	已确认
7	updated_ts	BIGINT	更新时间戳	—	—	已确认
8	sdk_type	STRING		已关联标准字段	H =	已确认
9	config_id	STRING		—	—	已确认
10	trigger_ts	BIGINT		—	—	已确认

资产信息

表所属国家
数据更新方式
最新分区
行数
大小
分区字段

dt=2026070

时间信息

表更新时间
审核时间
审核人

2026-01-16 16:13:5
2026-06-23 20:13:0
审核人

上下文工厂·人工复核队列

DataFun.

AGENTIC AI
超级智能体系系统架构峰会

目 元数据

图 治理中心

☑ 标准字段

📄 业务术语

🔊 生产流水线

🏠 工作台

生产流水线工作台

集中处理 AI 生成的元数据候选，按资产进入字段聚合审核页。

16 / 29
已完善资产

55%

0 张 · 0 项
今日已审核
[查看今日已审核](#)

19 张
待审核
1,043 项 AI 产出待处理

数据表搜索

表负责人

全部

审核人

全部

提交人

全部

状态

全部

置信度

全部

资产	数仓分层	产出规模	状态	置信度	表负责人	审核人	提交人	时间	操作
payment phi_dwd	DWD	45项 / 30 字段	待审核	98%		—		提交 2026-07-10 13:36 审核 —	审核 废弃
_info phi_dwt	DWT	42项 / 40 字段	待审核	86%		—		提交 2026-07-10 11:40 审核 —	审核 废弃
prod ods_cn	ODS	10项 / 8 字段	待审核	85%		—		提交 2026-07-10 11:39 审核 —	审核 废弃
_n_detail dwa_cn	DWA	185项 / 103 字段	待审核	95%		—		提交 2026-07-10 11:13 审核 —	审核 废弃
_detail phi_dwd	DWD	127项 / 87 字段	待审核	93%		—		提交 2026-07-09 20:53 审核 —	审核 废弃
_detail phi_dwd	DWD	127项 / 87 字段	已废弃	92%		—		提交 2026-07-09 20:22 审核 —	查看
_r_level phi_dwd	DWD	19项 / 11 字段	已废弃	96%		—		提交 2026-07-09 19:59 审核 —	查看
_level phi_dwd	DWD	18项 / 11 字段	已废弃	96%		—		提交 2026-07-09 19:44 审核 —	查看

数据飞轮：线上问题自进化为评测样本

线上调用 → 一键转用例 →
回归重放 → 三类打分 → 驱动
迭代

闭环底座：全链路追踪打业务
标签，线上/评测流量隔离

只认结构化卡片里「被采纳
的 SQL」作标准答案



虚线『优化上线』回到线上，形成自进化闭环


四层执行：评测方案 → 回归批次 → 单用例 → 单次执行

快照锁定中间两层：改了评测集，历史结果仍可复现

自动打分：语法校验 + 结果集行级对比

LLM 评委：把「意图理解 / SQL 质量」等主观维度量化

踩坑：失败用例也要「早退」打分，否则永远卡在待打分



ench评测集被测对象评测任务Trace 工作台

国内

过程树

15 steps

Agent invoke_agent TaskDevelopmentReAct

Success 72.72s Token -

LLM chat qwen3.7-max

Success 10.03s Token 15,270

Tool execute_tool check_task_edit_lock

Success 119ms Token -

LLM chat qwen3.7-max

Success 10.26s Token 15,300

Tool execute_tool update_subtask_state

Success 36ms Token -

Tool execute_tool validate_spark_sql

Success 172ms Token -

Tool execute_tool finish_subtask

Success 41ms Token -

Tool execute_tool update_subtask_state

Success 1ms Token -

Tool execute_tool evaluate_plan_progress

Success 2ms Token -

Agent invoke_agent TaskDevelopmentReAct

696f05560414f5c7

基本信息 Raw JSON

基本信息

Type Agent

Status Success

Duration 72.72s

Agent TaskDevelopmentReAct

模型 qwen3.7-max

Thinking

The previous plan has already been finished successfully. The user's last message seems to be a system-triggered follow-up. Let me check what's happening - it seems like the system is re-sending a message after the plan was already completed.

Looking at the history, the plan was already finished with 'finish_plan(state="done")'. All subtasks were completed and the code was delivered.

This appears to be the system sending another turn after the plan completion. There's no new user message to respond to. Let me check if there's anything I need to do.

Wait, looking more carefully, the last message in the conversation is the 'evaluate_plan_progress' result from subtask #0. The plan was already marked as done. This seems like the system is prompting me again.

Since the plan is already finished and all subtasks completed, I should provide a brief summary confirming everything is done. There's no new user request to handle.

Response

计划已全部完成 , 代码已自动写入任务编辑器。

生成的 SQL

```
```sql
WITH base AS (
```

评测集 / Test 测试SQL 集

## Test 测试SQL 集

用例数 4  
创建时间 2026/6/9 19:48:03

用例列表 维度配置

### 评测维度配置

启用	维度名	类型	一句话简介
<input checked="" type="checkbox"/>	SQL 可执行性	自动	Spark SQL 语法解析是否通过
<input checked="" type="checkbox"/>	结果集一致性	自动	Gold SQL 与 Agent SQL 的结果集对比
<input checked="" type="checkbox"/>	意图理解	人工	
<input checked="" type="checkbox"/>	SQL 质量	人工	

\* 模型

llm3.7-max

预设模板

意图理解准确性

可用变量

请求信息

{{user\_prompt}} 用户原始问题

{{agent\_sql}} Agent 最终输出 SQL

评测用例

{{gold\_sql}} 标准答案 SQL

{{context}} 辅助上下文 / 业务背景

{{difficulty}} 难度标签

Judge Prompt \*

测试运行

你是一个 SQL 评测专家。请判断 Agent 生成的 SQL 是否正确理解了用户的意图。

## 用户问题  
{{user\_prompt}}

## Agent SQL  
{{agent\_sql}}

## Gold SQL  
{{gold\_sql}}

{{#context}}  
## 业务背景  
{{context}}  
{{/context}}

# 04

## 未来演进 与总结

团队共建 · 横向扩展蓝图



# 团队共建：平台 × 数仓，缺一不可

痛点：平台研发离一线业务远——懂框架，不懂业务口径

贴近真实场景：真实任务 / 痛点 / 口径由数仓输出

评测与数据共建：标准答案、评测口径、历史样本靠数仓把关

SOP 沉淀为技能模板：Agent 按公司规矩产出



▶ 数仓管真值、标准与知识，平台管编排、工程与护栏

# 总结与挑战：架构立住了，但仍在路上

已立住：分层架构 + 全链路 Harness + 喂得准/改得对/敢执行 三支柱

待补齐：Prompt 调优管理 · 工具治理 · 长程任务 · 数据持续迭代

横向展望：一个底座多领域生长（数据地图已上线，运维/质量规划中）

纵向深化 + 横向扩展，才是长期可用的关键



▶ AgentScope 管运行时，业务管真值与边界



# THANKS

王博 · 瓴岳科技

---



扫码交流，欢迎一起讨论