

从自动化到自进化 —— 大数据运维 Agent 实践与思考

演讲嘉宾：熊伟

目录

CONTENT

- 01 困境与破局：为何做运维智能体**
- 02 架构与演进：如何做运维智能体**
- 03 核心场景实践：典型场景案例**
- 04 总结与展望：智能的运维新生态**

01

困境与破局：为何做运维智能体

传统运维的“结构性困境”：告警风暴与被动响应



01 告警风暴 (Alarm Storm)

底层单一故障引发系统级连锁反应，瞬间产生成百上千条冗余告警。运维人员陷入“告警海洋”，无法快速分辨主次与根因，导致故障定位效率大幅降低，平均修复时间（MTTR）显著增加。



02 被动响应 (Passive Response)

运维团队长期扮演“救火队”角色，仅在故障发生并造成业务中断后才介入处理。这种“事后补救”的模式使得业务损失（如用户流失、交易失败）已成既定事实，缺乏事前的风险感知与主动预防机制。

80%

计划外停机的核心诱因

Gartner 2025年研究数据表明，绝大多数非计划停机并非源于硬件故障，而是由人为操作失误、流程管理漏洞及配置变更不当直接引发。

42%

技术中断的首要归因

超过四成的系统非预期中断可直接追溯至内部配置变更错误、参数误设或部署流程不规范，而非外部攻击或不可抗因素，暴露了运维管理的脆弱性。

传统运维的“结构性困境”：效率低下与经验依赖

01 故障定位难，耗时巨大

面对海量分散的监控指标、日志与链路数据，工程师如同“大海捞针”般排查问题。据行业统计，根因分析环节占据了故障处理总时长的70%以上，大量有效工作时间被浪费在信息检索、交叉验证与反复试错上，严重拖慢了业务恢复的速度。

02 专家依赖与知识断层风险

核心系统的故障排查高度依赖少数资深专家的个人经验与直觉，缺乏标准化的诊断流程与可复用的知识沉淀机制。这种“人治”模式不仅造成了响应瓶颈，更存在巨大的知识断层风险——一旦关键人员变动，系统的稳定性保障能力将面临断崖式下跌。

1 - 2 小时

行业平均 MTTR

传统运维模式下，从故障发生到业务完全恢复的平均耗时，往往远超业务的容忍阈值。

15 - 30 分钟

世界级标杆 MTTR

头部科技企业依托全链路可观测性与自动化自愈体系，实现的极致故障恢复速度。

> 30 分钟

故障定位平均耗时

83%的企业在此环节陷入停滞，根因分析成为故障处理流程中最大的效率瓶颈。

从“人力密集”到“数据驱动”的必然选择

01 预见性 Predictive

从被动响应转向主动预测，通过多模态数据与时序分析，将隐患掐灭在萌芽。

02 自动化 Automated

从重复堆人力转向机器自主执行，释放人力去做架构优化与技术创新。

03 洞察力 Insightful

从凭经验猜转向大数据关联诊断，挖掘海量指标背后的根因，为资源调度和架构优化提供决策支持。

STEP 01 · 数据驱动基础化

打破监控孤岛，构建统一的数据采集与可视化平台，实现全链路数据的标准化治理与实时监控。

STEP 02 · AI模型智能化

引入机器学习算法，实现智能异常检测、告警聚合降噪，以及基于关联图谱的根因自动分析。

STEP 03 · 智能体自主进化

具备自然语言交互能力，理解复杂业务意图，实现跨域协同的自主决策、自动执行与自我优化。

02

架构与演进：如何做运维智能体

智能体的角色定位：解放人的“数字化工程师”

01 核心价值：重塑人机协作边界

解放人力

将工程师从重复配置、例行巡检等机械性工作中释放，专注于高价值的架构创新与研发。

经验复制

将专家的隐性排障经验转化为显性的自动化规则与模型，打破个人能力瓶颈，实现经验复用。

极致效率

7x24小时不间断自主巡检与处置，故障响应速度提升10倍以上，大幅缩短平均修复时间。

降低风险

严格遵循标准化执行流程，消除人工操作的疏忽与误判，从源头降低系统运行的安全隐患。

02 技术理念：规则与模型的双轮驱动

规则先行：确定性的基石

负责划定**逻辑清晰、边界明确**的标准化任务（如资源阈值告警、常规配置），通过硬编码规则实现毫秒级响应。优势在于结果可控、无幻觉、可解释性强，是系统稳定运行的压舱石。

大模型辅助：智能的延伸

面对**非线性、模糊复杂**的场景（如根因分析、异常检测），利用AI模型挖掘数据隐式关联。优势在于从复杂日志和多源数据中进行根因推断、语义理解与意图拆解，实现从被动运维向主动智能的进化。

智能体能力覆盖全景



01 优化治理

核心方案：基于AI预测的智能容量规划，实时检测配置漂移，实现资源动态调度与基线校准，避免资源浪费。

核心成效：资源利用率提升**20-30%**，整体IT运营成本直接节约**15%**。



02 日常运维

核心方案：部署全链路自动化巡检机器人，利用NLP技术进行告警自动分诊、降噪与关联分析，过滤无效干扰。

核心成效：巡检耗时从2小时缩短至**5分钟**，无效告警数量大幅减少**90%**。



03 故障管理

核心方案：基于知识图谱与因果推断的智能根因定位，配合自动化运维剧本，实现故障的分钟级诊断与自愈。

核心成效：平均修复时间(MTTR)降至**15分钟**，超**60%**常见故障实现无人干预自愈。



04 价值提升

核心方案：实时业务影响范围分析，基于流量画像与日志的深度挖掘，智能识别性能瓶颈并提供优化建议。

核心成效：故障影响评估实现秒级响应，核心业务接口性能整体优化提升**15%**，提升用户体验。

协同工作的智能体系：LLM + MCP + Ansible

01 发起请求

用户通过自然语言下达运维指令，支持模糊语义与复杂场景需求，无需掌握专业代码。

02 意图理解

LLM作为“大脑”深度解析用户意图，将非结构化的自然语言拆解为可执行的结构化任务。

03 安全转译

MCP充当“翻译官”与“安全网关”，将任务转为标准化API，执行严格的鉴权与风险校验。

04 自动执行

Ansible作为“手臂”，接管具体的基础设施操作，自动化完成配置、部署、监控与修复。

05 结果闭环

执行结果实时回传，由LLM将技术日志转化为自然语言总结，清晰反馈结果。

技术架构执行闭环



用户交互终端

输入层：提供自然语言接口，支持语音或文本交互，是智能运维的起点。



LLM 决策中枢

处理层：理解用户意图，将非结构化需求转化为结构化的运维任务清单。



MCP 管控网关

控制层：将任务转为标准API调用，并提供**权限验证、参数校验**，确保操作安全合规。



Ansible 执行器

执行层：自动化操作的“双手”，直连服务器，接管基础设施，可靠执行具体的运维操作。



执行结果回传闭环

03

核心场景实践：典型场景案例

3-1、Hadoop集群自愈智能体：闭环处置，秒级恢复

背景与挑战：在 Hadoop 生产集群中，磁盘根目录爆满、核心服务异常是最高发的两类故障场景，亟需构建一套自动化、闭环式的故障自愈体系，实现核心故障的主动监测、自动处置与结果反馈，从根源上降低集群故障发生率与业务影响。

01 磁盘根目录爆满，节点故障风险高

主机磁盘使用率常无预警激增，根目录爆满会直接导致节点服务不可用、集群读写异常。人工巡检与清理的响应滞后，极易引发单节点宕机并扩散为集群级故障，严重威胁数据安全与业务连续性。

02 核心服务异常，业务中断影响大

HiveServer2等核心组件一旦出现节点无响应、连接超时或服务崩溃，上层数仓SQL查询与分析任务将直接中断。人工排查依赖经验，服务重启与状态恢复流程繁琐，导致业务中断时间长，直接影响数据决策效率。

03 人工处置效率低，重复性工作多

日常运维中，磁盘清理、服务重启、日志排查等操作高度依赖人工逐节点登录执行，不仅响应时效慢，还容易因人为误操作引发次生故障。大量重复性、低价值的工作占用运维团队精力，使其难以聚焦于架构优化与主动治理。

04 故障处置无闭环，风险重复发生

故障临时恢复后缺乏标准化的效果验证与根因分析，也无自动通知与复盘机制。同类问题反复出现，运维团队陷入“救火式”被动循环，缺乏可复用的自动化处置能力，无法形成故障发现、定位、修复、验证的完整治理闭环。

3-1、Hadoop集群自愈智能体：闭环处置，秒级恢复

技术方案：智能体以「故障监测 - 自动处置 - 结果验证 - 通知反馈」为核心逻辑，打造磁盘根目录自愈、HiveServer2自愈两大核心模块，同时配套标准化工作流与工具插件底座，实现故障全流程闭环处置。

01 故障监测

实时采集，精准监督集群故障

02 自动处置

实时采集，精准监督集群故障

03 结果验证

闭环执行健康检查

04 通知反馈

生成结构化恢复日志

运维能力三层架构体系

应用层 · 核心场景覆盖

聚焦两大高频故障：磁盘根目录自动扩容与清理、HiveServer2服务异常重启。实现从单点故障到服务可用性的全面自愈保障。

能力层 · 自动化执行引擎

构建“监测-决策-执行-验证”的智能闭环引擎，包含故障精准识别算法、自动处置执行器及效果校验模块，确保每一步操作可追溯、可回滚。

底座层 · 标准化支撑体系

沉淀4套通用故障处置工作流与3个核心运维插件，结合智能异常分析模型，为上层应用提供灵活的编排能力与稳定的技术基座。

核心技术价值亮点



场景化定制：无损自愈策略

针对磁盘爆满，独创“先移动后压缩”策略，保障数据零丢失；针对服务异常，建立“探测-重启-健康检查”的闭环机制，避免无效操作。



轻量化探针：无侵入零干扰

采用直连探针模式，无需在集群节点安装额外Agent，不占用计算资源。毫秒级感知服务状态与磁盘水位，在不影响业务运行的前提下实现精准告警。



标准化底座：降本增效引擎

模块化设计让新场景接入效率提升60%，预置的工作流与插件库，不仅降低了开发门槛，更实现了运维经验的资产化沉淀与快速复用。

3-1、Hadoop集群自愈智能体：闭环处置，秒级恢复

核心价值与成效



故障处置效率 +900%

从人工处置的“小时级”缩短至自动化的“分钟级”，大幅降低业务中断风险，保障集群高可用。



运维人力成本 -60%

自动化替代人工重复排查与处置，释放运维精力聚焦架构优化与技术创新，实现降本增效。



故障自愈成功率 = 100%

覆盖全场景故障测试，识别精准度与自动处置执行率均达生产标准，实现零人工干预可靠运行。

01 运维模式全链路重塑

传统模式

人工巡检 → 指标排查 → 日志翻查 → 人工研判 → 手动执行，链路冗长，响应滞后，极易导致故障扩散。



智能模式

实时监测告警 → AI根因诊断 → 自动匹配预案 → 一键执行处置 → 结果自动通知，各步骤毫秒级响应，化被动为主动。

02 规模化落地与场景覆盖

新场景落地效率 +200%

基于标准化工作流引擎与插件化工具底座，新自愈场景开发周期缩短60%，快速适配业务增长带来的新需求。

核心场景验证

已稳定覆盖磁盘根目录自动清理、HiveServer2服务自动恢复两大核心场景，在生产集群长期运行无异常。

3-2、Hadoop集群管家智能体：打破孤岛，自然交互

背景与挑战：在 Hadoop 集群日常运维中，运维数据分散在多套系统中，数据不互通、查询不便捷、分析不智能的问题，已成为制约运维效率与集群稳定性提升的核心瓶颈，亟需构建一套统一、智能的集群运维信息查询与分析入口。

01 运维数据分散，多系统切换繁琐

集群信息、监控指标、巡检结果分散在CMDB、监控平台、巡检工具等多套系统中，运维人员需频繁切换系统，信息获取效率极低，严重拖慢响应速度。

02 集群信息查询门槛高，效率低

复杂的集群元数据与运行信息需通过SQL查询或后台命令行获取，对运维人员技术要求高，日常查询耗时久，无法快速响应业务与运维的即时需求。

03 故障定位难，根因分析耗时长

故障发生时需手动跨系统关联日志、监控、配置数据排查，无法实现多维度数据的自动联动分析，根因定位周期长，易导致业务影响持续扩大。

04 风险识别滞后，被动响应式运维

依赖人工定期巡检发现集群异常，无法主动关联多维度数据识别潜在风险点，运维模式偏被动，难以提前规避集群性能劣化与故障风险。

3-2、Hadoop集群管家智能体：打破孤岛，自然交互

技术方案：以全量运维数据为底座，以自然语言交互为核心，构建集数据统一汇聚、智能查询分析、风险主动识别于一体的一站式集群运维解决方案，实现运维操作从「多系统切换」到「一站式搞定」的效率飞跃。

01 数据汇聚

全量采集 · 统一治理存储

02 智能查询

SQL · 自然语言交互

03 风险识别

多维关联 · 主动异常预警

04 一站式运维

决策辅助 · 闭环管理落地

运维能力三层架构体系

应用层 · 核心场景覆盖

覆盖集群信息智能查询、故障根因分析、风险主动识别及运维决策建议输出，直接解决日常运维的高频痛点。

能力层 · 自动化执行引擎

依托自然语言SQL引擎、多维度关联分析模型、异常检测算法及运维知识图谱推理，实现智能化的“大脑”驱动。

底座层 · 标准化支撑体系

打通CMDB资产、监控指标、巡检报告及集群元数据，实现多源异构数据的标准化汇聚与治理，夯实数据基础。

核心技术价值亮点



全量数据融合，打破信息孤岛

整合CMDB、监控工具、巡检系统的分散数据，消除数据壁垒，为智能分析提供完整、实时的数据支撑。



自然语言交互，降低技术门槛

无需编写复杂SQL或学习工具指令，运维人员通过日常口语即可查询集群状态与指标，大幅降低操作门槛。



主动风险治理，变被动为主动

基于多维度数据关联分析，自动识别异常节点、资源瓶颈等潜在风险，同步输出针对性排查与优化建议。

3-2、Hadoop集群管家智能体：打破孤岛，自然交互

核心价值与成效



信息查询效率 +500%

告别多系统切换与手动检索，通过自然语言交互实现集群信息秒级获取，将查询效率提升5倍以上，释放运维人力。



故障定位时长 -80%

多维度日志与指标自动关联分析，故障根因定位从“小时级”压缩至“分钟级”，极大降低业务中断风险与损失。



运维操作门槛 -90%

以自然语言替代复杂的HDFS/YARN命令与SQL查询，零基础运维人员亦可快速上手，完成复杂的集群诊断与风险排查。

01 运维模式：从「被动响应」到「主动智能」

传统模式

多系统切换 · 人工排查
依赖经验 · 事后补救



智能模式

一站式入口 · 自动分析
主动预警 · 闭环处置

重构运维 workflow，将运维人员从重复的查询和排查中解放，专注于更高价值的架构优化与治理工作。

02 决策赋能：从「经验驱动」到「数据智能」

风险识别能力 +300%

从“人工巡检”到“AI全天候感知”，提前识别潜在隐患，防患于未然。

决策科学化

基于全量数据的智能研判，输出可量化的优化建议，支撑精准决策。

不仅是执行工具，更是“运维大脑”，为集群稳定性保障与性能优化提供持续的、可落地的决策支持。

3-3、Hadoop配置智检智能体：全量比对，事前防爆

背景与挑战：配置是 Hadoop 集群稳定运行的核心基石，传统运维模式下，配置全流程管理缺少智能化工具支撑，校验效率低、风险发现慢、知识获取难、优化无依据，亟需一套专注配置识别、分析、辅助决策的智能体，实现配置风险的前置管控与运维效率提升。

01 配置一致性失控，故障定位难

Ambari前台展示配置与节点后台真实生效配置、实际运行日志记录的配置存在差异，人工巡检无法做到全覆盖与实时性，导致因配置不一致引发的集群故障排查耗时耗力，严重影响业务稳定性。

02 配置风险识别滞后，无主动预警

传统模式依赖人工定期巡检，无法实现分钟级常态化监测，配置风险往往在引发业务故障、造成实际损失后才被被动发现，缺乏事前主动识别、实时告警与阻断的能力。

03 配置理解门槛高，误操作风险大

Hadoop生态组件参数繁杂、关联性强，运维人员难以全面掌握参数含义与影响范围，极易因配置修改不当引发业务故障，且缺乏便捷的配置语义查询、模拟验证与回滚渠道。

04 配置优化无依据，容量规划不准

配置优化依赖个人经验与零散文档，缺乏标准化、可量化的优化方案；集群扩容仅靠经验评估，无法结合配置现状、历史运行数据与业务负载趋势进行精准推荐，造成资源浪费或容量不足。

3-3、Hadoop配置智检智能体：全量比对，事前防爆

技术方案：聚焦配置全生命周期的识别与分析能力，通过多源配置自动采集、一致性校验、风险预警、智能问答及优化建议输出，打造一站式配置分析平台，实现从被动排查到主动治理的转变。

01 配置采集

多源数据自动汇聚

02 一致性校验

前后台全量比对

03 风险预警

异常主动识别告警

04 智能问答

自然语言交互查询

05 优化建议

可落地方案输出

配置管理三层架构体系

应用层·核心场景覆盖

提供多源配置一致性自动校验、配置异常风险智能预警、配置知识智能问答与优化建议输出四大核心能力，直接赋能运维日常配置管理与故障排查。

能力层·自动化执行引擎

依托配置比对校验引擎、大模型语义理解引擎与资源优化分析引擎，实现配置的智能解析、逻辑推理与决策支持，是智能体的“大脑”。

底座层·标准化支撑体系

汇集集群多源配置数据、资源监控指标、任务运行日志与业务负载数据，打破数据孤岛，构建配置分析与智能决策的全量数据底座。

核心技术亮点



多源配置自动比对

自动抓取前台展示与后台真实生效配置，全量自动化比对，精准识别配置漂移与一致性问题，分钟级完成全集群巡检。



风险事前主动预警

实时监测并识别配置异常与潜在风险，同步输出风险影响范围与根因详情，实现从“事后救火”到“事前防控”的转变。



大模型智能问答

内置完整配置知识库，支持自然语言交互查询配置含义、业务影响及约束，消除运维认知偏差，降低学习与沟通成本。



智能优化与容量规划

结合集群资源现状与业务负载，输出可落地的配置调优建议，智能评估容量水位，科学指导集群扩容或缩容决策。

3-3、Hadoop配置智检智能体：全量比对，事前防爆

核心价值与成效



配置巡检效率 +100%

人工小时级核对升级为自动化分钟级全量校验，彻底消除人工漏检隐患，实现集群配置巡检覆盖率100%，大幅释放运维人力资源。



风险识别提前率 +95%

在配置异常引发业务故障前实现主动识别与实时预警，推动运维模式从「事后救火」向「事前防控」转变，保障集群稳定性。



配置认知偏差率 -90%

建立标准化配置知识库，通过自然语言交互消除运维人员对参数的理解歧义，从源头规避因配置理解偏差导致的人为误操作风险。

01 运维范式：从被动到主动

传统人工模式：

依赖人工逐条核对，效率低且易漏检；故障发生后被动排查，缺乏前瞻性；配置查询分散，依赖个人经验积累。

智能主动模式：

自动化全量巡检，分钟级完成；AI主动发现潜在风险并预警；智能问答即查即得，数据驱动优化决策。

02 资源规划精准度提升 +25%

通过多维度运行数据的智能联动分析，替代传统的人工经验估算，让集群容量规划与参数调优更具科学性，避免过度配置或资源不足。

成本优化成效：在保障业务性能的前提下，显著减少资源闲置浪费，提升集群整体资源利用率，实现基础设施投入的价值最大化。

3-4、TOPSQL智能分析智能体：精准定界，智能重写

背景与挑战：TOPSQL是计算引擎稳定运行的核心基石，传统运维模式下，慢任务排查依赖人工经验，单次排查耗时30分钟+且难以系统性发现资源超配等隐蔽问题。

01 慢查询拖垮全局，定位耗时久

海量任务中识别烂SQL如大海捞针，单次排查分析执行计划往往超过30分钟。

02 资源超配极度隐蔽，浪费严重

业务方经常过度申请资源（如过大并发/内存），人工难以系统性甄别和纠正。

03 优化强依赖DBA经验，难以复制

看出问题不代表会改，重写SQL、调优参数强依赖极少数专家的隐性知识。

04 缺乏优化闭环，劣质任务反复跑

问题指出后缺乏追踪，业务方不愿改，导致同类劣质SQL持续侵蚀集群资源。

3-4、 TOPSQL智能分析智能体：精准定界，智能重写

技术方案：聚焦建立了一套涵盖数据、知识到应用的模型。不仅实时抓取性能最差的 SQL，更关键的是引入了大模型来做“语法树解析”。它能把复杂的执行计划“翻译”出来，不仅告诉你问题（比如全表扫描），还能直接给你写好优化后的 SQL 语句。

01 任务采集

Hive/YARN元数据汇聚

02 性能画像

构建性能视图

03 风险识别

识别Top 5 高风险烂SQL
及资源超配项

04 AI诊断

语法树解析结合专家规则
定性异常根因

05 智能重写

自动生成索引优化、参数
调优或重写代码

配置管理三层架构体系

应用层 · 核心场景覆盖

提供 TOPSQL 性能全景视图、多维风险识别与智能重写建议。

能力层 · 自动化执行引擎

大模型SQL语法解析树引擎 + 专家诊断规则库。

底座层 · 标准化支撑体系

实时采集 Hive 元数据、YARN 日志与底层任务执行指标。

核心技术亮点



全景性能画像

构建包含执行时长/CPU/内存/
扫描行数等多维度的SQL剖析图。



自动化重写代码

模型直接给出优化依据，并输出
可直接执行的重写/调优代码。



AI智能风险识别

自动对齐专家经验规则，
揪出全表扫描、数据倾斜
等暗病。

3-4、 TOPSQL智能分析智能体：精准定界，智能重写

核心价值与成效



排查定位效率 +600%

诊断定位从人工 30 分钟缩短至 AI 的 5 分钟。



异常发现率 =100%

从人工随机抽查升级为全量机器自动扫描覆盖。



智能闭环修复率 +90%

AI直接生成修改建议，从“仅发现”跨越到“辅助解决”。

01 模式转化

传统人工模式：

人工查日志拼凑指标 → 靠经验推测 → 业务方自己找方案。

智能主动模式：

全自动识别高风险 → 明确诊断依据 → 给出优化后代码。

02 计算资源利用率显著优化 +30%

过去由于业务线粗放式使用，海量计算资源被劣质任务长期霸占。智能体主动输出重写方案与合理并发参数，强力推动作业整改闭环。

成本优化成效：大幅削减无效的扫描行数与内存溢出重试，使得原本拥挤的集群队列恢复通畅，直接节省了千万级的底层计算节点扩容成本。

3-5、Hadoop集群健康度智能体：量化体检，全局溯源

背景与挑战：传统集群运维依赖人工经验排查，缺乏标准化量化评分体系，数据统计滞后、覆盖不全，难以提前识别潜在风险，排查效率低、主观性强，整体运维精准度与时效性较差。

01 健康评估无量化，主观性强

集群到底是“健康”还是“亚健康”？依赖运维直觉，缺乏标准化、量化评分体系。

02 指标统计滞后，覆盖不全

海量监控数据分散，传统手动统计耗时以天计，无法全量覆盖所有集群细分指标。

03 共性隐患发现难，缺乏全局视野

单点查故障容易，但难以横向对比多集群的共性衰退问题，缺乏宏观大盘视角。

04 “治未病”能力弱，缺乏指导

看出亚健康也难以对症下药，急需一套能自动给出综合调优与架构整改的智能体系。

3-5、Hadoop集群健康度智能体：量化体检，全局溯源

技术方案：聚焦建立了一套涵盖数据、知识到应用的评分模型。

01 全量采集

自动按月回溯抓取集群近
30项核心指标

02 数据聚合

清洗指标，对齐历史负载
趋势与警戒水位

03 量化打分

结合专家经验，动态进行
降维聚合与权重评分

04 AI会诊

多模态大模型判定“健康/
亚健康/不健康”

05 处方打分

针对扣分项自动输出系统
重构及扩缩容建议

配置管理三层架构体系

应用层 · 核心场景覆盖

全集群健康度自动打分大盘、异常项下钻分析与全局优化建议。

能力层 · 自动化执行引擎

动态权重评分模型 + 历史趋势异常检测 + 专家推理引擎。

底座层 · 标准化支撑体系

自动聚合近30天全量集群运行数据（含CPU、内存水位、HDFS健康度等）。

核心技术亮点



多项指标聚合评分

结合预设分级阈值，构建标准化的健康度六边形画像。



“治未病”处方

根据最终得分输出可落地的系统级重构、扩容或缩容建议。



AI全局风险诊断

不仅给单个指标打分，更能对多集群异常进行共性根因推理。

3-5、Hadoop集群健康度智能体：量化体检，全局溯源

核心价值与成效



健康检测效率 +500%

全集群健康回溯从人工“小时级/天级”飞跃至“分钟级”。



全景覆盖率 = 100%

无死角覆盖所有纳管集群的核心健康指标，消除盲区。



精细化容量管理 + 90%

提前识别存储与计算瓶颈，资源规划精度显著提升。

01 模式转化

传统被动式：

凭直觉拍脑袋 ➡ 数据抽样不全 ➡ 事后应对瓶颈。

智能主动式：

精准数据打分 ➡ 全量自动采集 ➡ 前置规划扩缩容。

02 全网基础设施规划科学度提升 +40%

通过将模糊的集群状态转化为直观的具体分值与诊断建议，决策层能够清晰看到每个资源池的健康水位，彻底告别“凭感觉采购”。

业务赋能成效：精准指导来年的预算申报与硬件淘汰计划。通过预知存储容量瓶颈并提前引导冷热数据分离，避免了突发式采购，实现 IT 预算的科学规划。

3-6、Flink作业健康度智能体：多模推理，降噪归因

背景与挑战：传统运维链路中，SRE从“看到告警”到“动手修复”平均耗时30-60分钟；巡检依赖人工经验，故障定位靠“翻日志、拼指标、写结论”，全链路效率低下且难以标准化。

01 告警风暴掩盖关键信号

海量作业产生大量告警，关键故障信号被噪声淹没，SRE难以快速识别真正需要处理的异常。

02 诊断依赖人工经验

不同SRE对同一指标的处置方式差异大，缺乏统一评估标准，诊断结果不可复现。

03 根因分析链路断裂

从异常现象到根因定位需跨越Prometheus、Flink Web UI、日志系统等多个工具，认知成本高。

04 巡检覆盖范围有限

人工抽样巡检只能覆盖少量作业，无法实现200+生产作业的全量健康状态监控。

3-6、Flink作业健康度智能体：多模推理，降噪归因

技术方案：聚焦建立了一套涵盖数据、知识到应用的健康模型。数据采集 — 多维评分 — AI根因推理 — 前端可视化。

01 数据采集

Prometheus 6维指标

02 多维评分

0-100多维健康评分

03 AI根因推理

Qwen3-32B多模态融合

04 前端可视化

Flink Doctor Agent

配置管理三层架构体系

应用层 · 核心场景覆盖

提供 Flink Doctor 概览、“全局总览+巡检列表+AI诊断报告”三件套。

能力层 · 自动化执行引擎

基于大语言模型（如 Qwen3-32B）打造的多模态融合根因推理引擎。

底座层 · 标准化支撑体系

采集 Prometheus 六维核心指标（CPU负载/堆内存/任务反压/Checkpoint/重启/Kafka延迟）。

核心技术亮点



六维立体归因矩阵

统一评分标准，扣分明细完全可追溯，支持人工30秒复核。



智能化处方输出

建立从“异常现象 → 异常原因 → 诊断结论 → AI处方”的标准流水线。



大模型多模态推理

创新性地将结构化指标曲线、文本日志和配置参数“喂”给AI做联合推理。

3-6、Flink作业健康度智能体：多模推理，降噪归因

核心价值与成效



评估耗时节省 +95%

从传统链路的 30 分钟骤降至智能页面的 1.5 分钟。



故障定位缩短 -88%

排查耗时从 45 分钟缩减至 5 分钟内，大幅保障实时性。



全量无死角覆盖 =100%

200+ 生产作业全量接入，巡检覆盖率从 20% 飞升至 100%。

01 模式转化

传统被动式：

看告警 → 查指标 → 翻日志 → 写定位 → 处置（耗时30-60分钟）。

智能主动式：

打开页面 → 看健康分数 → 直达AI多模态诊断报告（耗时60-90秒）。

02 大规模流计算治理成本断崖式下降

原来只能靠人工随机抽查的 200+ 生产作业，现在全部实现了全量自动化日常体检。

人力赋能成效：新集群监控能力接入仅需 1 个人天。一线的初级工程师也能凭借 AI 出具的深层诊断报告，直接处理复杂的 Flink 内存泄漏或参数失调问题，大大稀释了昂贵专家的运维压力。

3-7、割接变更管理智能体：拓扑防爆，受控执行

背景与挑战：传统集群运维依赖人工经验排查，缺乏标准化量化评分体系，数据统计滞后、覆盖不全，难以提前识别潜在风险，运维变更管理的困境：效率瓶颈 | 高风险操作 | 管理混乱。

01 变更黑盒，影响面评估不足

版本升级、网络割接等变更操作前，对上下游依赖和潜在影响评估严重依赖人工，极易漏判。

02 操作标准化差，过程难追踪

变更步骤多散落于 Word 或 Wiki 中，执行全靠人工“复制粘贴”，缺乏受控的自动化执行引擎。

03 验证手段匮乏，事后回滚慢

割接后缺乏全视角的自动化验证手段，业务连带受损往往在事后被客诉发现，回滚操作极度滞后。

04 事故追溯难，复盘流于形式

变更缺乏可审计的结构化记录，出了事故难定责，经验教训无法有效沉淀至下一次变更。

3-7、割接变更管理智能体：拓扑防爆，受控执行

技术方案：聚焦建立了一套涵盖数据、知识到应用的工单审计模型。

01 工单解析

AI自动初审变更方案与操作规范性

02 影响面评估

结合CMDB拓扑绘制“爆炸半径”拦截高危项

03 剧本编排

将文本SOP拆解为可自动执行的 Ansible 剧本

04 受控执行

大模型配合 MCP 安全网关步步确认、下发变更指令

配置管理三层架构体系

应用层 · 核心场景覆盖

提供变更工单智能审核、影响面拓扑分析与智能安全割接看板。

能力层 · 自动化执行引擎

依赖智能图谱引擎评估爆炸半径，配合 MCP 安全网关调度执行。

底座层 · 标准化支撑体系

拉通CMDB关系链、历史变更事故知识库与标准操作SOP库。

核心技术亮点



事前智能评估拦截

AI 自动解析变更文档，绘制“爆炸半径”拓扑图，拦截高风险操作。



事后全息自动比对

割接完毕后一键拉起自动化巡检，深度比对前后业务状态，确保平滑。



事中严密受控执行

大模型拆解工单，通过安全网关下发指令，步步确认，防范误操作。

3-7、割接变更管理智能体：拓扑防爆，受控执行

核心价值与成效



重大变更事故率 -100%

拦截超高危变更隐患，割接由于操作不当引发的事故率降至0。



变更审批效率 +300%

AI自动初审工单质量与影响面，极大缩短人工审核排队时间。



变更执行耗时 -70%

从人工敲命令转为受控流执行，割接窗口期大幅缩减，降低业务阵痛。

01 模式转化

传统被动式：

人工写文档 → 凭经验审核
→ 手工敲命令 → 业务客
诉报障。

智能主动式：

AI画拓扑测风险 → 机器拦截
高危 → 闭环受控执行 →
事后主动校验。

02 高危操作引发的事故率清零

通过系统级的事前评估、事中拦截和事后验证，成功排除了因疲劳操作、疏忽大意导致的人为破坏风险。

风险治理成效：重塑了整个 IT 割接文化，从“提心吊胆的黑盒操作”变成了“安全透明的标准化流水线”。变更全程留痕，复盘有据可依，真正将重大变更的安全底线牢牢守住。

04

总结与展望：智能的运维新生态

总结：迈向运维新范式



01 核心挑战：结构性困境

人不够 · 活太多 · 风险高 · 效率低

传统运维陷入资源与需求的严重错配，人工响应滞后于故障发生。被动式救火不仅消耗大量人力，更难以应对云原生架构下的高并发挑战，系统稳定性面临严峻考验。



02 核心解法：运维智能体

规则先行 · 模型辅助 · 主动协同

以“运维智能体”为中枢重构体系，用确定性规则守住稳定底线，用大模型解决非标难题。实现自动化执行与智能化决策的深度融合，推动运维从工具驱动向智能驱动跨越。



03 核心价值：价值重塑

效率跃升 · 稳定加固 · 价值创造

将运维人员从重复劳动中解放，转向架构优化等高质量工作。实现故障处置效率指数级提升，构建可预测、可自愈的韧性系统，为业务创新与规模化增长提供坚实基础。

从被动响应到主动创造，以智能运维为支点，撬动企业数字化运营的全新增长极，共同迈向更高效、更稳定的运维新范式。

展望：共建智能运维新生态

01 近期规划



扩大覆盖范围

将智能体能力拓展至数据库、消息队列等核心中间件，打破运维孤岛，实现对复杂业务场景的全链路智能化监控与管理。



深化模型能力

引入运维知识图谱构建领域知识库，结合实时告警数据与历史案例，显著提升故障诊断的精准度与决策的可解释性。

02 远期展望



迈向主动式 AIOps

基于机器学习实现资源与故障趋势预判，从“事后补救”转向“事前预防”，自动化识别潜在风险并提前干预，保障系统极致稳定。



构建开放赋能生态

打造标准化的运维智能体开放平台，提供低代码接口与组件库，赋能各业务团队自主定制运维工具，形成共建共享的技术生态。

让我们共同努力，推动运维工作向更高阶的智能化、自主化迈进，以技术赋能业务，用智能驱动未来！

THANKS

