

构建 Agent 时代的实时数据分析底座

马如悦, SelectDB, 2026.7



面向智能体时代的

极速实时分析数据库

Ultra-fast real-time analytics database for the Agent Era.

The Future of Analytics Is Real-time and Agentic.



AGENTIC AI
超级智能系统架构峰会

面向智能体的分析

Agentic Analytics

面向客户的分析

Customer-facing Analytics

面向终端用户/客户的在线数据产品

比如：用户行为分析、实时推荐、风控决策

低延迟，高并发

数仓分析

Warehouse/Lakehouse Analytics

企业内部多负载混合分析

比如：仪表盘、报表、即时分析

开放格式、共享联邦

可观测分析

Observability Analytics

日志·指标·链路统一分析

比如：故障定位、性能监控、安全审计

高吞吐、极致性价比

当 AI 不再是稀缺品，只有各自的数据不会撞车。对数据的实时分析能力，就是下一个核心生产力。

SelectDB: Real-Time Analytics for AI Agents

极速实时

极致性价比

多模统一

极速实时

亚秒级响应不是优化，是底线

ASAP

DataFun.

AGENTIC AI
超级智能系统架构峰会

Agent 的分析不是"一条 SQL"，而是一个多步推理循环

5~15

一次提问触发的 SQL 数




50+

复杂对话可触发查询数

×10~50

延迟放大倍数

比同类系统快 5-10 倍的极速分析性能



极速实时成功案例



200+ 集群 · 百 PB 数据

极速实时分析

日均 20 亿+ 次查询，从 ClickHouse 到 Doris 的统一 OLAP 底座

- 百 PB 级数据、200+ 集群、数千张表，支撑商业化、电商、AB 等多业务线。
- 查询性能**提升数倍**，多表 JOIN 和湖仓查询能力大幅超越 ClickHouse。
- 迁移平台"星移"自动化：DDL 转换、任务复制、数据校验全流程 **分钟级** 完成。

全球 Top-5 Web3 业务 总部新加坡 · 8000 万+ 用户

极速实时分析

日均 \$100 亿交易量，P95 查询延迟 30ms

- 1-3 秒数据就绪：Flink CDC 实时同步，数据产生即查，支撑风控与反洗钱。
- 峰值 5,000 QPS，P95 < 500ms；交易排名场景 **P95 仅 30ms**。
- 400TB+ 交易数据，跨 AZ 高可用，零中断，**30 分钟 Spark 任务缩至 3-5 分钟**。

应对 Agent 时代大数据量、大查询量和负载的不可预测

传统架构的困境

- ✓ BI 负载有规律：每天/每周固定刷新，可提前预留资源
- ✓ Agent 负载完全不可预测：一次追问触发数十条查询
- ✓ 峰值可能是平时的 10~100 倍
- ✓ 为峰值预留 大部分时间闲置 成本严重浪费
- ✓ Agent 时代，数据量和分析量都会大10-100倍

Cloud Native & Serverless 是最好的解决之道

- ✓ 存算分离：计算和存储独立伸缩，互不制约
- ✓ 秒级弹性：高峰自动扩容，低谷自动缩回
- ✓ 按量计费：只为实际查询付费，Ad-Hoc 零浪费
- ✓ 免运维：团队聚焦 Agent 场景，不被集群管理拖累

Agentic 分析成本的高性价比变得更为关键。

阿里云 SelectDB Serverless 已于26年3月份正式商业化，提供秒级弹性伸缩，大幅降低计算费用。

Cloud Native & Serverless 成功案例

阿里云

DataFun.

AGENTIC AI
超级智能体系系统架构峰会



收钱吧 连锁餐饮数字化

SelectDB Serverless

门店年增 50%，算力成本反降 32%+

- 痛点：为应对峰值按最高配置，**平峰闲置超 60%**；多负载争抢资源，核心报表频繁卡顿。
- 方案：采用 SelectDB Serverless，秒级弹性伸缩 + 独立计算资源组实现负载隔离。
- 效果：**算力成本降 32%+**，运维成本降 83%，查询性能提升 80%+。



MINIMAX MiniMax GenAI 可观测性

SelectDB 存算分离

PB 级日志，扩容从天级降至分钟级

- 痛点：自建 Doris 扩缩容需数据迁移，**PB 级耗时数小时甚至天级**；多业务共享实例，资源争抢频繁宕机。
- 方案：迁移至 SelectDB 存算分离架构，弹性伸缩 + 多集群硬隔离 + 读写分离。
- 效果：扩缩容**分钟级**完成，计算资源降 40%，热存储降 50%，P95 查询 <3s。

内外表统一，一条 SQL 跨源访问

- ✓ Iceberg / Hive / Paimon 湖上数据
- ✓ MySQL / PostgreSQL 关系库
- ✓ S3 / HDFS 对象存储

多模数据统一，一条 SQL 混合查询

- ✓ JSON 半结构化
- ✓ Text 全文
- ✓ Vector 向量

多模统一成功案例



洋钱罐 瓴岳科技 · 全球金融科技

湖仓一体 · 跨源统一

Hive 透明加速，P95 降低 90%+，日均 500 万次查询

- 无需数据迁移：SelectDB Hive Catalog 直连数据湖，**98% Hive SQL 兼容**，业务无感切换。
- 智能路由覆盖 **95% 查询**，P95 响应从 300 秒降至 20 秒，缓存命中率 90%+。
- 计算资源 1000+ Core，数据导出从 300 秒缩至 **20 秒**，DQC 从 43 分钟缩至 25 秒。



HubSpot 全球 CRM 领导者

多模统一 · 搜索分析融合

统一 ES + Snowflake，一个引擎覆盖搜索与分析

- **Elasticsearch + Snowflake → VeloDB**：搜索与分析合并为**单一平台**，消除跨系统 JOIN 瓶颈。
- **Variant 列存**：原生处理 **10000+ 子列**的动态 JSON，自动类型推导 + 专项倒排索引。
- 向量检索 + 全文检索 + Iceberg 湖上查询**一条 SQL**，支撑智能 CRM 与 Agent 实时推理。

三种产品形态

SelectDB Cloud

全托管的极速分析数据库服务，多云原生，支持 SaaS 和 BYOC 两种模式，

国内上线阿里云、华为云、腾讯云和亚马逊云科技。

国外上线AWS、GCP和 Azure。

SelectDB Enterprise


自管理私有化软件，部署在物理机、虚拟机或 K8s 上。长周期稳定内核，企业级安全合规，专业团队技术支持。

阿里云 SelectDB


阿里云与飞轮科技联合推出的云原生分析数据库，深度集成阿里云生态，阿里云用户首选方案。

面向智能体时代的**两大解决方案**

Agent Observability and Evaluation Stack




Agentic Analytics Stack



Litefuse : 基于 SelectDB 的端到端 Agent 可观测与评估平台


Agent 观测与评估的意义




Litefuse 将 EDD 产品化的 Agent 可观测与效果评估平台




Agent 观测与评估的意义



LITEFUSE 基于 LANGFUSE 和 SELECTDB 构建



Litefuse - Observability 解开 Agent 执行黑盒




Litefuse - Evaluation 评估 Agent 效果



Variant 类型 - 最高效存储分析 Agent 产生的数据

Agent 产生的数据挑战

- Free Schema
- 稀疏多列，有的场景多达成千上万列
- 大字段，有的字段甚至到 MB~百MB级别



SelectDB解决方案 - Variant

- VARIANT 数据类型可以存储任何合法的JSON，可自动从JSON中抽取字段并推断其类型
- 抽取的字段存储为VARIANT列的子列，列存的方式存储，能够高效压缩存储和分析
- VARIANT的方案使得半结构化数据处理效率逼近结构化数据，同时又满足了灵活性的目的

方案	存储空间	第一次查询时间	第二次查询时间	第三次查询时间
ETL 转结构化	12.618 GB	233.79 s	86.02 s	83.03 s
JSON as VARIANT	12.718 GB	248.66 s	94.82 s	92.29 s
JSON as String	JSON String35.711 GB	大部分超时	789.24 s	743.69 s

阶跃星辰 - 基于 SelectDB 的 Agent Trace 观测性方案

Agent Trace 对数据底座提出的新挑战

记录的是 Agent 决策过程，而不是传统服务日志

Agent 链路天然高并发、高基数、半结构化；观测平台必须同时承载实时写入、灵活检索与持续聚合。

Day0就需要构建完整的数据加工与分析能力

EDD驱动，AgentOps流程要求数据回流与标注




宽事实链建模

prompt / tool / retrieval / usage 等动态字段快速增长，要求支持半结构化存储与跨层级关联。



灵活检索钻取

既要 trace_id 秒级点查，也要检索 message、metadata、tool_args 并做即席分析。



多维指标聚合

从延迟 / 错误率扩展到成功率、质量、Token、成本，需要分钟级多维 Rollup。



混合负载治理

实时写入、明细钻取、BI 看板和长期留存并存，要求资源隔离与弹性扩展。

为什么 SelectDB 适合 Agent Trace

灵活事实建模

VARIANT 承载动态 metadata，Unique Key 支持状态补齐，明细与终态同库分析

高效检索钻取

倒排索引加速 trace_id / 文本，支持 message 与 JSON path 过滤，点查、检索、聚合同引擎

可复用Rollup

异步 MV 沉淀多维指标，分区增量刷新降低重算，透明改写服务 BI / API

能力要求更综合

Stream / Routine Load 实时写入，Workload Group 隔离负载，FE + BE 在线扩展

Trace记录着模型从决策到行动的事实 应对运行轨迹的不确定性，提供观测手段

推理的不确定性

Prompt、Reasoning、Tool Call、Sub-agent 共同构成了一次完整的Agent Invoke

会话复盘

多轮任务按 session 回放，定位上下文漂移、记忆错位与失败分支。

成本治理

Token、模型版本、Prompt 模板与调用来源进入统一归因口径。

元数据检索

用户、环境、模型实例、业务标签作为高基数维度直接参与过滤与倒排。

评测闭环


线上 Trace 回流 Eval / Dataset / 回归集，失败样本一键沉淀。

Infra 关联


推理调度、KV cache、沙箱状态、灰度分桶与业务链路联动。

Minimax - 基于 SelectDB 的日志和 Agent 观测场景实践

基于Loki的早期日志系统



基于Doris的全新日志系统



数据规模：数PB级 写入性能：数十GB/s 查询：秒级响应

2 倍

查询性能提升

- SQL 查询语言，支持 Join，相比 DSL简单，表达能力强
- 高效的执行引擎和优化器，高效的索引与文本分析

5 倍

写入吞吐提升

- 简化去掉正排等索引结构，减少倒排数据量 30%
- 列式存储和ZSTD高效压缩，提供 5-10 倍压缩比
- 存算分离，冷热分层，大幅降低冷数据成本

80%

存储成本降低

- 向量化指令，提升数据解析，索引构建的性能
- 简化去掉正排等索引结构，降低索引构建开销

稳定性

大幅提升

- 资源隔离和大查询限制
- 高效内存管理，避免 Java GC 影响

Agentic Analytics: 让 Agent 理解和分析企业数据

语义层和 MCP Server

Agent 的盲区

- 不知道“活跃客户”= 30天有交易，还是 7天打开过 App
- 看不懂 tbl_usr_trx_v5 的业务含义
- “流失率”按账户、用户还是设备计算？
- 无法自行发现跨表、跨源的数据关联关系

SelectDB 的解法


语义层 Semantic Layer

- 语义指标治理，Agent 查的是治理过的业务指标，而非裸表
- 跨源统一口径，“月收入”“活跃客户”在所有数据源上一致

MCP 标准接入

Claude / Codex / Cursor 一次接入，所有 Agent 通用数据发现，Schema 查询，语义检索，SQL 执行

CURSOR Claude OPENCLAW



THANKS

