

从 BIRD 第三到生产可用：小米 Data Agent 落地实践

演讲嘉宾：方彪

目录

CONTENT

- 01 小米Data Agent介绍
- 02 落地挑战与解法
- 03 实践案例
- 04 经验与展望

01

小米Data Agent介绍

小米 Data Agent 总览

DataFun.

AGENTIC AI
超级智能系统架构峰会

小米Data Agent 全貌



本次聚焦：分析Agent



周活5万的BI平台之上，为什么还需要分析Agent

AGENTIC AI
超级智能体系架构峰会

BI 的四堵墙

专业要求高

需会搭看板、写 SQL、建报表 → 非技术用户被挡在门外

不够智能

只展示数值不分析：是否异常？什么原因？该深入什么？

灵活性差

新增指标要排期、改看板等数周，依赖数据人员

决策不闭环

看板看完就结束，数据到业务决策的后链路断裂

分析 Agent 的解锁



自然语言对话

对话式问数，零门槛，无需任何技术背景



智能根因分析

异常自动诊断 + 维度拆解，不止于看数



即问即答，灵活下钻

随时提问即时回答，不排队等待



规则 + 行动闭环

接入业务规则与 Action，从分析直达决策

BI 是基础，Agent 是增强层 —— 解锁 BI 未能覆盖的长尾诉求

分析 Agent · 消费态

消费态

配置态

DataFun.

AGENTIC AI
超级智能体系架构峰会

用户视角：对话即分析，覆盖 问数 → 分析 → 呈现 的完整消费链路

① 对话式问数

自然语言，多轮追问

快速问数 · 人机交互 · SKILLS 调用

② 智能分析

不止看数，自动诊断

异常检测 · 根因分析 · 诊断建议

③ 可信呈现

结论可溯源，可视化

报告审查 · 数据溯源 · HTML 可视化


快速问数



异常根因

The screenshot displays a table with multiple columns, likely representing different data points or metrics. The table is organized into sections, with headers and sub-headers.

人机交互



计算工具



SKILLS调用



上下文压缩



报告审查



数据溯源



HTML可视化



分析 Agent · 配置态

消费态

配置态

DataFun.

AGENTIC AI
超级智能体系架构峰会

管理员视角：覆盖 接入 → 评测 → 调优 → 上线 → 监控 的完整建设链路



① 数据与语义接入

多源接入 + 语义配置

数据导入 · 语义管理 · 知识配置

② Agent 调优闭环

配置 · 评测 · 自迭代

Agent 配置 · 评测模块 · 效果自迭代

③ 上线与监控

权限 · 监控 · 多渠道

行列权限 · 线上监控 · 渠道接入

分析Agent内外现状

■ 集团内部落地

10+

业务领域规模化落地

千级周活

用户持续活跃使用

数千份

分析报告与数据洞察

10x+

用数 · 分析 · 决策提效

■ 外部公开榜单

BIRD 全球第三 | Text-to-SQL 权威评测基准

Overall Leaderboard				Single-Model Leaderboard		
Leaderboard - Execution Accuracy (EX)						
	Model	Code	Size	Oracle Knowledge	Dev (%)	Test (%)
	Human Performance <i>Data Engineers + DB Students</i>			✓		92.96
1 Dec 16, 2025	AskData + GPT-4o <i>AT&T CDO - DSAIR</i> [Shkapenyuk et al. '25]		UNK	✓	77.64	81.95
2 Sep 25, 2025	Agentar-Scale-SQL <i>Ant Group</i> [Pengfei Wang et al. '25]	[link]	UNK	✓	74.90	81.67
3 May 27, 2026	Xiaomi Text2SQL <i>Xiaomi ITP & Data</i>		UNK	✓	73.66	80.83 New Sub
4 July 14, 2025	LongData-SQL <i>LongShine AI Research</i>		UNK	✓	74.32	77.53
5 Apr 28, 2026	SiriusAI-Text2SQL-Agent <i>Tencent Data & Computation</i> <i>Platform Department</i>		UNK	✓	75.35	77.03

权威榜单问的是「能不能解题」，生产环境问的是「能不能长期稳定地答对」

02

落地挑战与解法

生产级 Data Agent 的五类不确定性

从「能解题」到「长期稳定答对」，是一条贯穿 输入 → 生成 → 度量 → 迭代 → 运维 的真实卡点链



①数据质量 | 多级语义回退架构: Metric → DSL → Reject

1 指标层 Metric

Text2JSON

原子指标

衍生指标

复合指标

业务域/口径/标签/认证

✓ 有指标直接查, 高可信路径

▼ 未命中指标 → 走语义模型

2 语义模型层

Text2DSL + 内置解析

度量

SUM / COUNT / AVG

维度

地区 / 时间 / 类目

关系

1:1 / 1:N / M:N

实体

primary / foreign / unique

语义解析

字段校验 · 歧义检测

关系连接

JOIN路径 · 笛卡尔积拦截

粒度映射

聚合粒度 · GROUP BY

安全拦截

行列权限

业务可自由建设, SQL 经过解析后执行

▼ 无语义模型覆盖 → 查底表

3 底表层

湖仓 · 直查数据库

ODS

原始数据层

DWD

明细数据层

DWS

汇总数据层

ADS

应用数据层

底表 Text2SQL, 无语义约束, 需人工校验

▼ 无法生成有效查询 → 兜底拒答

4 兜底 Reject

拒答 · 底线

明确拒答

不输出任何数据

引导优化

建议换问法 · 推荐指标

反馈闭环

驱动模型建设

用户教育

标注能力边界

x 宁可不说, 不可错说 · 保护业务决策底线

★★★★★

极高

官方认证指标库

★★★★☆

较高

语义模型 + DSL校验

★★★☆☆

中等

LLM直生成SQL

—
不输出

无可信来源

①数据质量 | 质量打分 + 血缘/日志驱动增强建议

对质量进行打分，并基于 **血缘+日志** 进行AI诊断给出 **诊断建议**，最后人工审核，**质量分达标**才可开启问答

语义增强 Agent

诊断建议 Agent

数据源

schema

生产作业

代码


查询历史

数据血缘

BI组件

表特征分析
数据粒度、表描述、业务知识、使用场景

字段特征分析



指标口径抽取

查询逻辑
指标定义

去重

质量分计算

- 表描述质量分
- 字段丰富质量分
- 字段歧义分

诊断建议

用户操作

采纳 拒绝
修改 自定义

质量分

>80分

开启问答

导入模型

1 选择模型

2 AI诊断

为保证问答准确率，请及时优化风险字段。

☒ 语义模型 localds_食堂测试数据 预览

AI诊断得分: 71, 检测到风险字段 42 个, 预估问答准确率低于 80%。为保证问答准确率, 请及时优化风险字段。

查看详情

AI诊断 - localds_食堂测试数据

AI诊断得分: 65, 检测到风险字段 51 个, 预估问答准确率低于 80%。为保证问答准确率, 请及时优化风险字段。

AI诊断修改建议

模型名称: localds_食堂测试数据 查看模型数据 模型数据

模型名称: localds_食堂测试数据 查看模型数据 模型数据

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。


设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

设备描述: 该表用于记录食堂员工的详细档案, 包括员工基本信息、薪酬信息、部门信息、职位信息以及一般统计指标。主要字段包括: 姓名、性别、出生日期、入职日期、部门信息、主要岗位、技能等级、职称、工作年限等。

②生成稳定 | 多路生成投票提高稳定性



②生成可信 | 可解释即可信任：数据溯源

① Data Agent 生成报告

多步推理 Agent
规划 · 取数 · 分析 · 成文

生成带数字的报告
“营收同比 +23% ...”

生成埋点

数字打 claim_id · 占位符携带工具上下文

带数字报告

② 数字捕获 & 来源分类

优先：埋点 claim 读取
直接拿到数字 → 来源绑定

兼底：规则 / 大模型 抽取
对缺 claim 的文本数字回抽

有数据源
可反向匹配

LLM 推导数字
无数据源 · 估算/预测

标记不可溯源

LLM 推导类 标为 untraceable, 直送④降级

可溯源数字

③ 来源绑定 (工具/推理)

SQL/根因/python
每个可溯源数字 → 产生它的查询

解析计算链

聚合 / 过滤 / JOIN / 衍生公式拆解

数字 + SQL

④ 置信度标注

来源方式得分
埋点高 / 抽取中

匹配分 / 歧义度
多候选冲突 → 降级

LLM 推导数字
不可溯源 → 最低级

综合置信度分级
高 / 中 / 低 / 不可溯源 · 低级醒目标签

带溯源+置信度

⑤ 可信报告交付

可下钻数字
每个数字可点击 → 来源



分级标识
高/中/低 · LLM 推导数字醒目标签

可信 · 可验 · 来源透明
交付结果

工具调用[置信度 高]

大模型计算[置信度 中]

大模型推导[置信度 中]



③评测构建 | 冷启动：BI 看板 + 智能生成

方式一：基于BI看板生成—看板的数据即标准答案



方式二：基于表字段智能生成——选择维度/度量 批量产出评测集样本



③评测构建 | 越问越准：基于用户行为智能挖掘

1 用户行为·信号分层

按行为可信度分强/弱

点赞 **强·正**

用户认可→正样本

点踩/报错 **强·负**

明确错误→负样本

多轮/空/其它 **弱·待定**

不确定→AI补判

强信号定标签，弱信号进AI判定

2 AI 预标注·只打草稿

把人从「从零写」降成「审草稿」

对每条样本，AI 出草稿供人修改

错因

诊断错在哪：
选表/口径/语
法/缺知识

较可靠

SQL草稿

对错误样本试
给SQL，准确
率有限仅作起
点

草稿

建议知识

从错因提炼，
如「默认只看
正式员工」

候选

全是草稿、不是结论 —— 准不准不重要，
人审才算数

3 人工审核·可信闸门

同时确认样本+知识

审核草稿包

AI 草稿只是参考，人来确认/
修改/拒绝，**审过的才算数**

接受✓
样本+知识
落库

拒绝✗
抛弃/改正

一个动作确认三样：对
错·SQL·知识

4 落库·两个产出

喂给自动优化

评测集

正样本=query+可信SQL
负样本=query+修正SQL

知识（副产品）

表/字段描述·业务口径
反哺语义层增强

↑ 知识随样本审核顺带沉淀

评测集→驱动自动优化闭环

用户每一次反馈，都在悄悄喂养这个系统 —— 越用越准

用户点赞



用户点踩



后台问答记录


更新时间	样本来源	状态	启用
2023-06-05 17:27:07	点踩	已审核	☒
2023-06-05 17:27:07	点踩	待审核	☐
2023-06-05 17:27:07	自动采集	待审核	☐

④优化提效 | Loop: 评测-归因-增强闭环

用户只需确认评测集，主动/定期 一键迭代，系统自动评测、错误分析、语义沉淀、再评测



用户一键开启优化



优化完成飞书通知



优化后用户审核



⑤抗衰减 | 回测监控 + 增量沉淀 + 语义层 CI

90% 上线 · 只是起点

数据 / 表结构 / 口径持续变化

无人维护 → 准确率逐日下降

防线 01

评测集持续回测

定期自动回测，效果下降自动告警；量化衰减、定位方向。

✓ 及时发现

防线 02

线上 query 增量沉淀

不浪费每次真实提问，持续归集为增量评测集养料，反哺迭代。

✓ 自动补充

防线 03

语义层变更 CI

像代码变更一样走审批，变更前后自动对比评测效果。

✓ 变更审核

上线不是终点，持续衰减才是数据系统的常态

03

实践案例

Before vs After: 非微小改善, 是数量级跃迁

Data Agent带来的效率跃迁

快速问数 1h - 1天 → 17秒

数百倍

根因分析 1 - 3天 → 2 - 5分钟

天 → 分

分析报告 1周 → 10分钟

周 → 分

新业务接入 月+ → 天+

月 → 天

标杆案例

金融销售

能力广度

一源覆盖多场景

文档政策 + 数据表问数

RAG

投票 · 溯源

人力资源

维度需求多样

分析思路 → 灵活配置

可视化要求高

智能路由

Skills 双沉淀

账单分析

协同深度

异常 → 根因

洞察 → 行动

溯源 · 根因

产品化闭环

效率提升的核心不是「快」, 是把人从「重复取数中解放出来」

案例：金融场景 · 问答 + 问数双需求

业务需求

一线人员多

海量文档 + 数据

问答需求

问数需求

同一人 · 两类需求并存

90%+

准确率
金融级精度

20x+

效率提升
小时→分钟

800+

评测集
持续运营验证

Data Agent解法

问答链路 · 找文档

文档散落找不到

RAG 文档问答

多轮澄清意图

问数链路 · 查数据

数要准 · 可回查

Verified SQL

多路投票

数字溯源

↑ 意图识别自动分流 · 问答走 RAG、问数走 SQL，支持RAG+SQL复合需求



「问数 + 问文档，一站式满足一线全部数据需求」

案例：人力资源场景 · 分析维度 + 可视化报告

DataFun.

AGENTIC AI
超级智能体系架构峰会

业务需求



Data Agent解法

沉淀分析思路

分析路径多

多轮澄清

Skills 沉淀分析思路

沉淀报告模板

报告格式多样

Skills 沉淀可视化模板

HTML报告风格：深度/精简/月度

200+

月活用户
覆盖多部门 HR

3.2次

周人均对话
消费频次

首次
自主取数

非技术零门槛
灵活取数



「分析思路统一，报告模板可复用，非技术 HR 也能拿到专业级输出」

案例：账单分析场景 · 可溯源 + 结果到人

业务需求



3天
→10分钟
报告生成

10+领域覆盖
标准化分析

洞察→行动
闭环
可追踪可量化

Data Agent解法

从数据到洞察

数不可信 · 异常说不清

数字溯源

异常根因诊断

从洞察到行动

生成→保存→签字→推送→跟进

数字到人，行动闭环

状态持续追踪

洞察列表	认证状态	创建时间
#153 finance miccode	未认证 创建人 审核人	2026-07-13 20:33
#154 finance jira_server	未认证 创建人 审核人	2026-07-08 19:53
#155 finance holo服务监控	未认证 创建人 审核人	2026-07-08 19:36
#156 finance 支出增长TOP3服务	未认证 创建人 审核人	2026-07-06 10:11
	已认证 创建人 审核人	2026-06-26 10:19
	已认证 创建人 审核人	2026-06-26 10:19
	未认证 创建人 审核人	2026-06-26 10:19

「DataAgent负责洞察，人Review报告内容 —— 从数字可信到优化落地」

新业务接入 SOP: 中台 × 业务, 标准化接入

DataFun.

AGENTIC AI
超级智能体系架构峰会

整体接入周期 1-2 周



一名懂数据的**业务 FDE** + 中台平台能力, **1-2 周**跑通新业务接入

04

经验与展望

分析Agent需要Harness

只有模型不够，可靠性来自 **Harness 工程闭环**，而非纯 LLM
数据分析不是写代码——没有护栏、答案唯一、无法确定性验证

BIRD 榜单排名 | Harness vs 纯 LLM

小米Harness排名						LLM baseline 排名					
Overall Leaderboard						Single-Model Leaderboard					
Leaderboard - Execution Accuracy (EX)											
Model	Code	Size	Oracle Knowledge	Dev (%)	Test (%)						
Human Performance Data Engineers + DB Students						✓				92.96	
1 AskData + GPT-4o AT&T CDO + DSAR [Shikanyuk et al., '25]		UNK	✓	77.64	81.95						
2 Agentar-Scale-SQL Ant Group [Pengfei Wang et al., '25]	[link]	UNK	✓	74.90	81.67						
3 Xiaomi Text2SQL Xiaomi ITP & Data		UNK	✓	73.66	80.83						
4 LongData-SQL LongShine AI Research		UNK	✓	74.32	77.53						
5 SiriusAI-Text2SQL-Agent Tencent Data & Computation Platform Department		UNK	✓	75.35	77.03						

同一 BIRD 榜单:

工程闭环 **第 3 名**，最强纯模型 **30~90 名开外**

- OpenAI GPT 5.5: 33
- Claude Opus 4.6: 48
- Qwen3-Coder-480B-A35B: 56
- GLM-4.7: 78
- DeepSeek-R1: 82
- Kimi-K2-Thinking: 87

Anthropic: Data is not software

Data is not software

LLMs' generative abilities are a double-edged sword: the mechanisms that enable creative solutions to complex problems can also hallucinate erroneous output. To fully understand the challenges with analytics agents, it's useful to compare them to coding agents.

Coding is an open-ended solution space that rewards the models' creativity, while documentation and tests provide natural guardrails against hallucination. In contrast, for analytics use cases, there's often only a single correct answer using a single correct source in which there's no deterministic way of proving the correctness.

Process Step	Coding	Analytics
Context	• Codebases are largely well maintained. I.e., READMEs, type signatures, docstrings, and commit history give the agents rich, structured context before it writes any code.	• A database often has millions of fields, many of them poorly documented. E.g., some notion of "revenue" may show up in thousands of places. • Even with the right field, different teams define the same metric differently. Two answers can both be technically correct, but situationally wrong.
Generation	• When it comes time to actually write the code, almost any spec admits many correct implementations, so a plausible answer is usually a valid one.	• Implementing an analytics solution is often trivial (i.e. 5 - 10 lines of SQL or Python), but equally as often there's only one correct approach.
Verification	• For all code that is produced, compilers, linters, and unit tests give fast, deterministic feedback.	• There's no compiler, no unit test, no ground truth. • Short of defining pre-set expectations, crudely triangulating against other sources, or baselining against historicals, there's no deterministic way to confirm the output is right.

数据质量差

答案唯一

SQL执行成功
不代表正确

AI 时代，分析 Agent 门槛很低

AI ERA · LOW BARRIER

门槛并不高 人人都能做

三重红利叠加，各团队都能
快速自建垂域分析 Agent

基建 CLI 开放

元数据获取 表结构 / 字段 / 血缘
数据查询 标准查询接口已开放
零启动成本 无需自建基础设施

场景 垂域复杂度 低

范围有限 聚焦该垂域数据与指标
业务理解深 垂域团队最懂自己数据
免口径对齐 无需跨域语义治理

成本 AI 提效

AI 工具 Claude / Codex 降门槛
Skills 机制 复用分析流程与知识
Agent 调用 快速嵌入现有 Agent

门槛这么低，中台重点做什么？

门槛很低，人人都能做。 但，做得起 $\neq$ 做得久

01 语义维护，成本越来越高

01 语义层治理基础设施

标准化语义层结构，业务语义一键高效导入，配套 CI / 版本 / 血缘 影响分析持续兜底。

↳ 数据与口径持续变化，自建治理设施不划算

02 线上准确性，如何持续保障

02 Harness 持续进化

让闭环更准、更快，评测 / 回测 / 监控成本更低，业务接入成本更低。

↳ 保障持续答对需专门工程，重复造轮子不划算

03 数据前链路，缺完整方案

03 全链路整合方案

打通开发 · 治理 · 分析三类 Agent，并开放 CLI / Skills——不要求必用，但更好用。

↳ 完整链路需多 Agent 协同，单团队建不全

中台不做别人做不了的事，而做别人做起来不划算的事

THANKS

演讲嘉宾：方彪
